Fundamentos de Deep Learning

Dr. Manuel Castillo-Cara
www.manuelcastillo.eu
Departamento de Inteligencia Artificial
Escuela Técnica Superior de Ingeniería Informática
Universidad Nacional de Educación a Distancia (UNED)

Preliminar

- Contrato de Manuel Castillo-Cara se encuentra financiado por la Unión Europea-NextGenerationEU

POLITÉCNICA

Ontology Engineering Group

GOBIERNO DE ESPAÑA

MINISTERIO DE UNIVERSIDADES

Índice

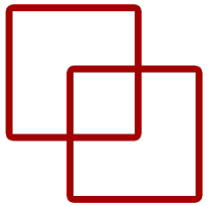

- Background
- Neurona
- Simulación
- Perceptron Multicapa
- Función de activación
- Cómo opera el MLP
- Backpropagation

Background

0. Background

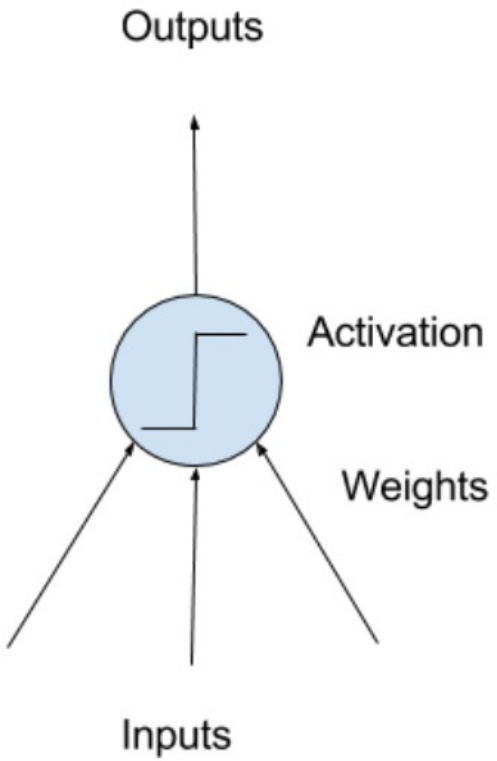

0. Background

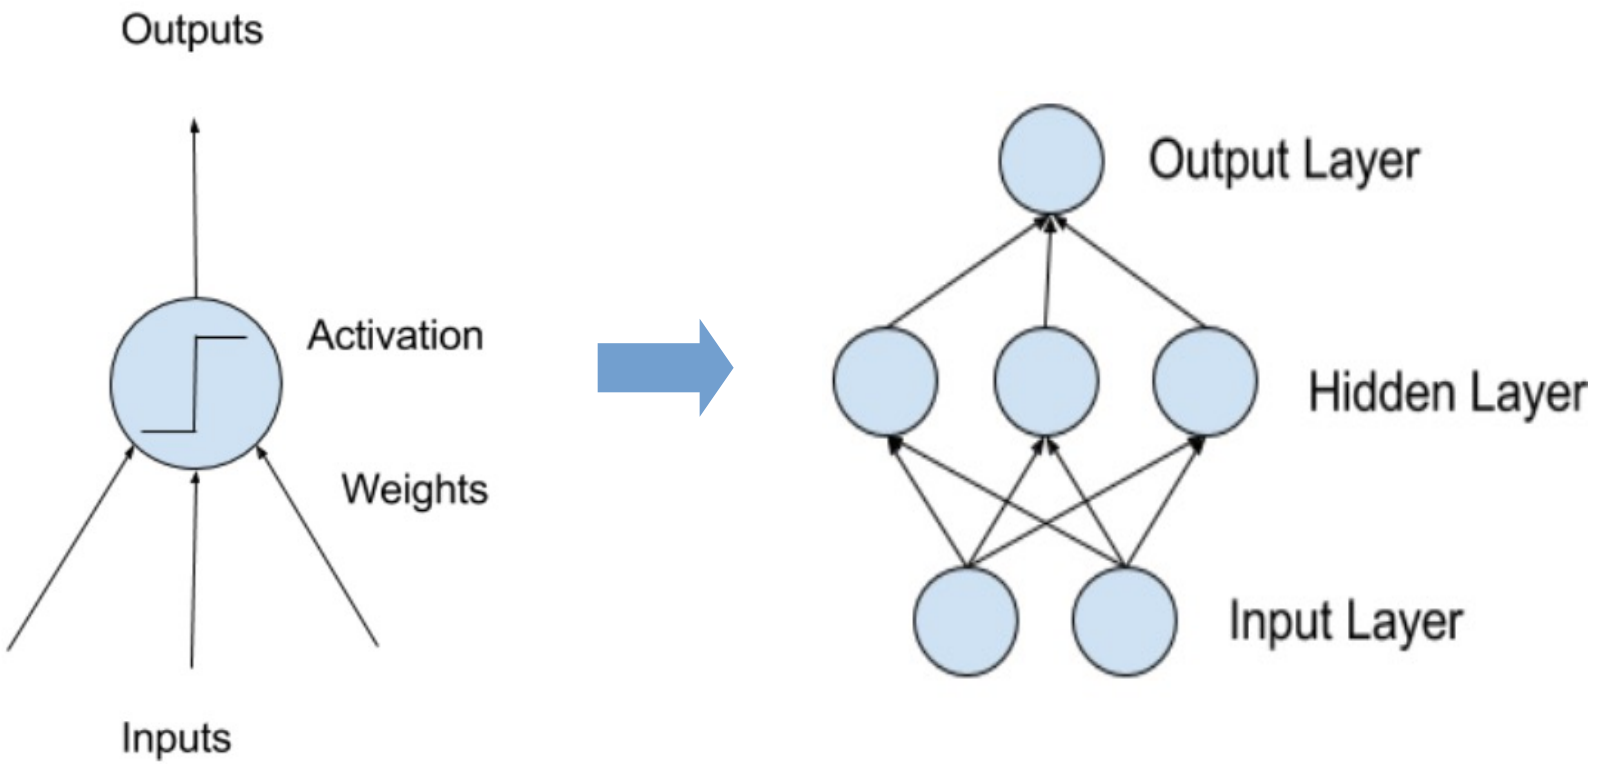

0. Background

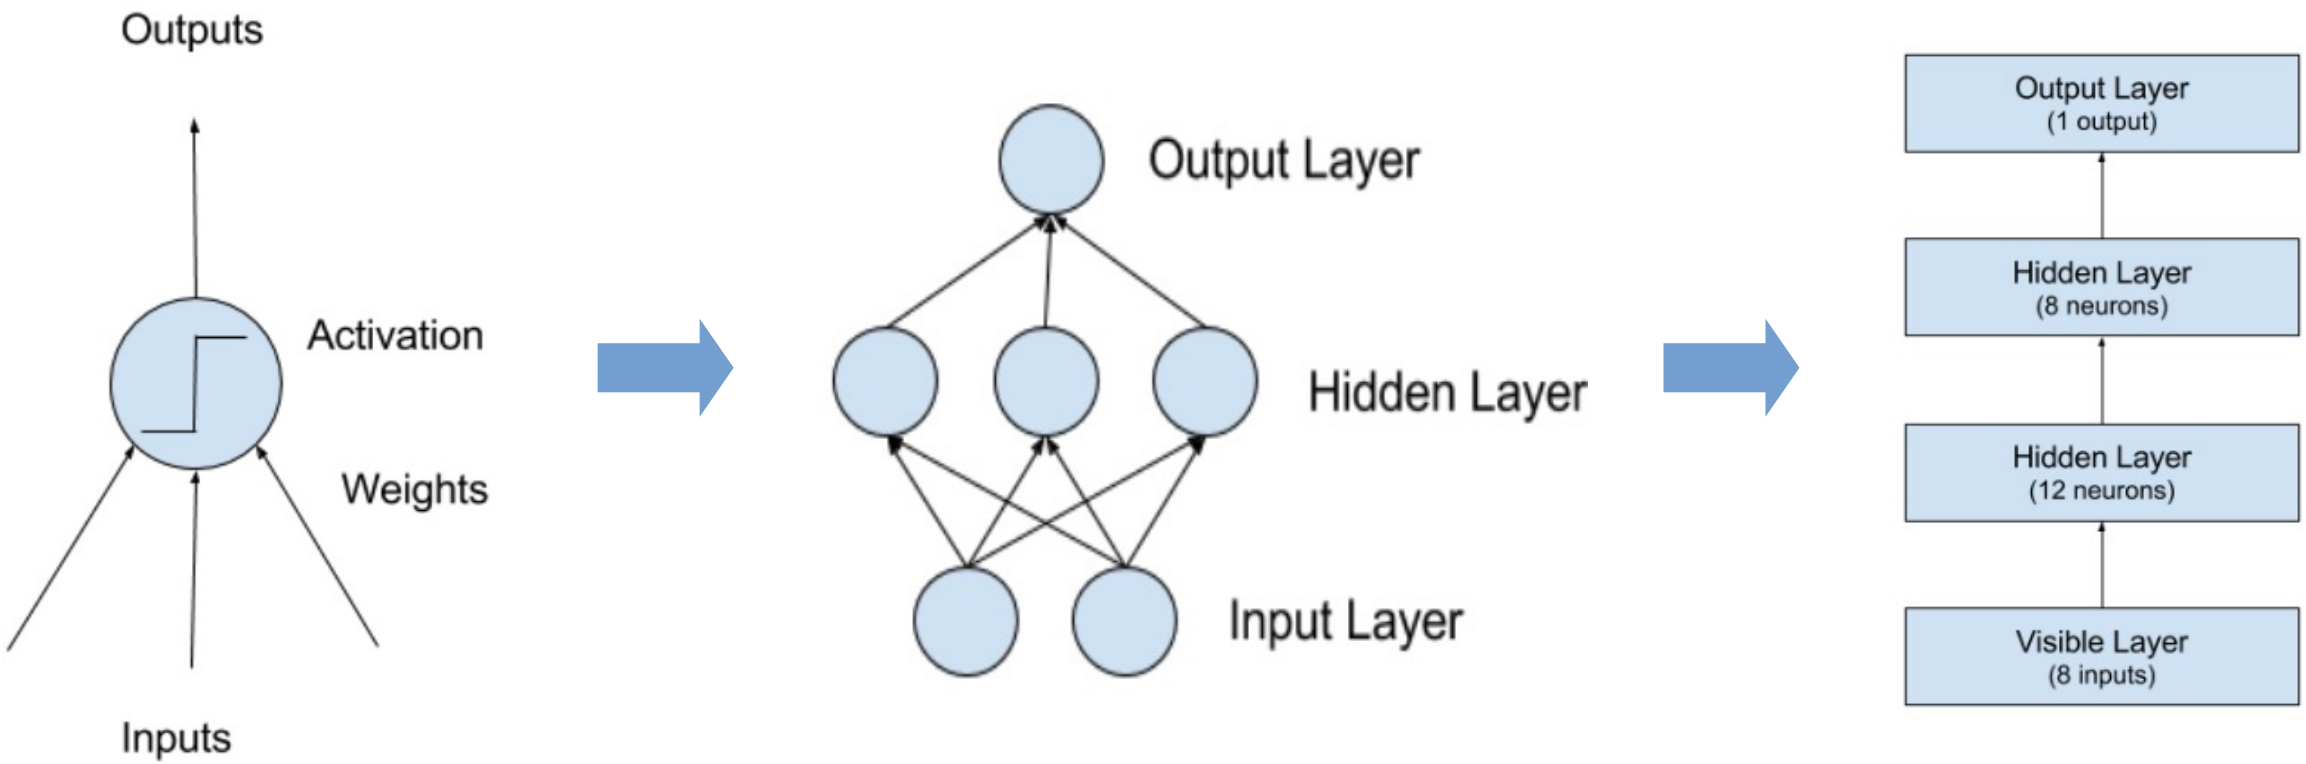

La neurona

ETS de Ingeniería Informática

UNED

1. Neurona

1. Neurona

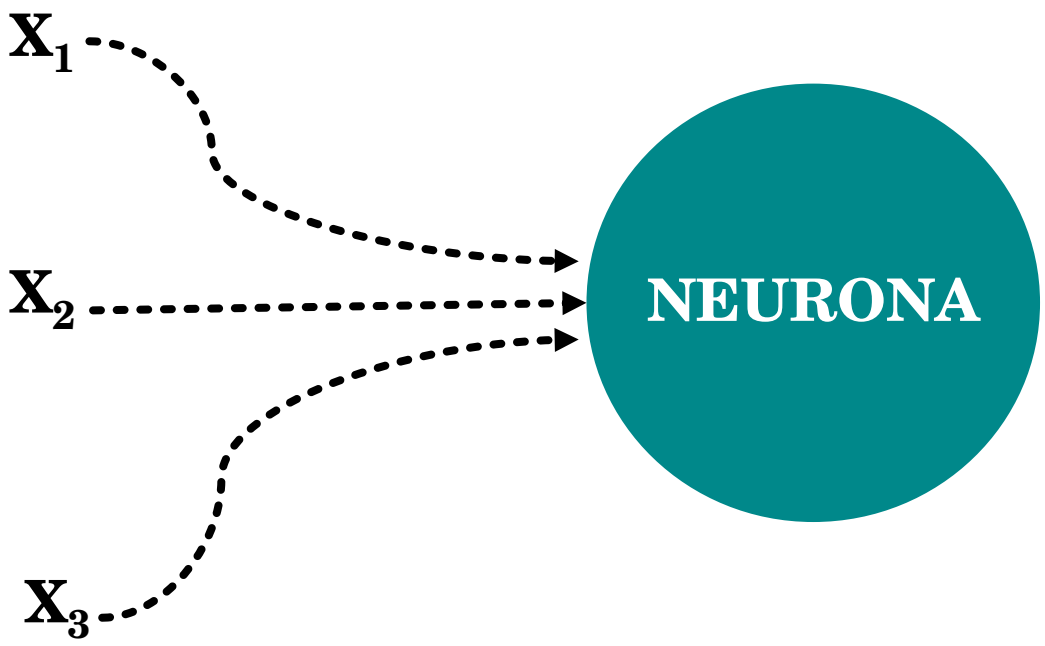

1. Neurona

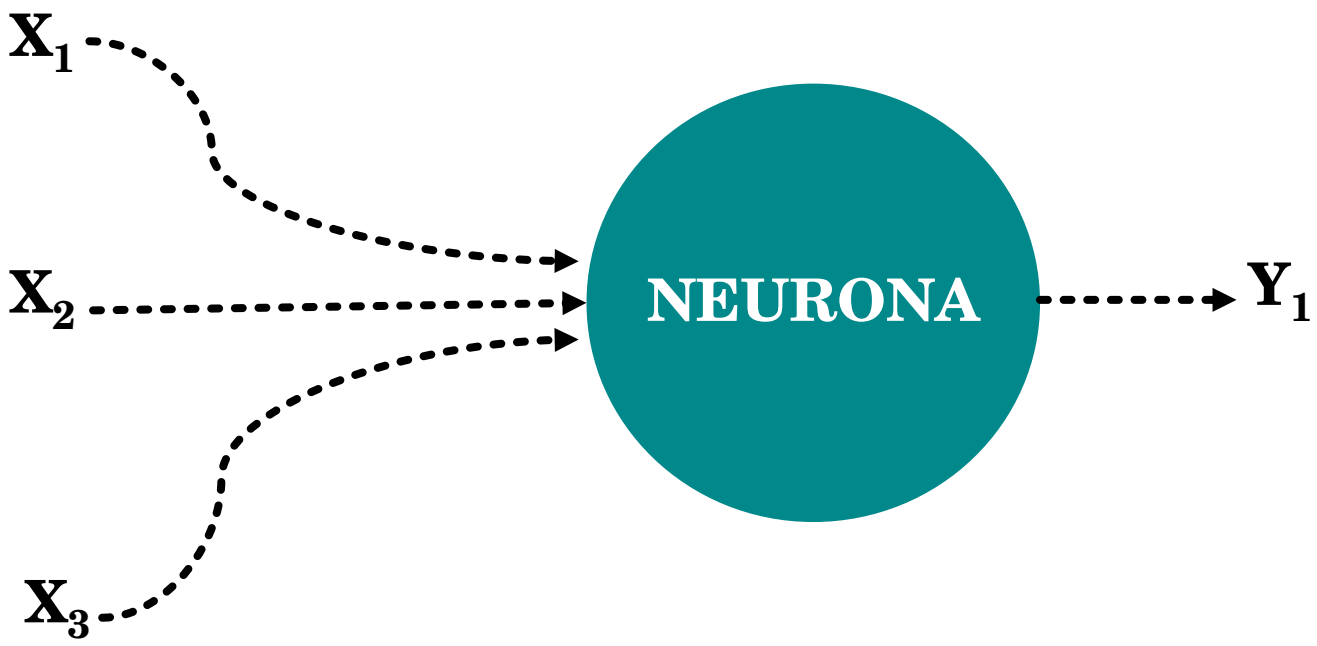

1. Neurona

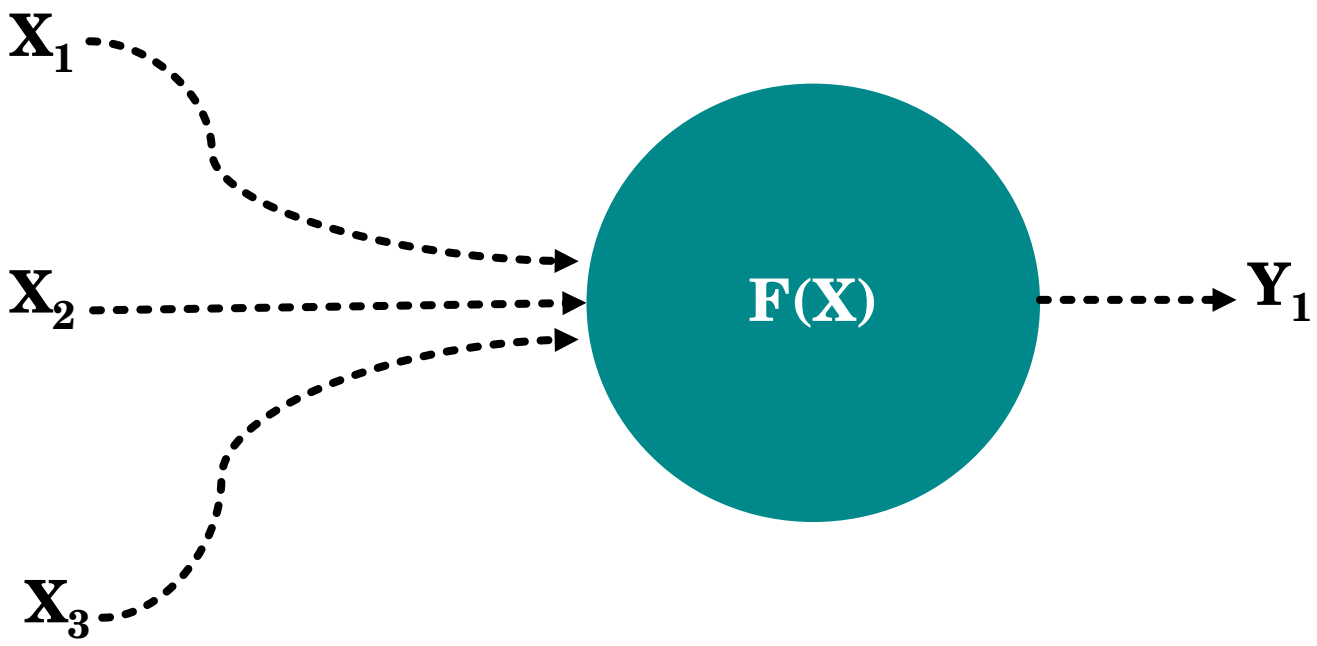

1. Neurona

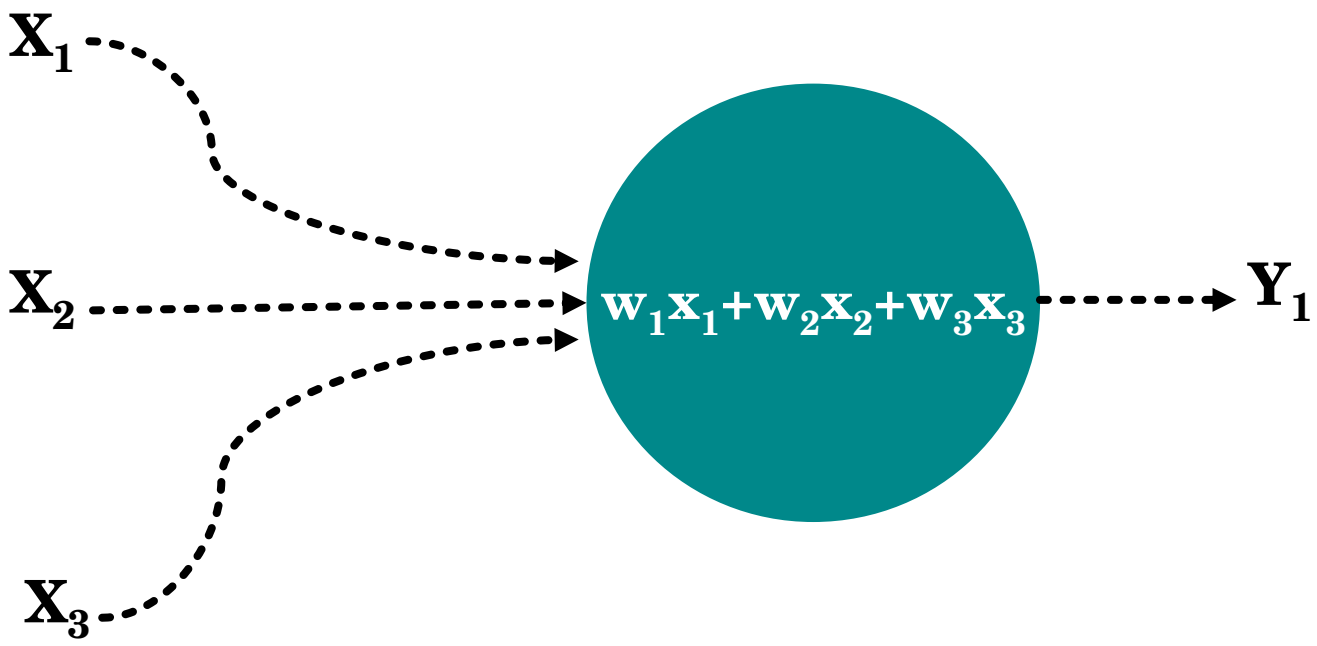

1. Neurona

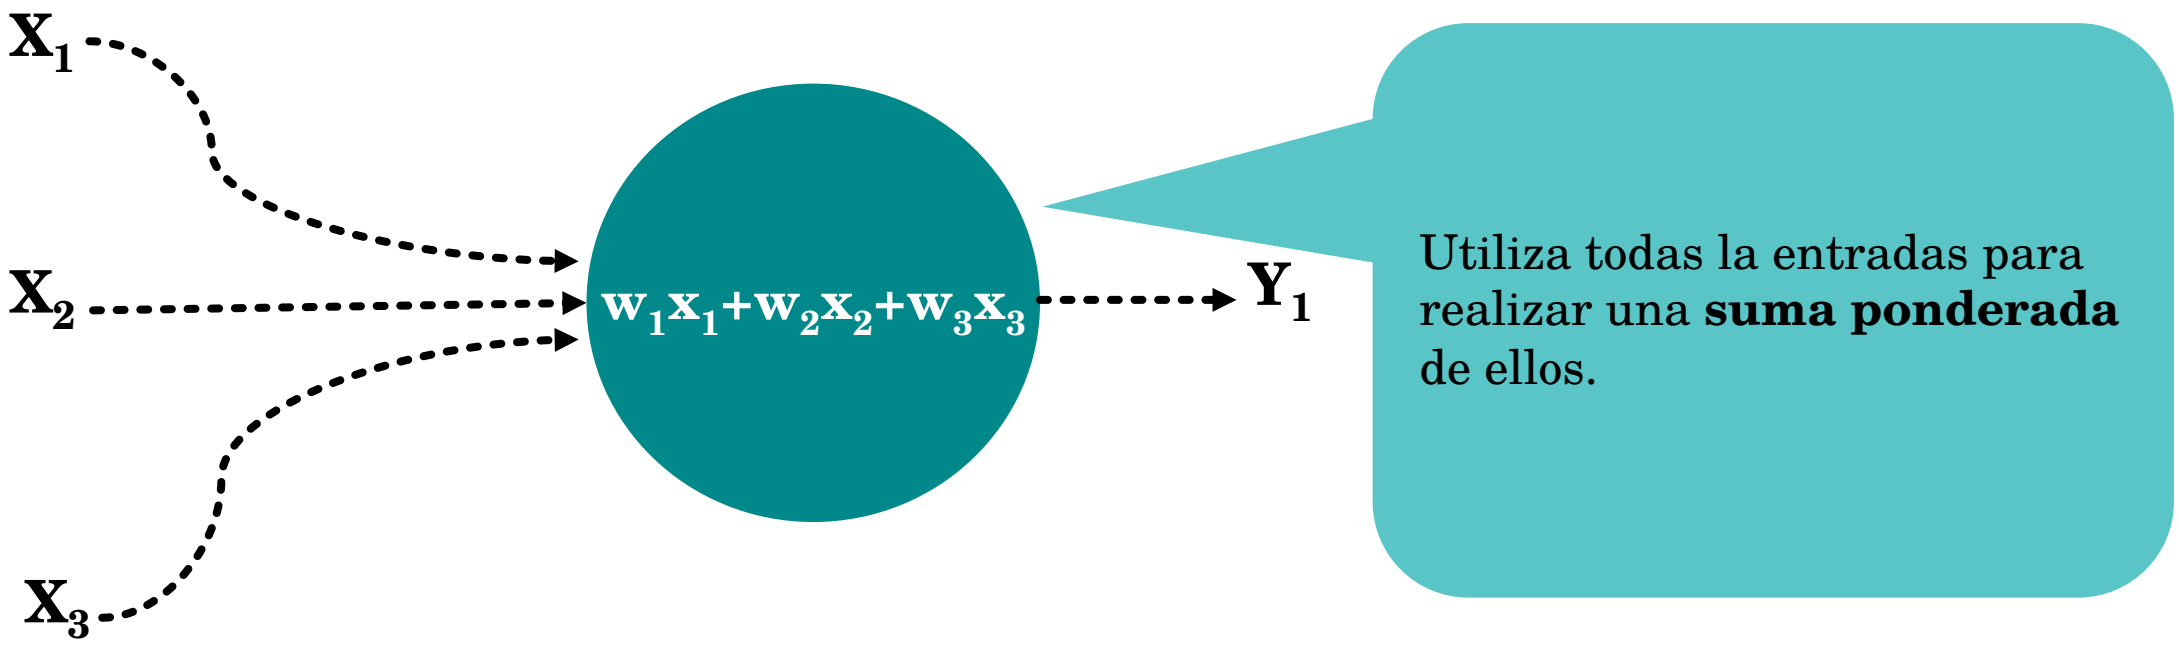
X_1
X_2
X_3
$w_1x_1+w_2x_2+w_3x_3$
Y_1
Utiliza todas la entradas para realizar una **suma ponderada** de ellos.

1. Neurona

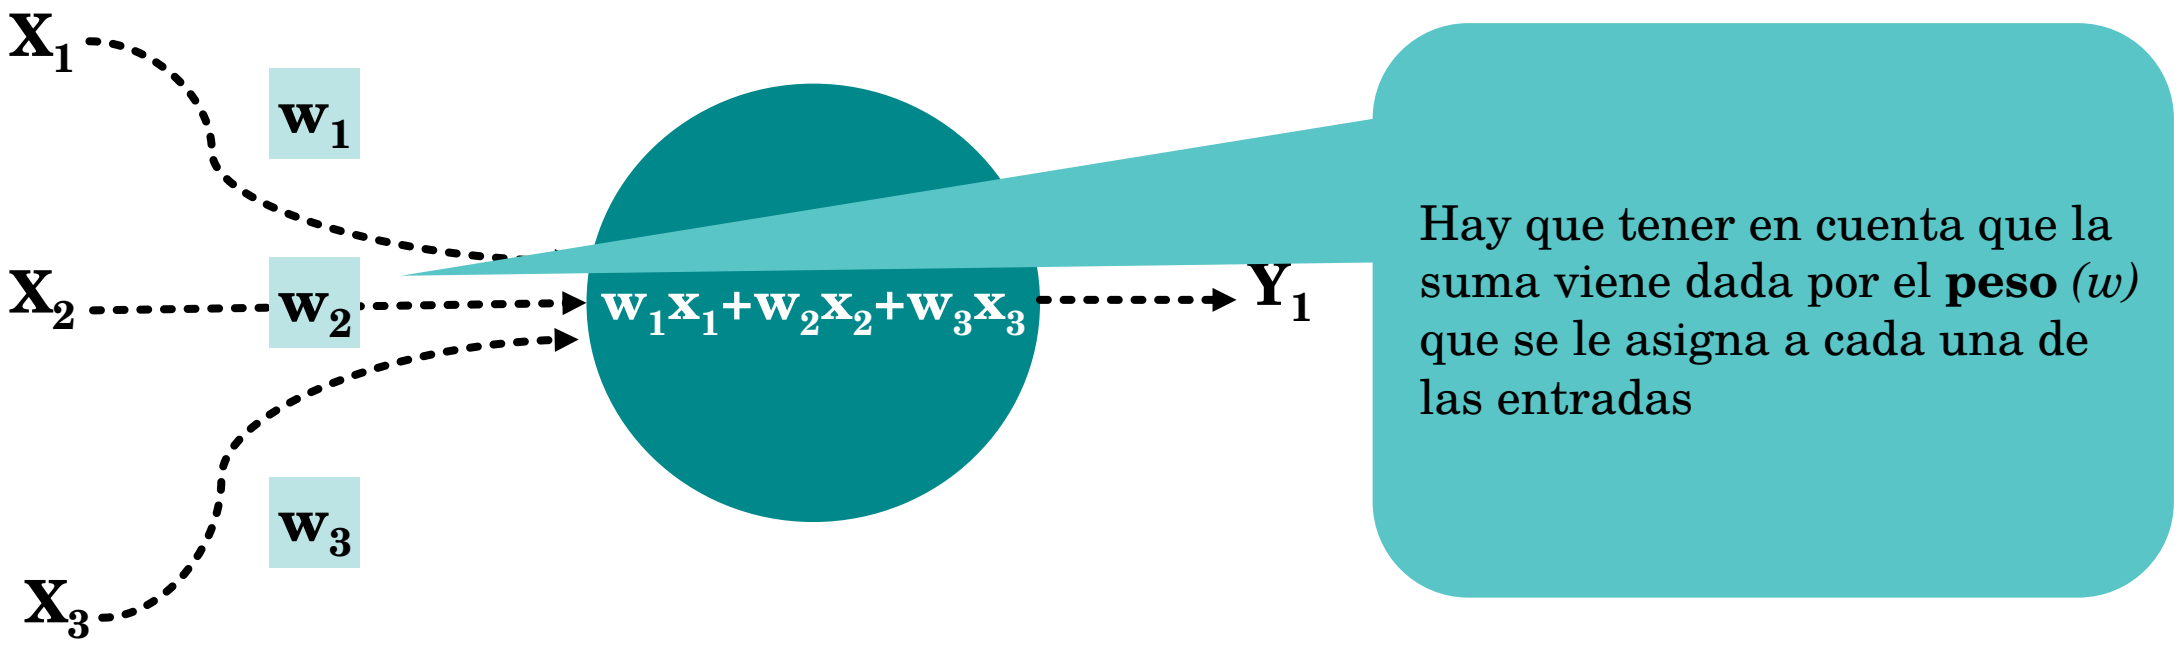
X_1
w_1
X_2
w_2
$w_1x_1+w_2x_2+w_3x_3$
Y_1
w_3
X_3
Hay que tener en cuenta que la suma viene dada por el **peso** *(w)* que se le asigna a cada una de las entradas

1. Neurona

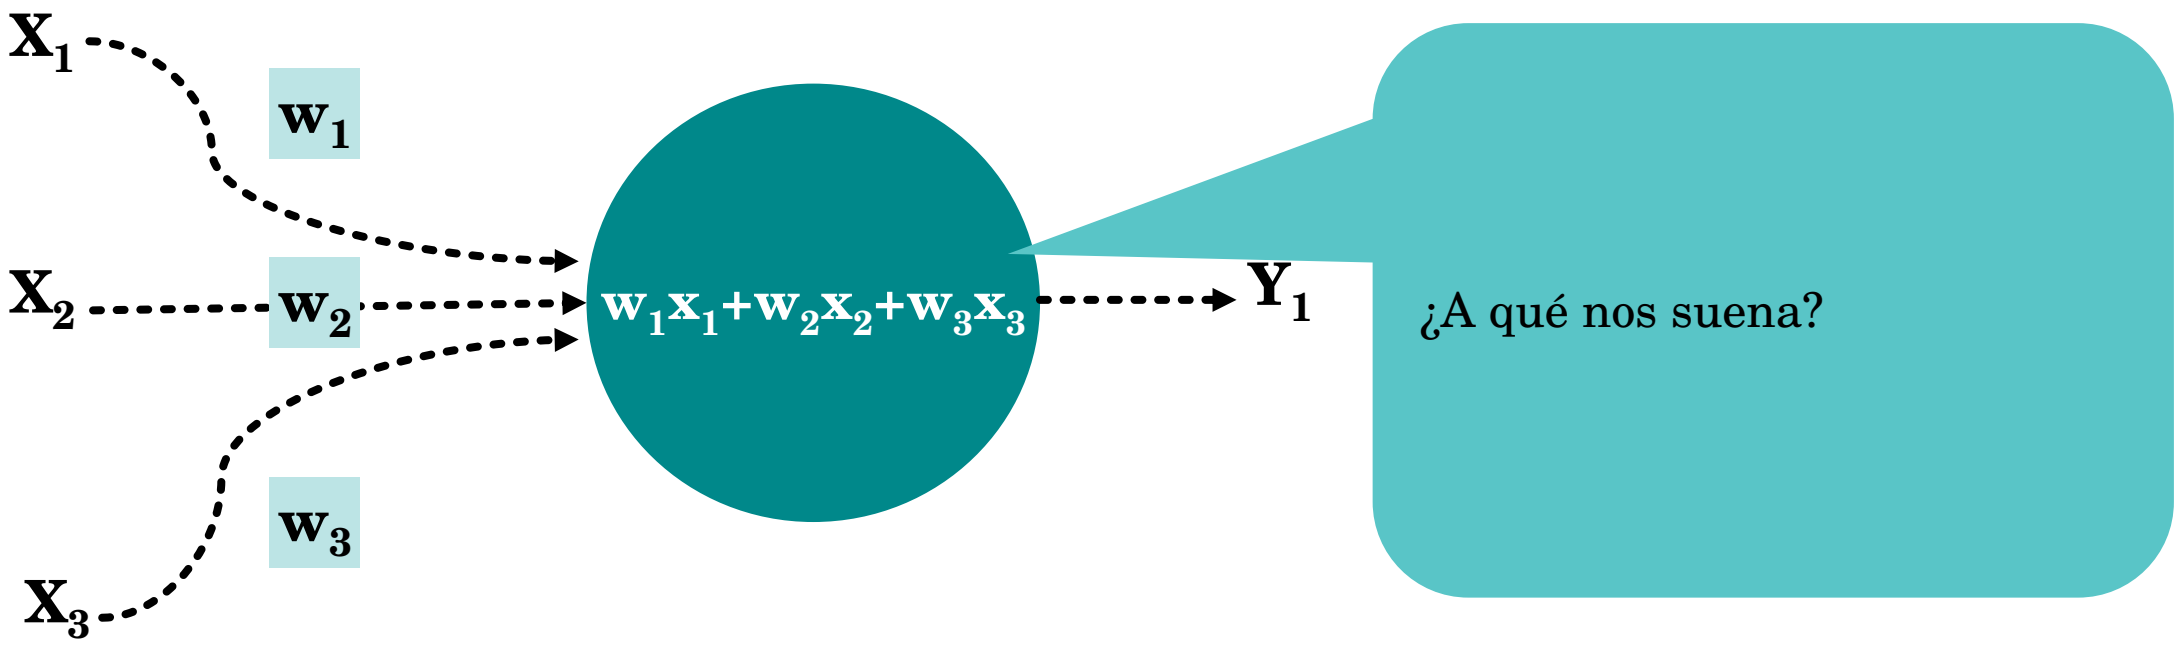

2. Regresión lineal

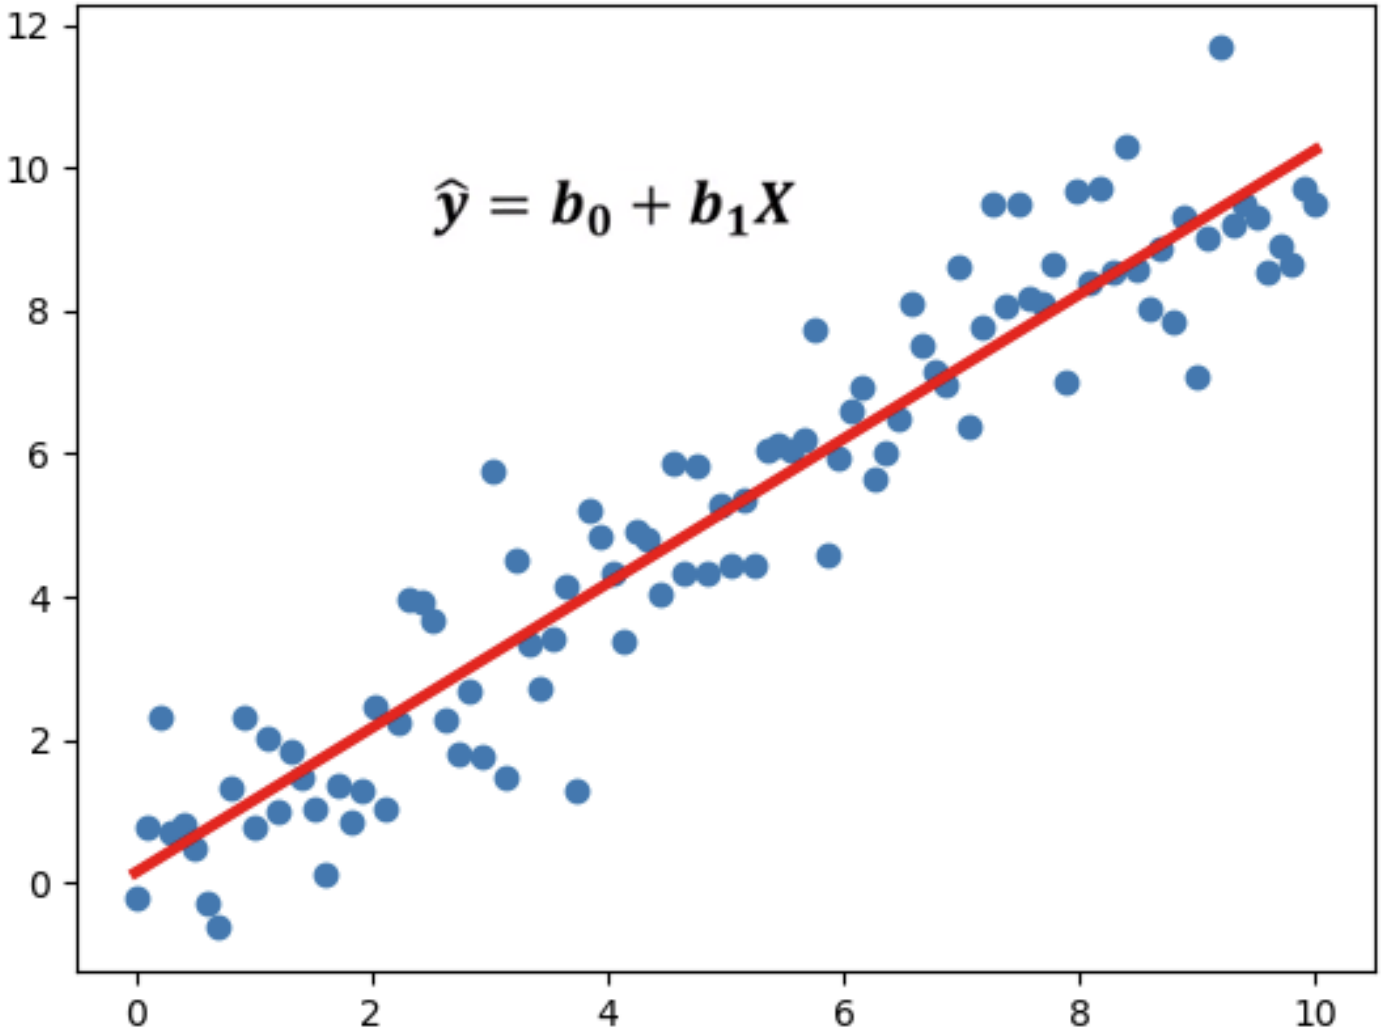

2. Regresión lineal

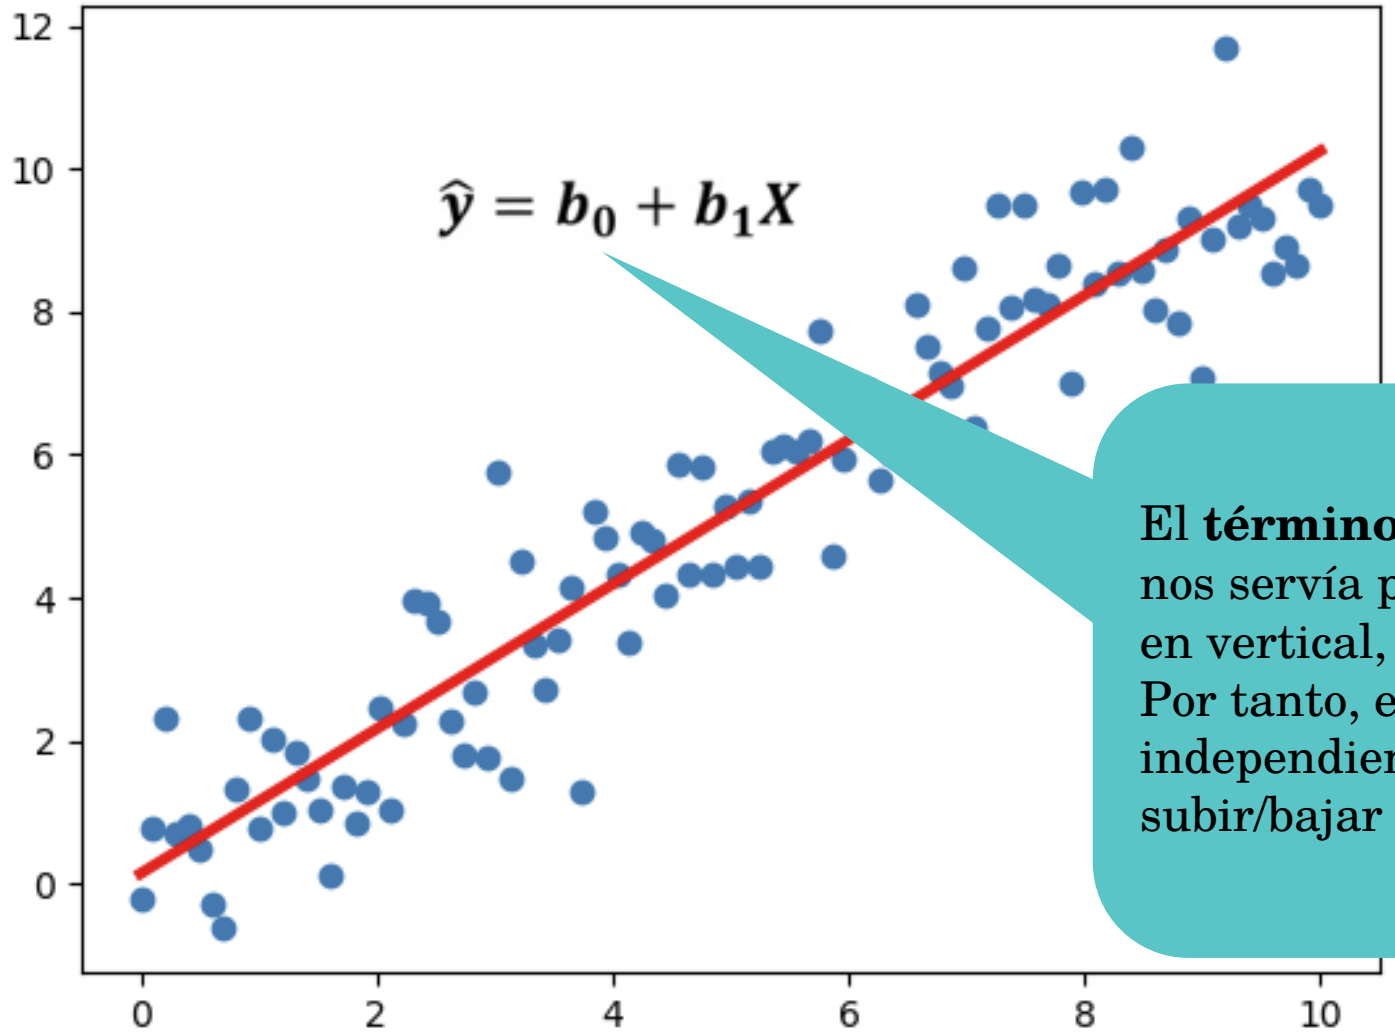

El **término independiente** nos servía para mover la recta en vertical, i.e., en el eje y. Por tanto, el término independiente nos servía para subir/bajar la recta

3. Función de la NN

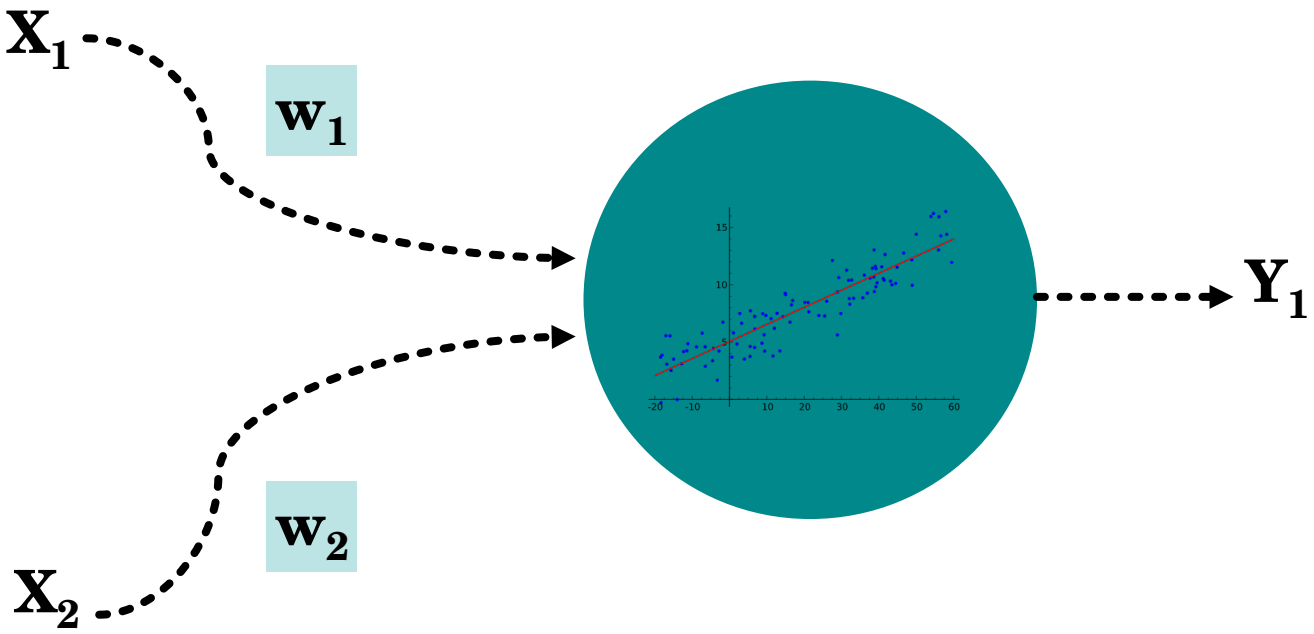

$$y = w_1x_1 + w_2x_2$$

3. Función de la NN

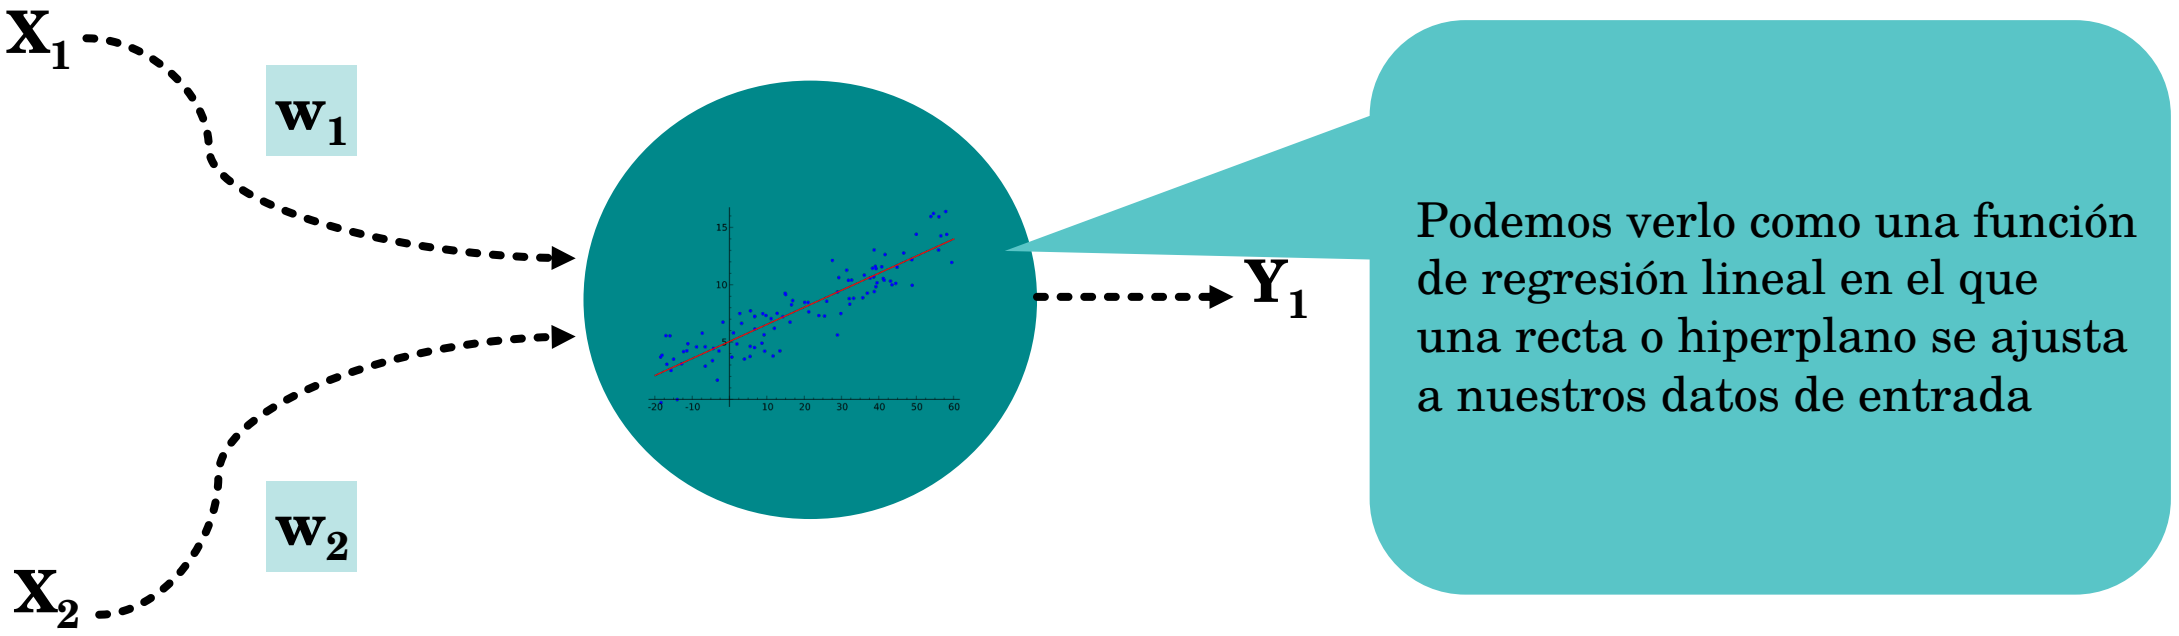

$$y = w_1x_1 + w_2x_2$$

3. Función de la NN

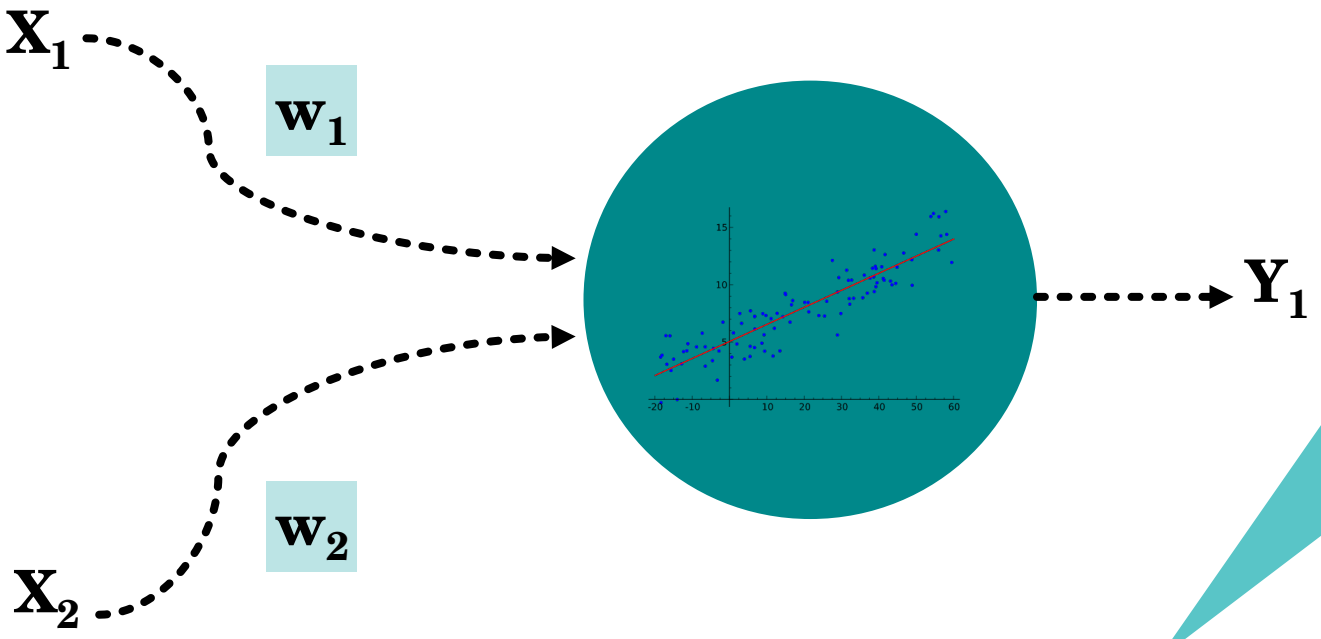

El término independiente, llamado **bias** o **sesgo**, nos permite el desplazamiento de la recta.

$$y = w_1x_1 + w_2x_2 + b$$

3. Función de la NN

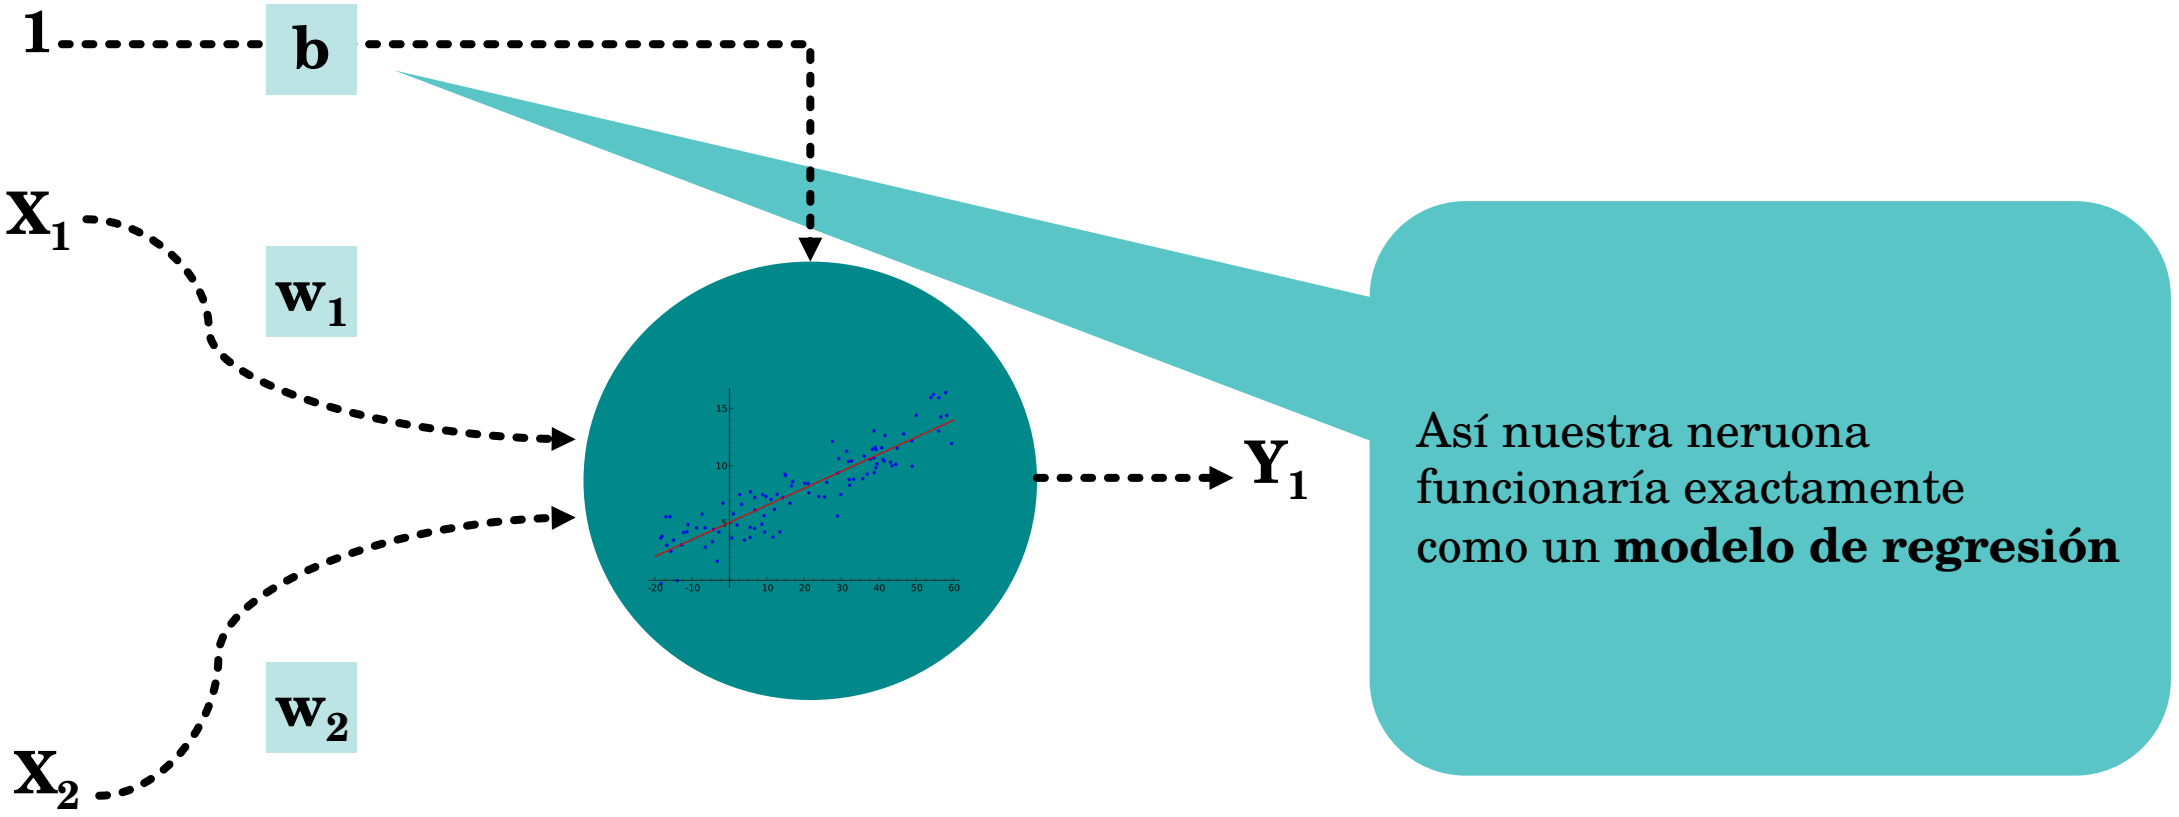

$$y = w_1x_1 + w_2x_2 + b$$

Simulación

ETS de Ingeniería Informática

UNED

1. Ejemplo

Estudiar + Estar en casa = Aprobar el examen

1. Ejemplo

Estudiar + Estar en casa = Aprobar el examen

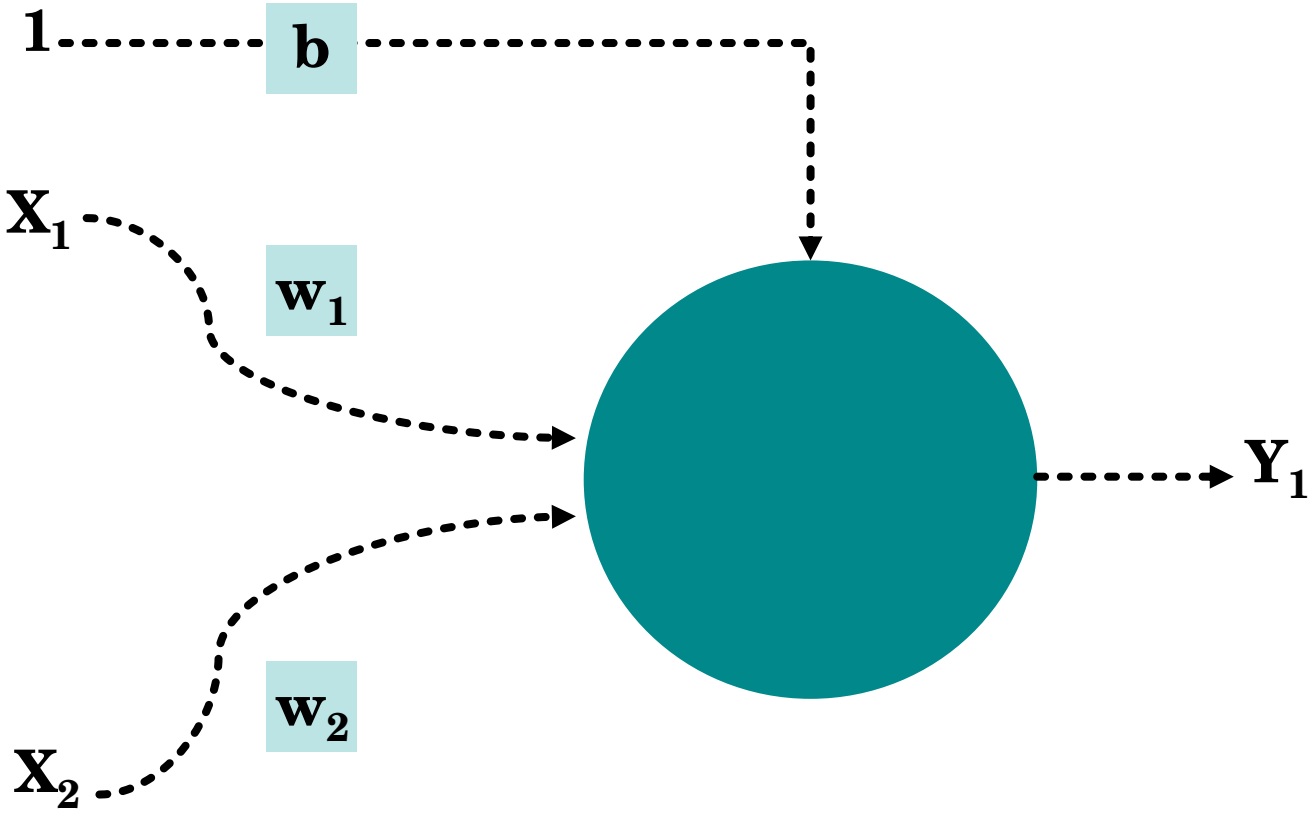

$$y = w_1x_1 + w_2x_2 + b$$

1. Ejemplo

Estudiar + Estar en casa = Aprobar el examen

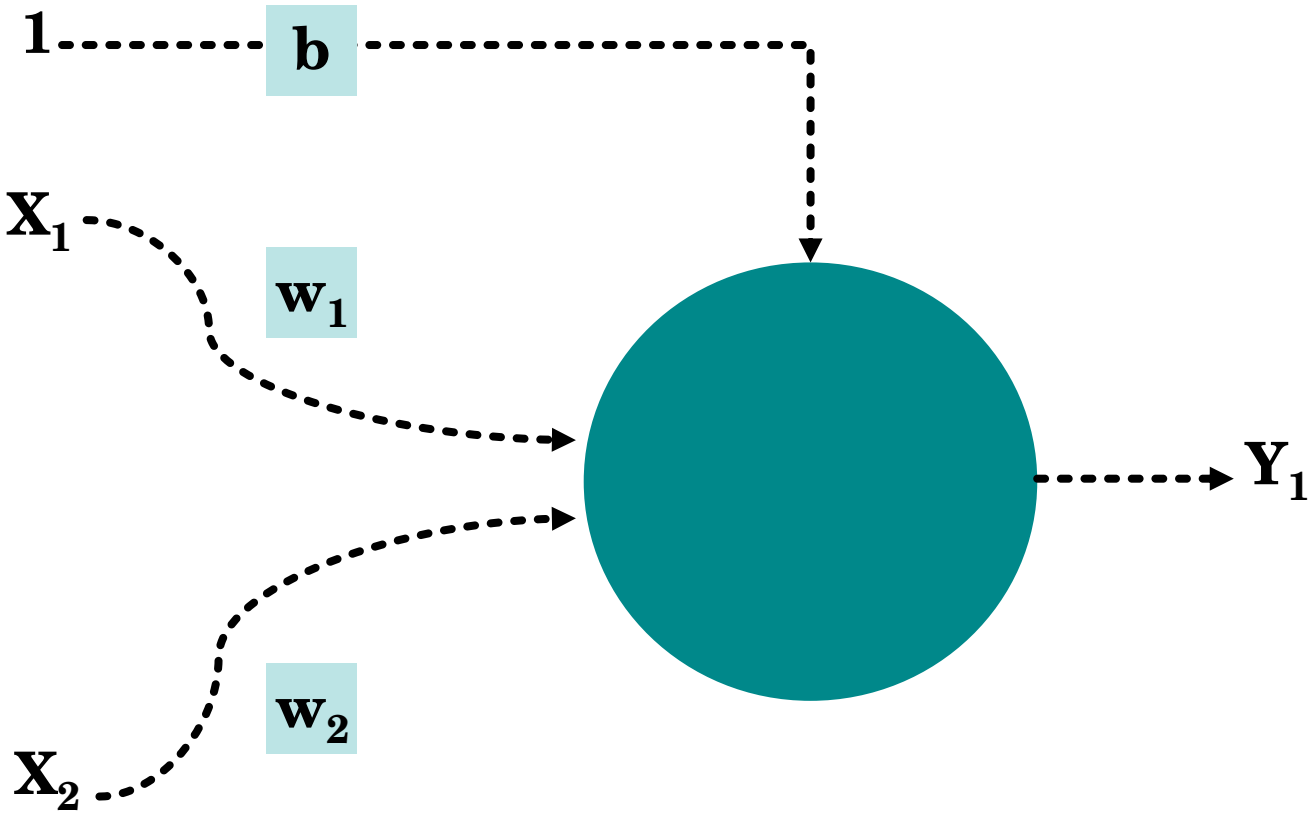

	1	0
X_1		
X_2		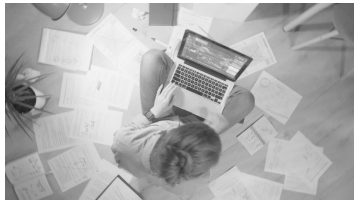

$$y = w_1x_1 + w_2x_2 + b$$

1. Ejemplo

Estudiar + Estar en casa = Aprobar el examen

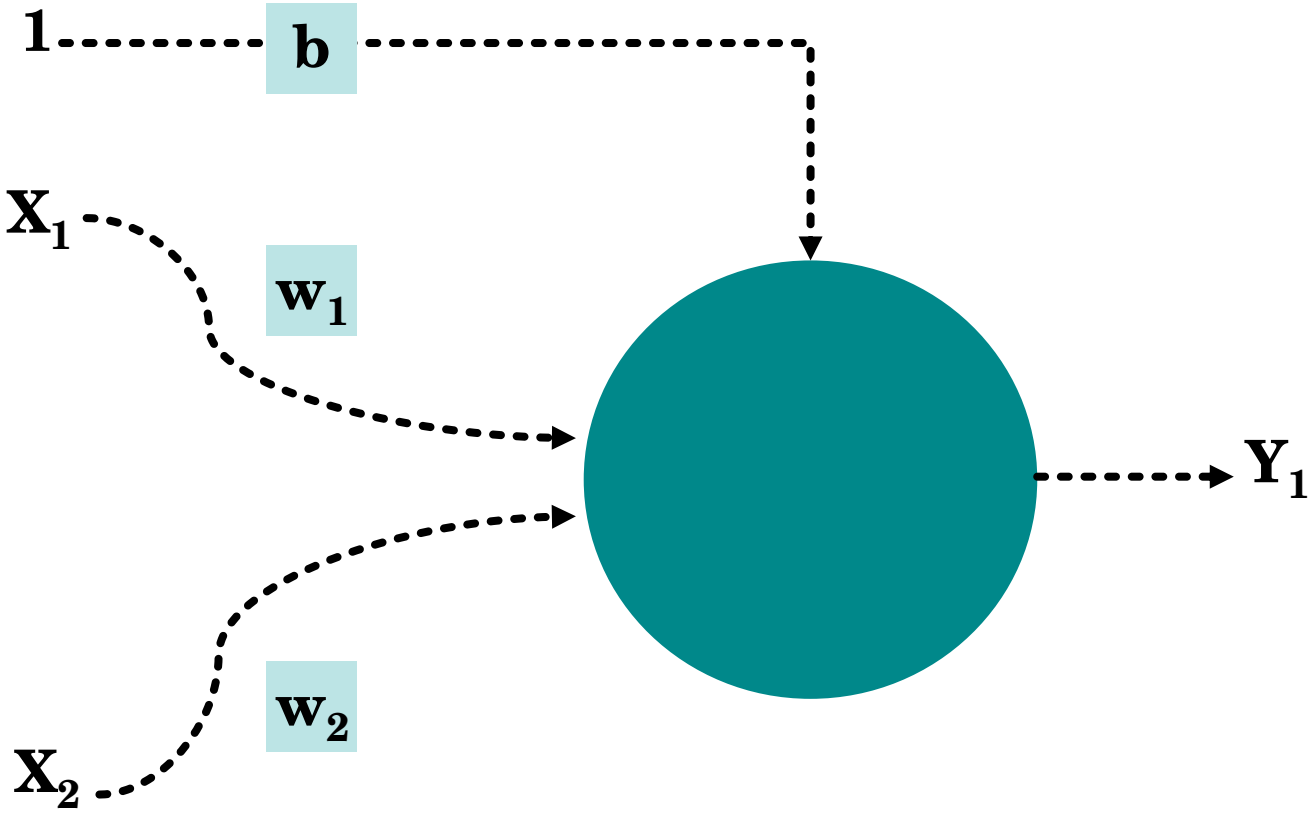

$$y = w_1x_1 + w_2x_2 + b$$

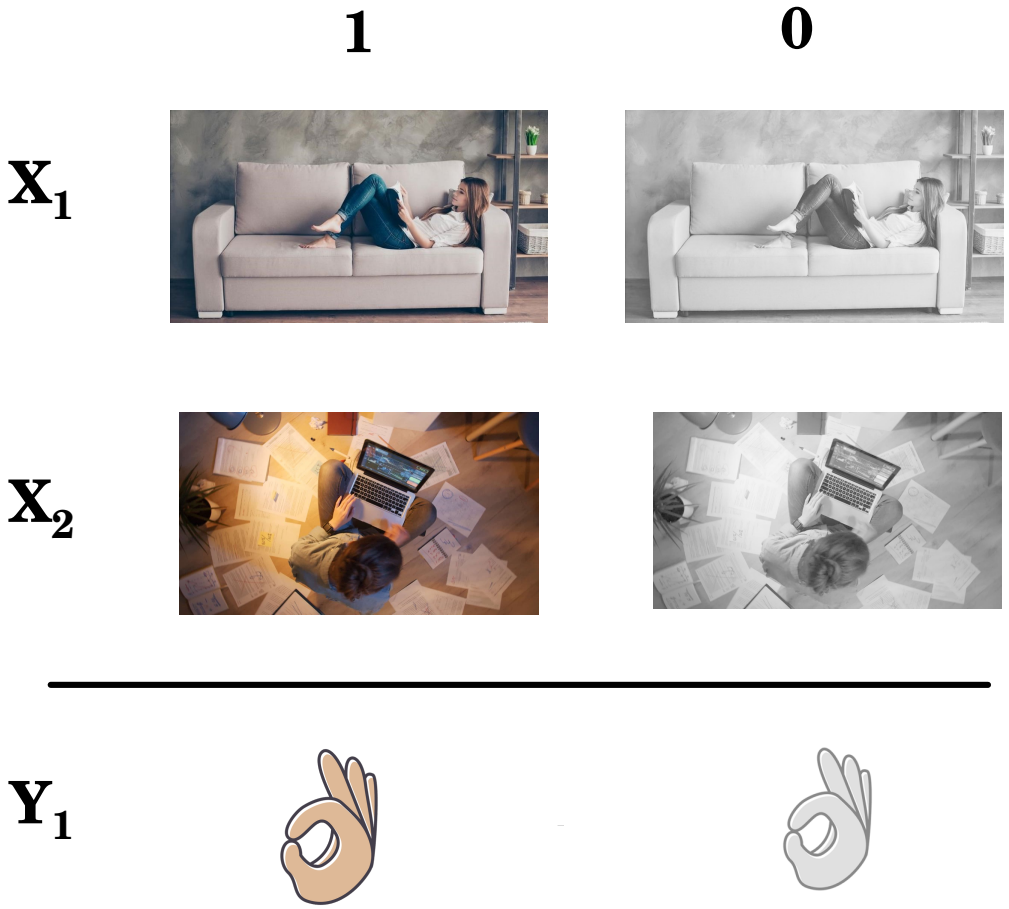

1. Ejemplo

Modelamos el problema

Estudiar + Estar en casa = Aprobar el examen

X_1	X_2	Target	Y
			
			
			
			

1. Ejemplo

Modelamos el problema

Estudiar + Estar en casa = Aprobar el examen

X_1	X_2	Target Y
		
		
		
		

1. Ejemplo

Modelamos el problema

Estudiar + Estar en casa = Aprobar el examen

X_1	X_2	Target	Y
			?
			?
			?
			?

El resultado de la NN estará condicionado por el valor de los **parámetros**. Por tanto, tenemos que buscar esos pesos y bias.

1. Ejemplo

Buscamos los parámetros

Estudiar + Estar en casa = Aprobar el examen

X_1	X_2	Target	Y
			?
			?
			?
			?

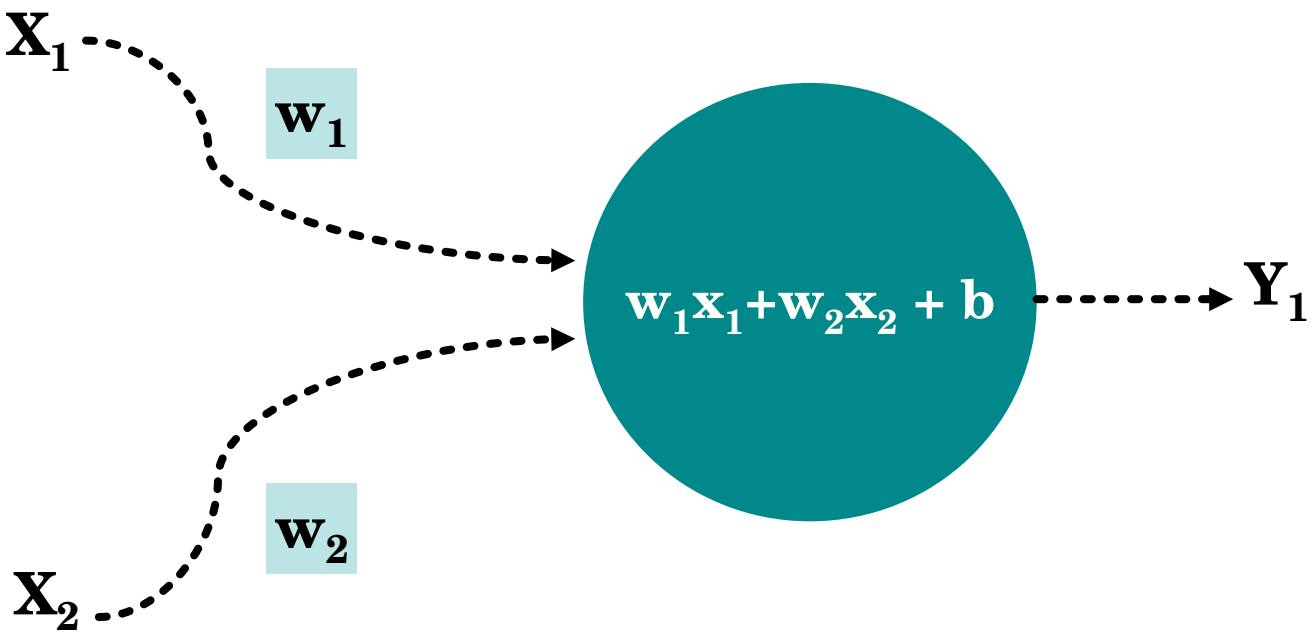

1. Ejemplo

Buscamos los parámetros

Estudiar + Estar en casa = Aprobar el examen

X_1	X_2	Target	Y
			-3
			0
			-7
			-4

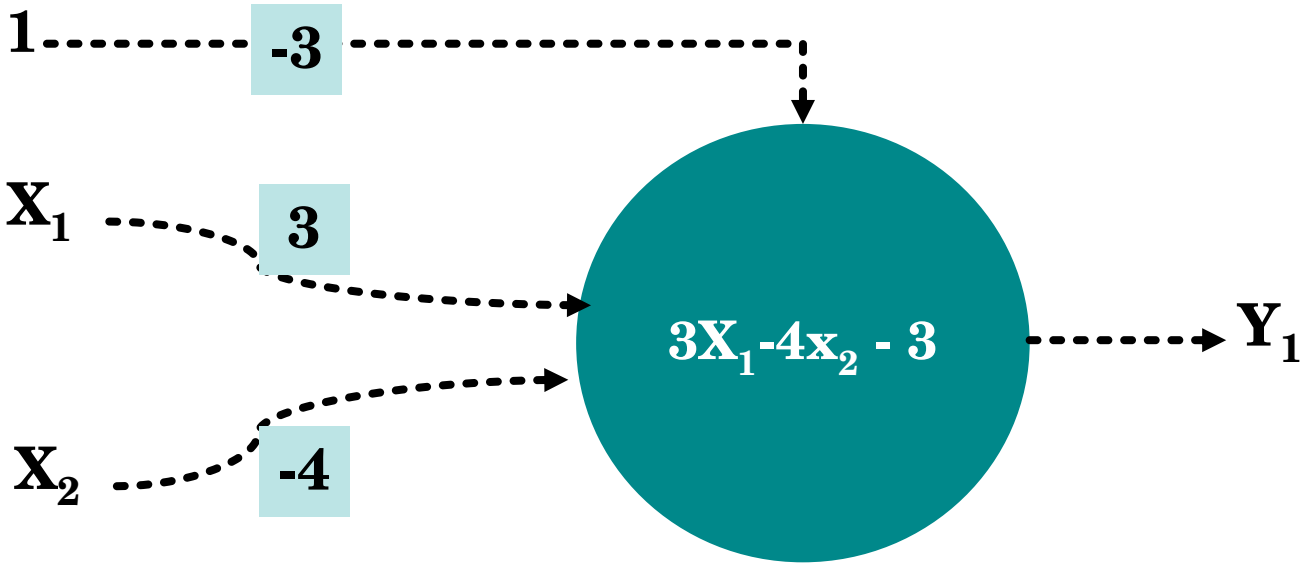

1. Ejemplo

Buscamos los parámetros

Estudiar + Estar en casa = Aprobar el examen

X_1	X_2	Target	Y
			-3
			0
			-7
			-4

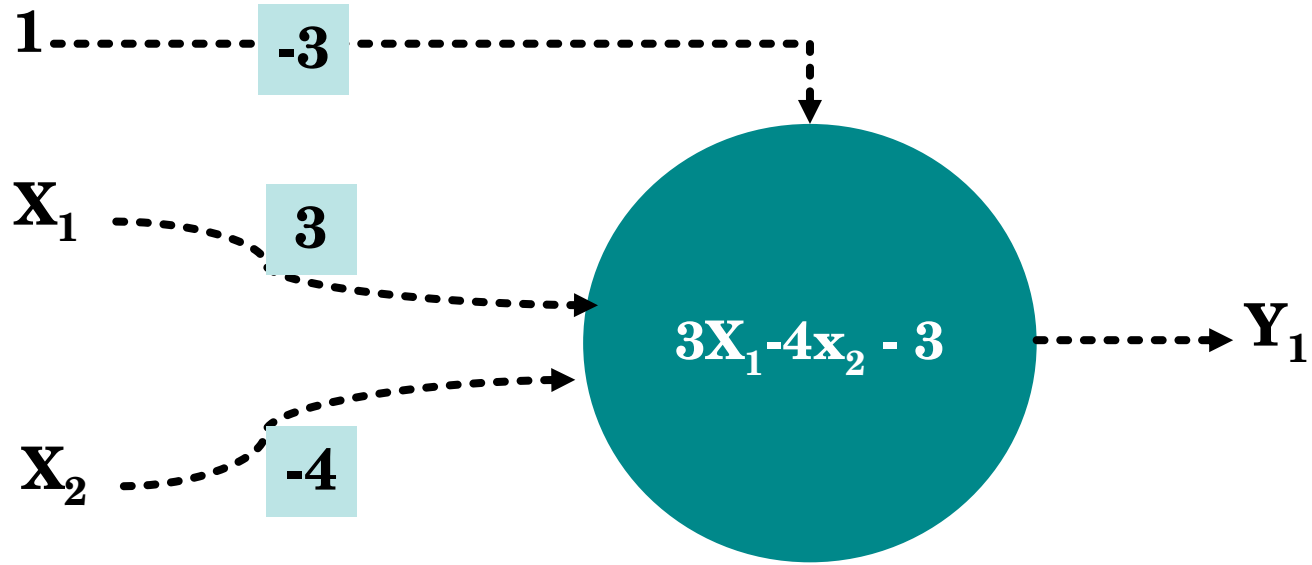

El objetivo es que salga un resultado positivo el último Y negativo los tres primeros

1. Ejemplo

Buscamos los parámetros

Estudiar + Estar en casa = Aprobar el examen

X_1	X_2	Target	Y
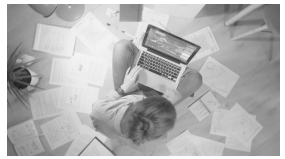			-3
			0
			-7
			-4

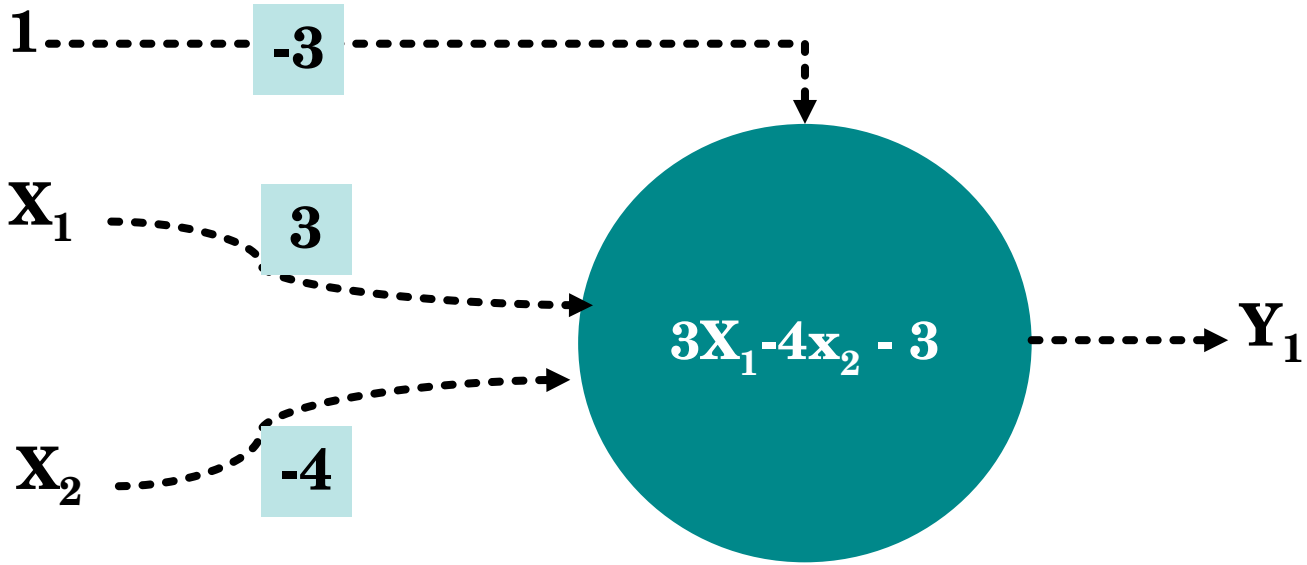

¡No cumple!

1. Ejemplo

Buscamos los parámetros

Estudiar + Estar en casa = Aprobar el examen

X_1	X_2	Target	Y
			2
			3
			3
			4

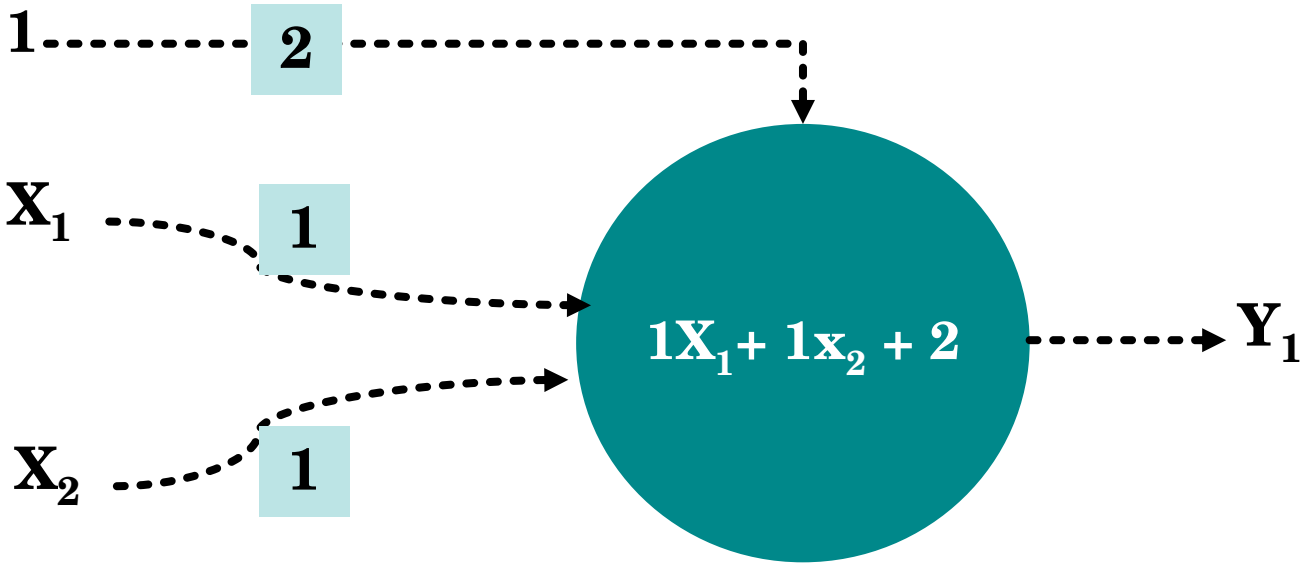

1. Ejemplo

Buscamos los parámetros

Estudiar + Estar en casa = Aprobar el examen

X_1	X_2	Target	Y
			2
			3
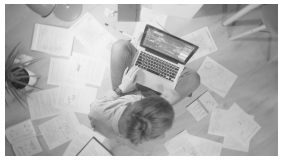			3
			4

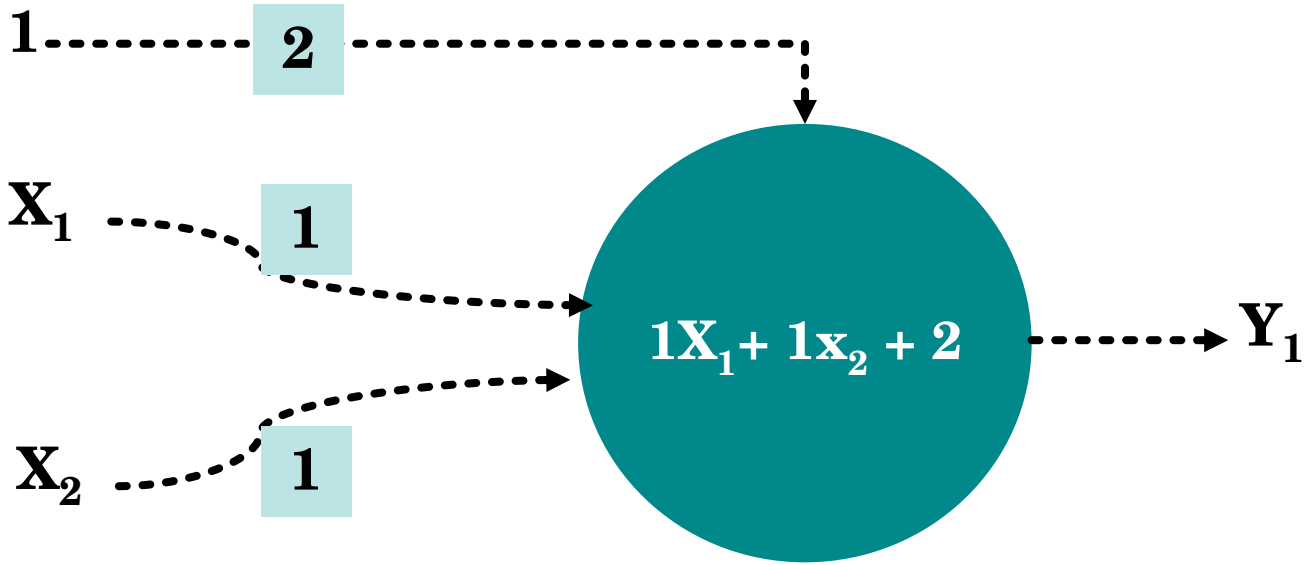

¡No cumple!

1. Ejemplo

Buscamos los parámetros

Estudiar + Estar en casa = Aprobar el examen

X_1	X_2	Target	Y
			-6
			-2
			-1
			3

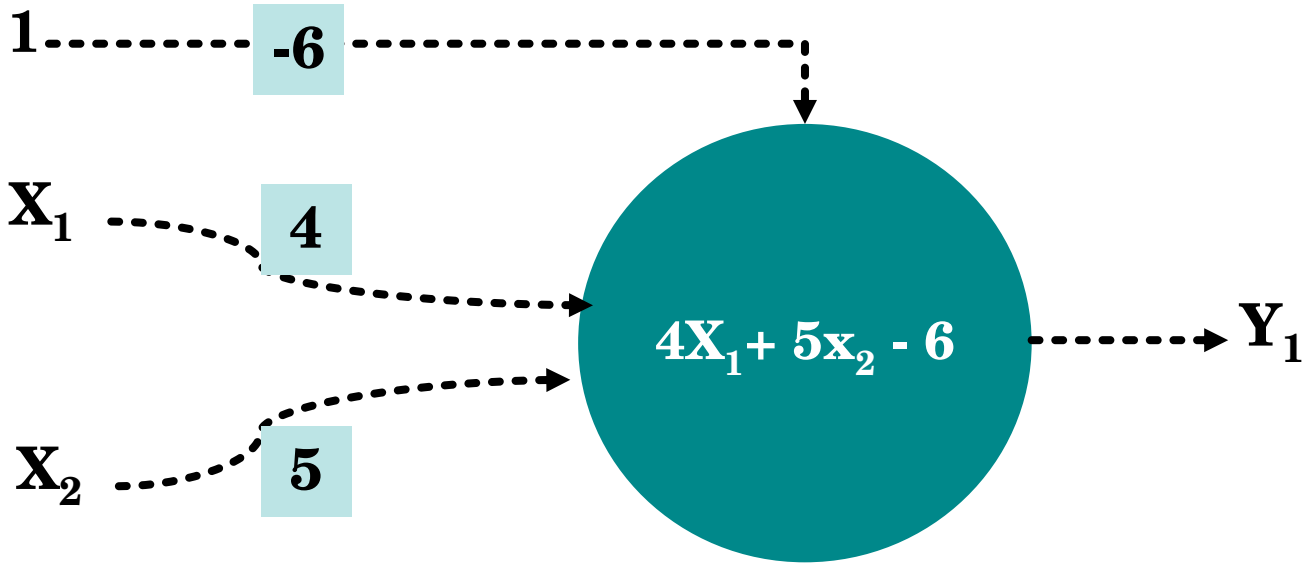

1. Ejemplo

Buscamos los parámetros

Estudiar + Estar en casa = Aprobar el examen

X_1	X_2	Target	Y
			-6
			-2
			-1
			3

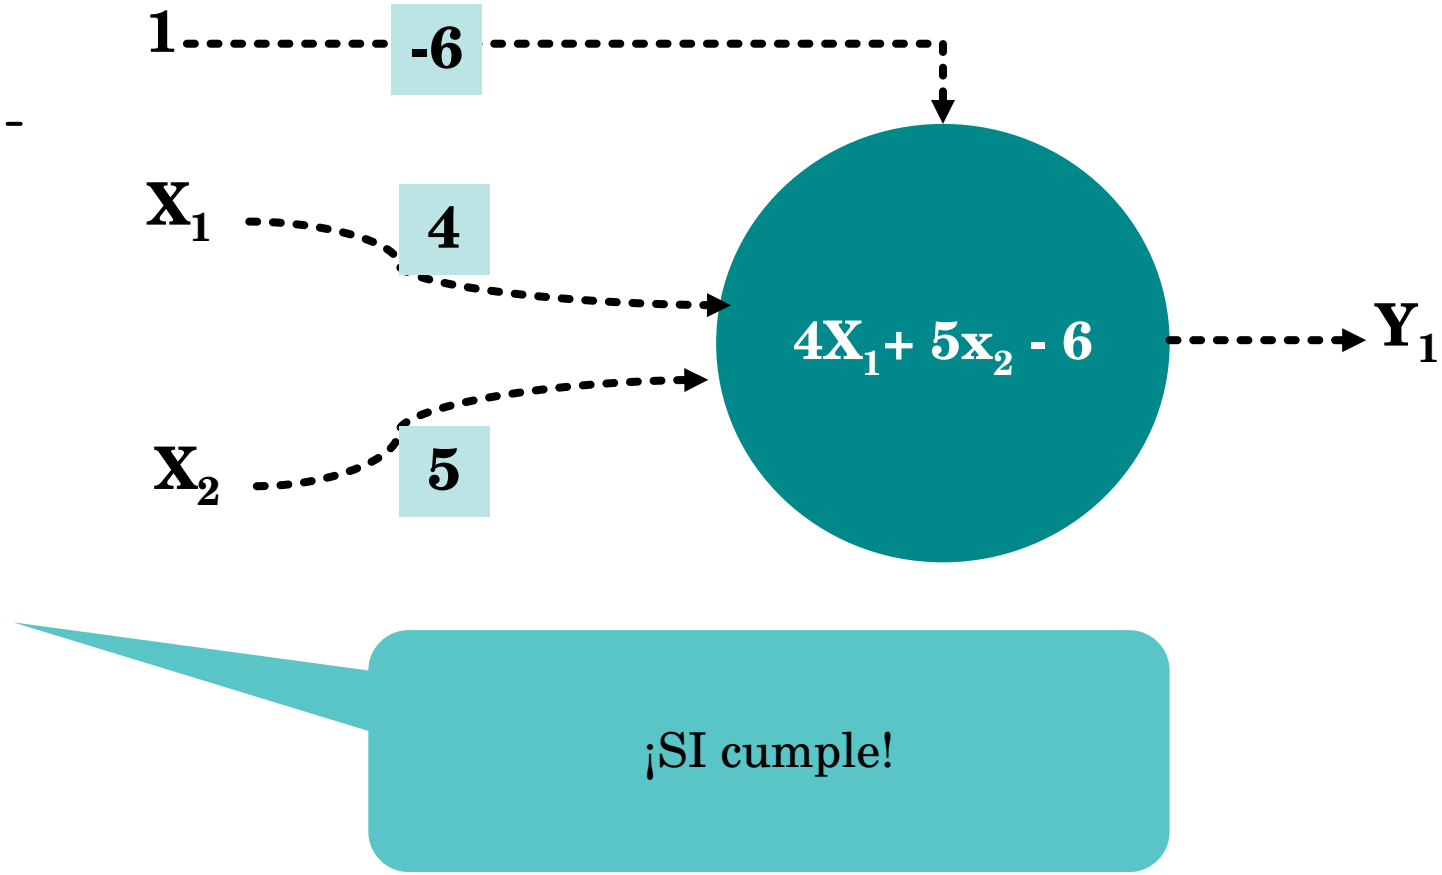

1. Ejemplo
Entender el procedimiento

x_1

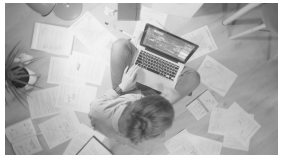

x_2

1. Ejemplo
Entender el procedimiento

x_1

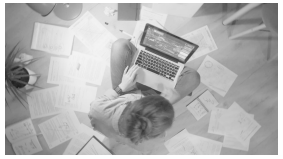

x_2

1. Ejemplo
Entender el procedimiento

x_1

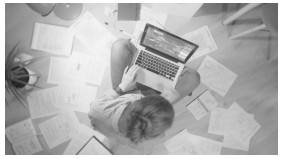

x_2

1. Ejemplo

Entender el procedimiento

1	0	1
x_1		
0	0	0
0	x_2	1

1. Ejemplo

Entender el procedimiento

1	0	1
x_1		
0	0	0
0	x_2	1

¿Qué observamos?

1. Ejemplo
Puerta lógica AND

1	0	1
0	0	0
0	1	0

x_1

x_2

¿Qué observamos?
Que tenemos una **puerta lógica AND**

1. Ejemplo
Puerta lógica AND

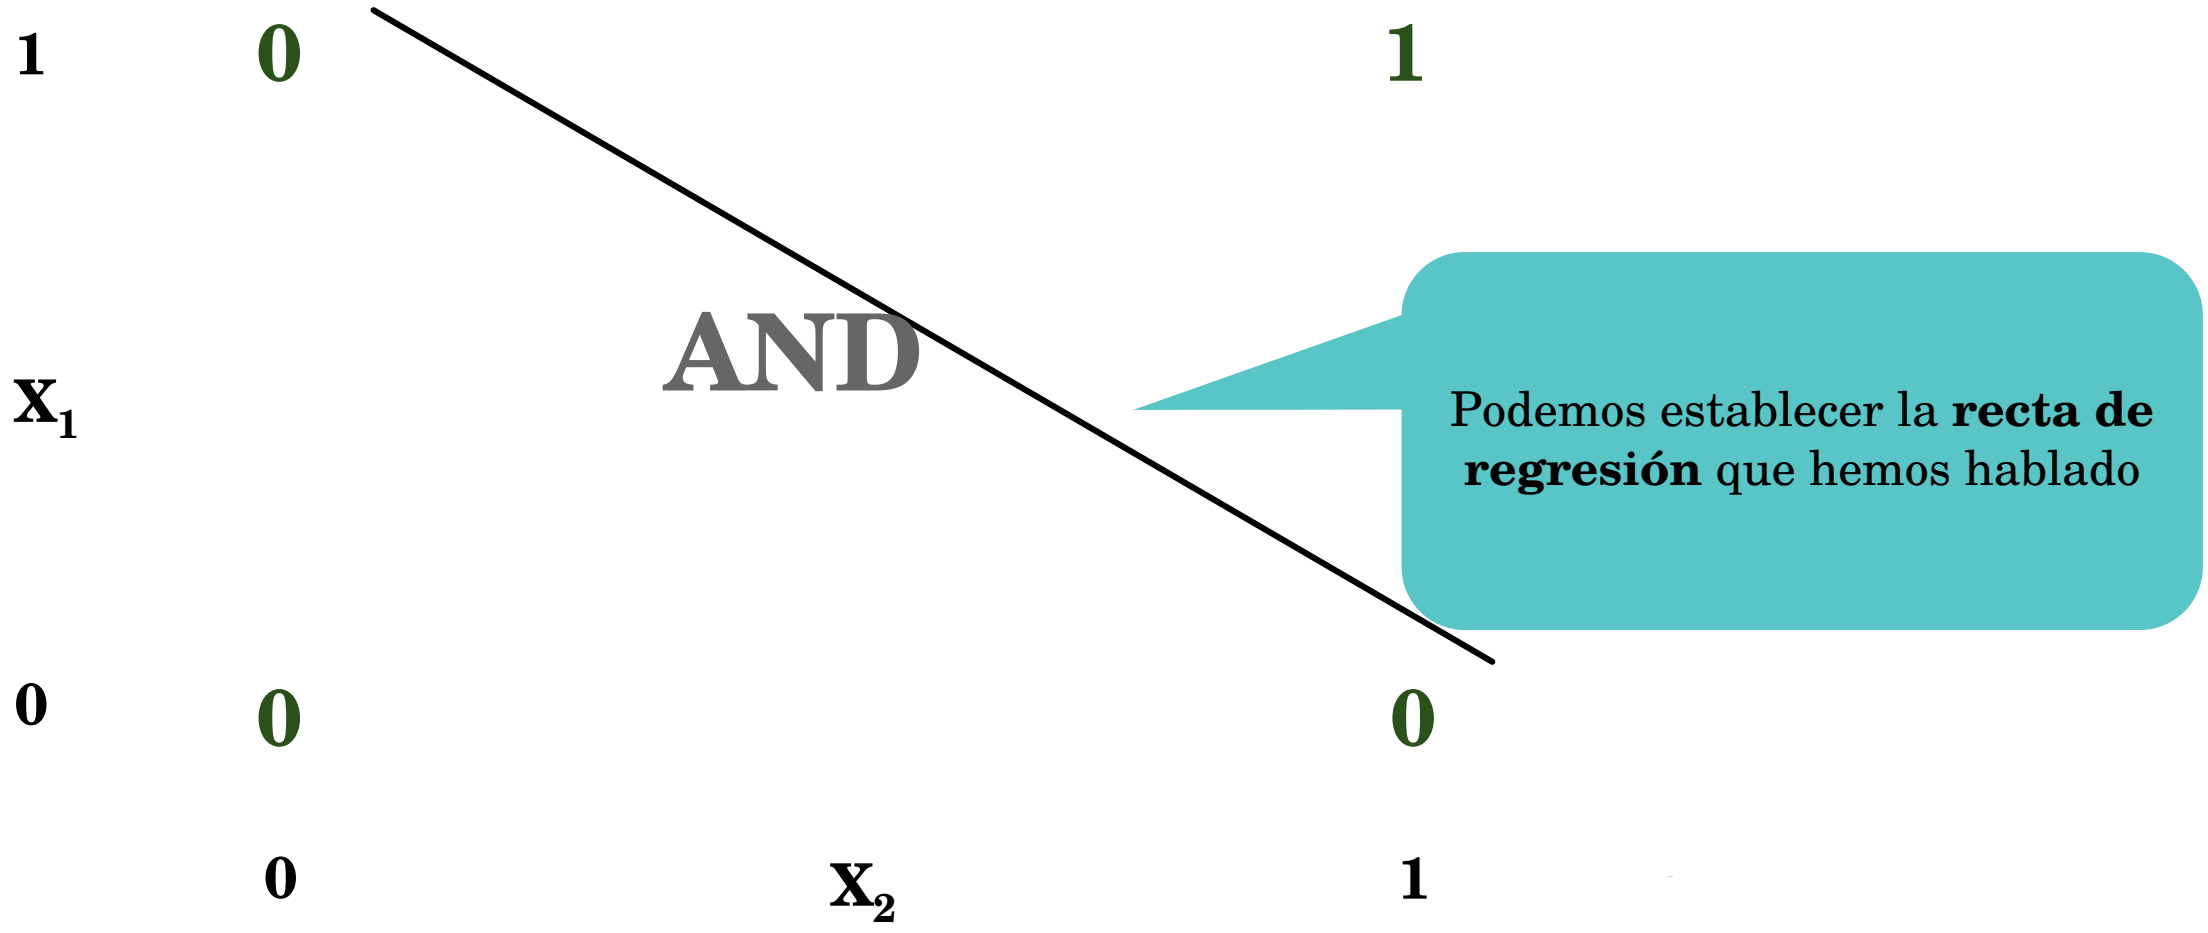

Podemos establecer la **recta de regresión** que hemos hablado

1. Ejemplo
Puerta lógica AND

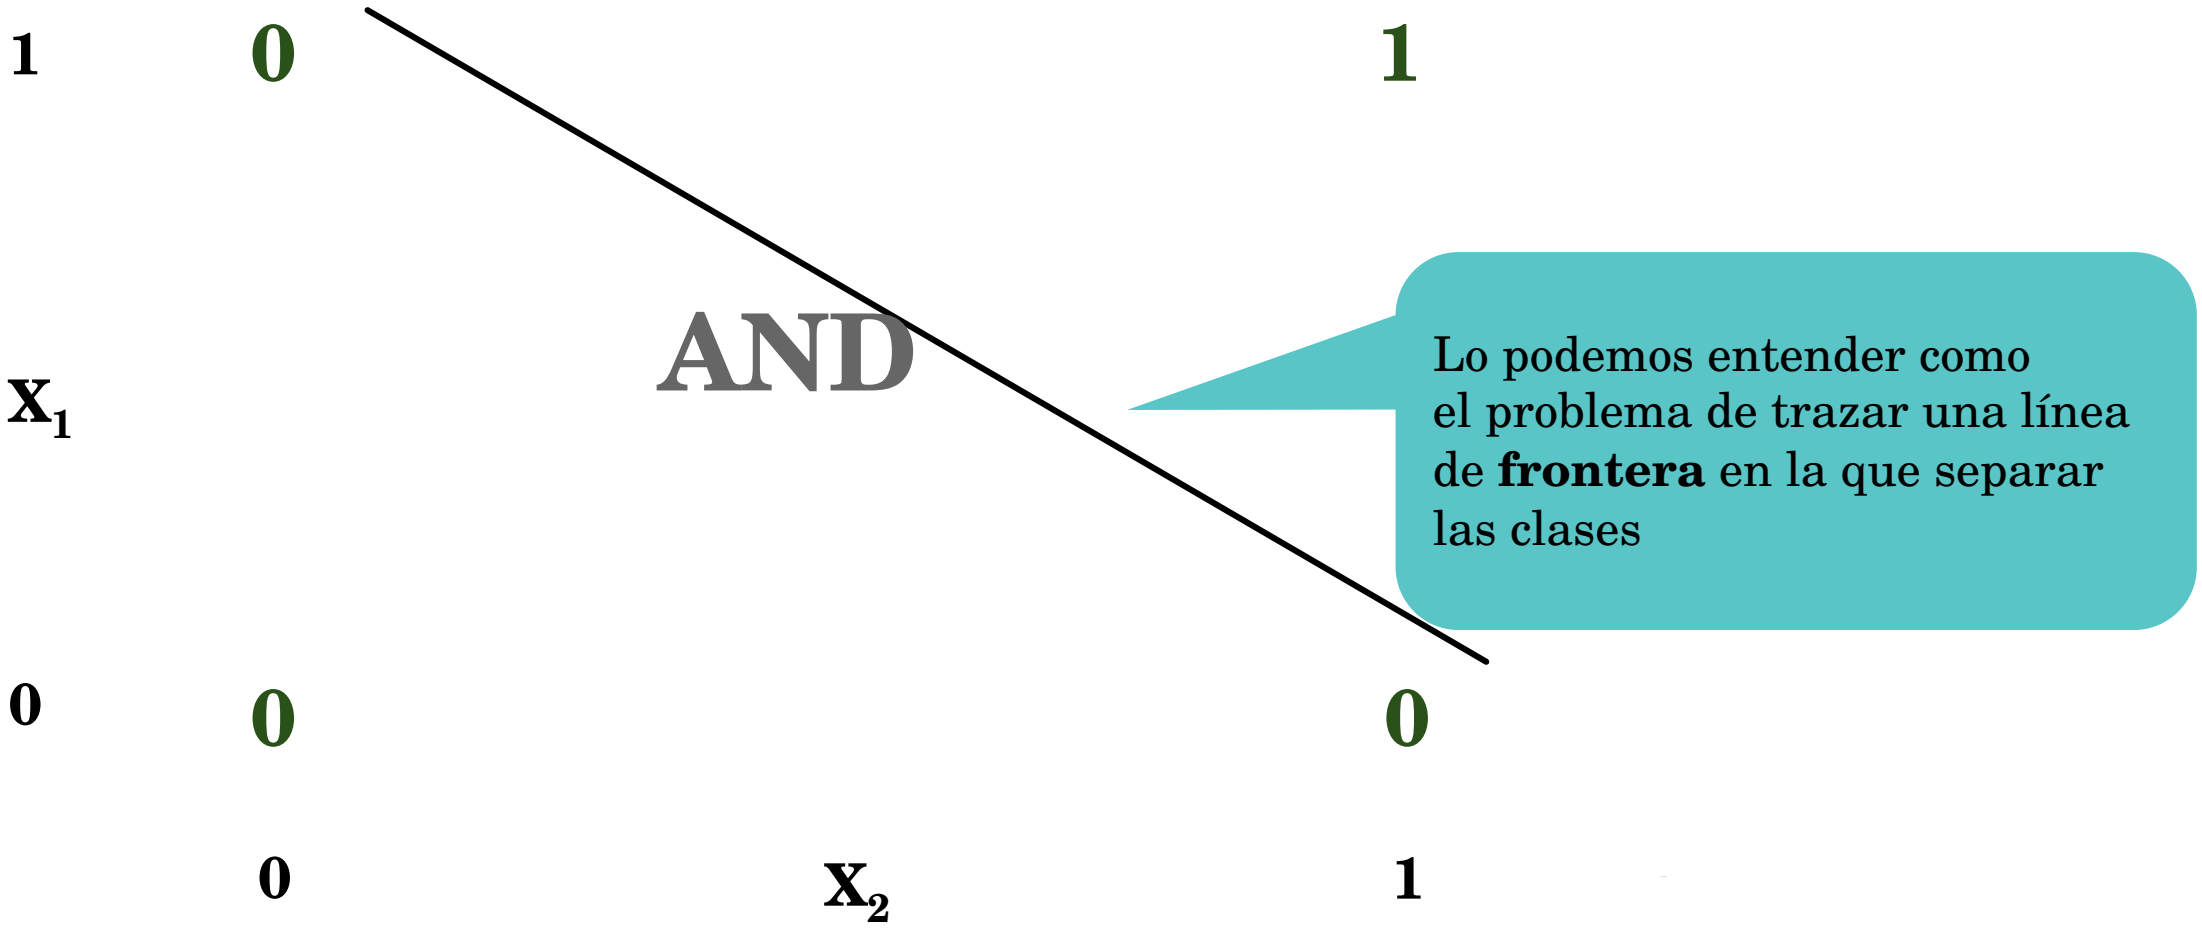

Lo podemos entender como el problema de trazar una línea de **frontera** en la que separar las clases

1. Ejemplo

Puerta lógica OR

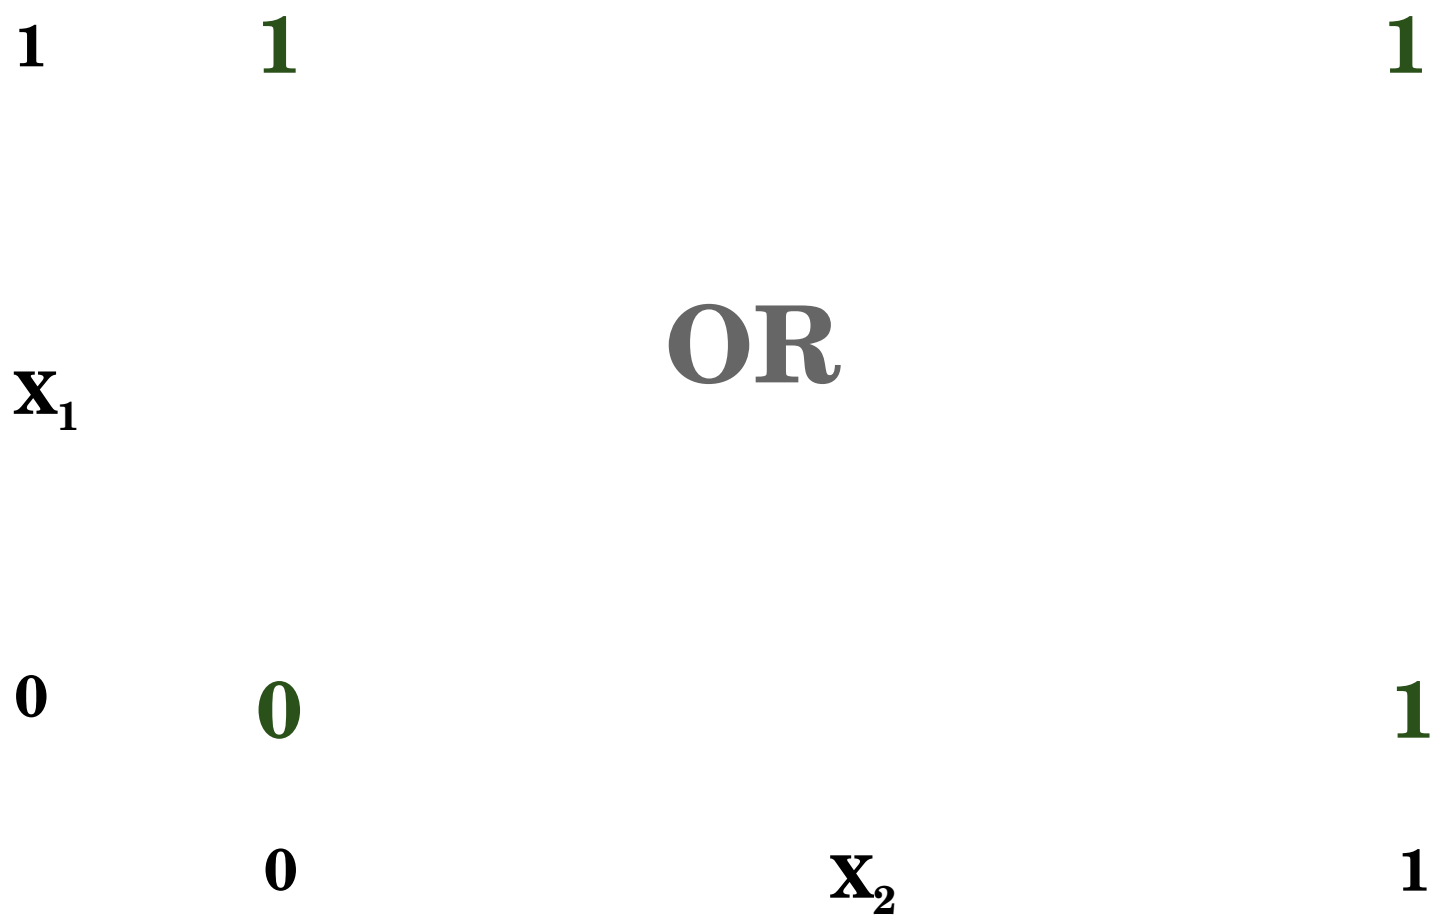

1. Ejemplo
Puerta lógica OR

x_1	x_2	OR
1	1	1
0	0	1
0	1	1

Tendríamos que ajustar los parámetros de la neurona hasta ajustar los resultados esperados

1. Ejemplo

Puerta lógica OR – Buscar parámetros

Estudiar + Estar en casa = Aprobar el examen

X_1	X_2	Target	Y
			-2
			1
			2
			5

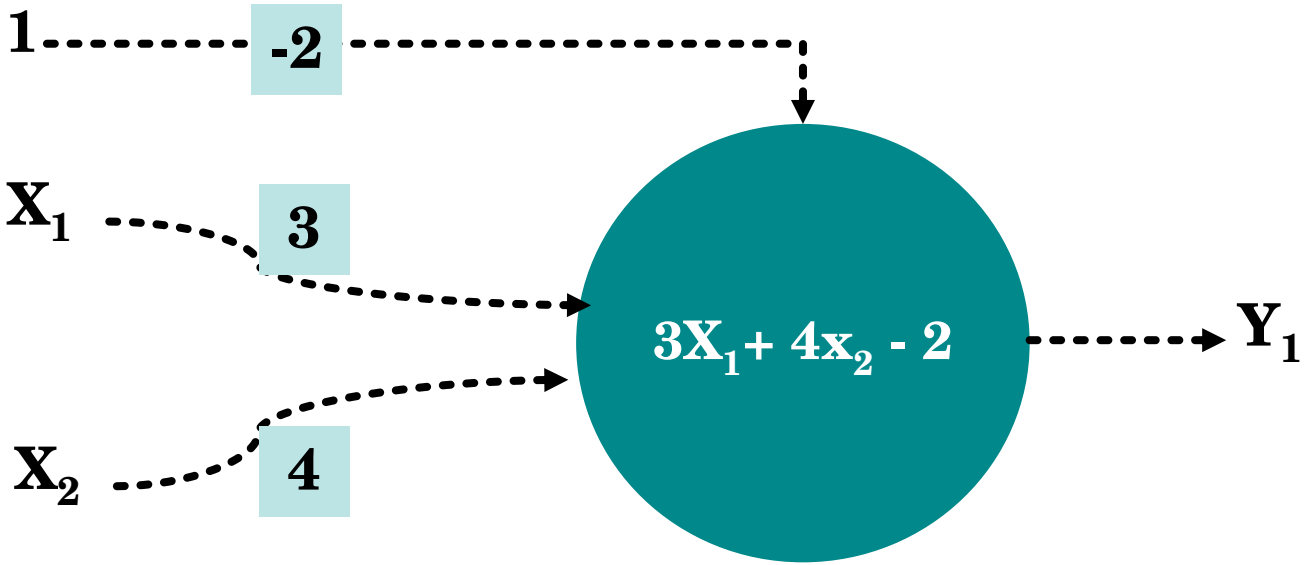

1. Ejemplo

Puerta lógica OR – Buscar parámetros

Estudiar + Estar en casa = Aprobar el examen

X_1	X_2	Target	Y
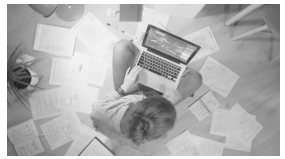			-2
			1
			2
			5

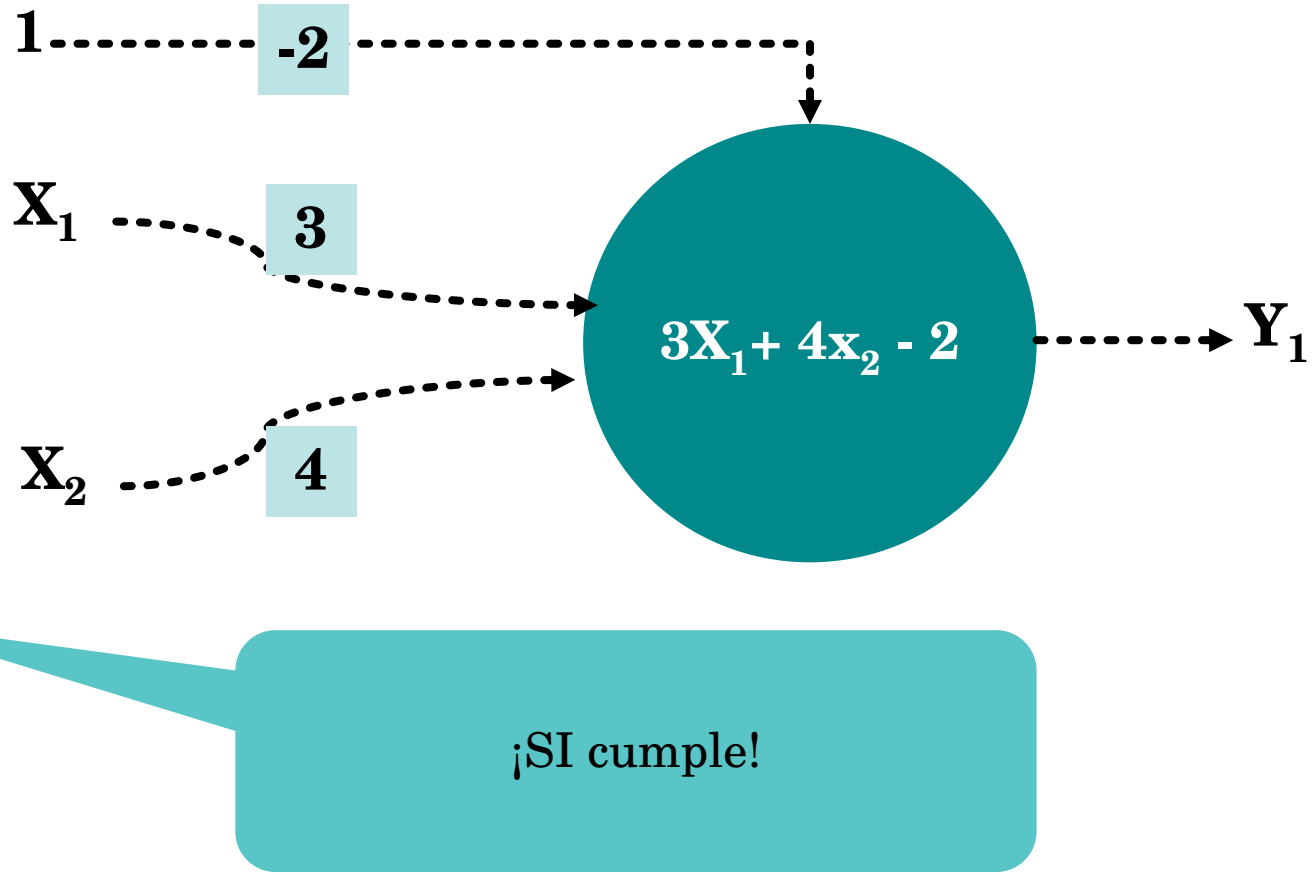

1. Ejemplo
Puerta lógica OR

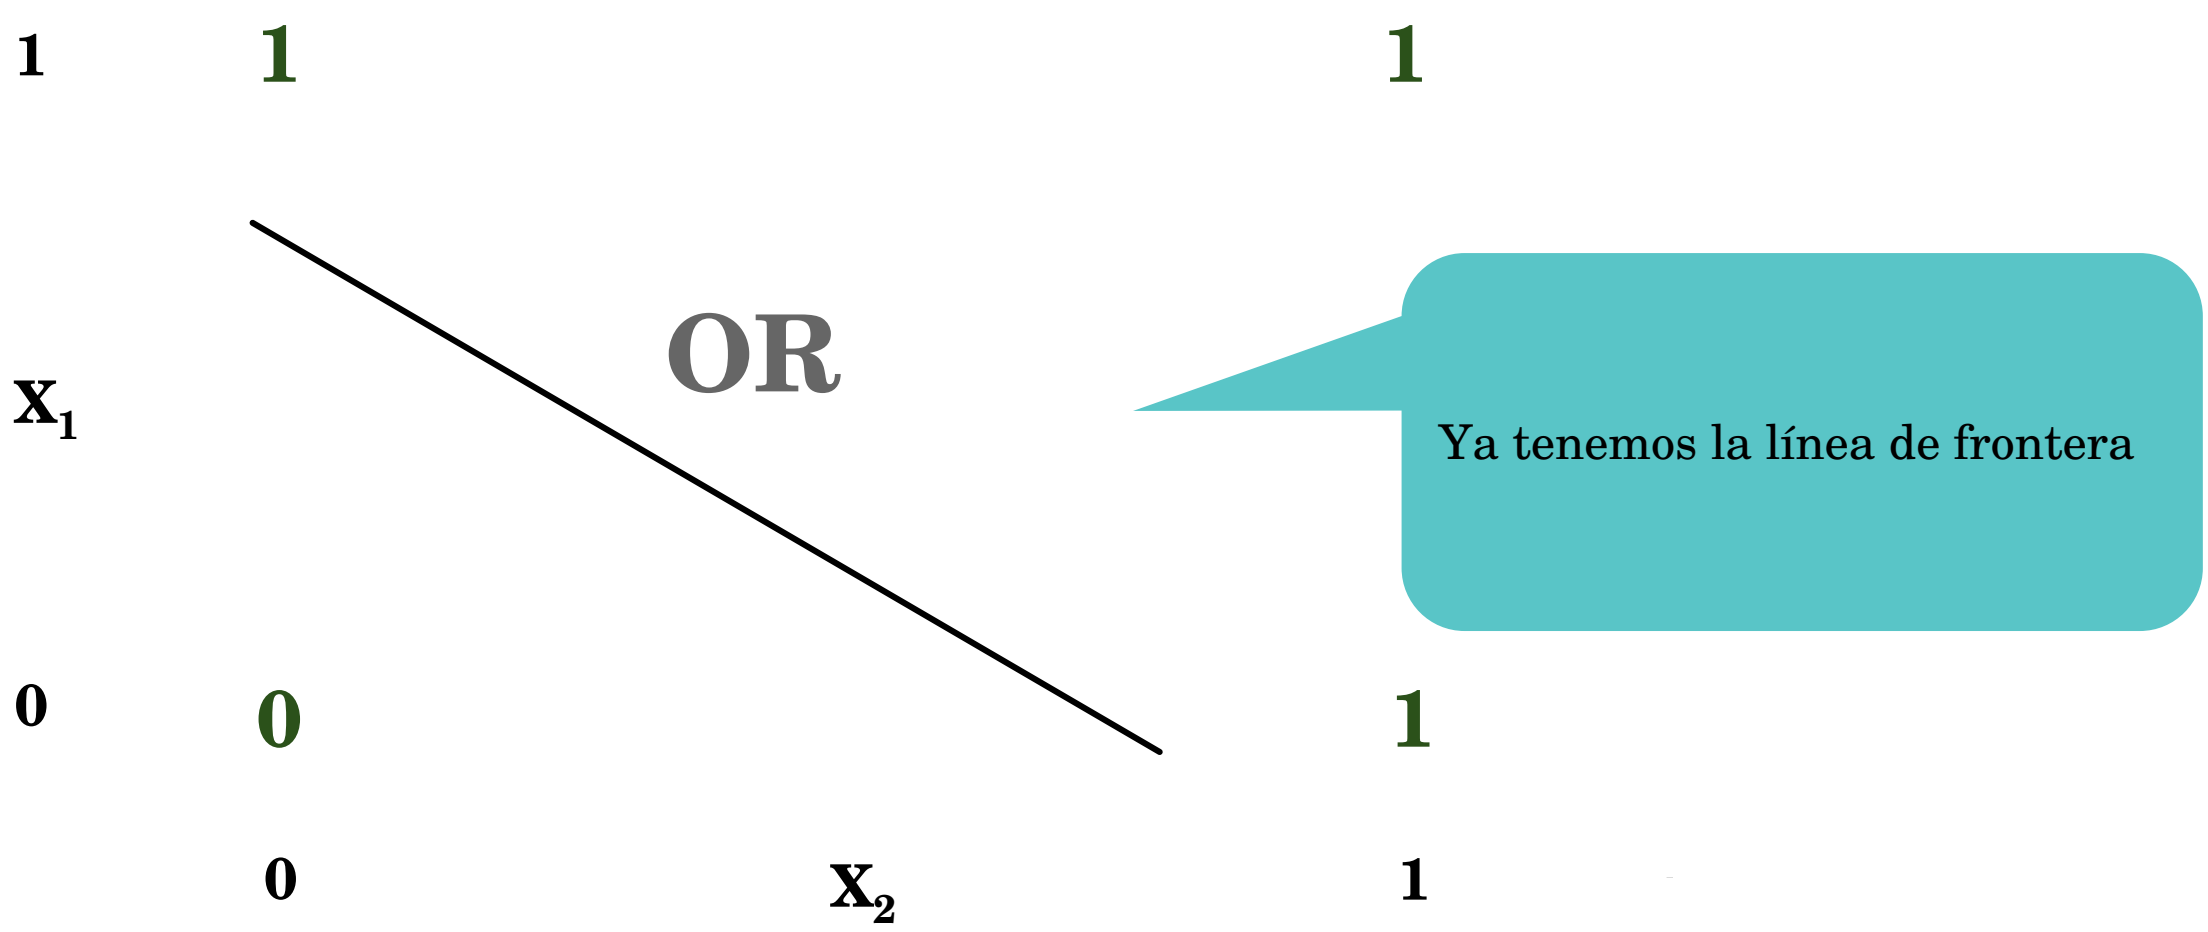

Ya tenemos la línea de frontera

1. Ejemplo
Puerta lógica XOR

1 1 0

XOR

x_1

0 0 1

0 x_2 1

¿Como sería con XOR?
¿Recordáis la sesión anterior?

1. Ejemplo
Puerta lógica XOR

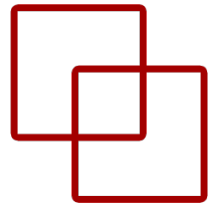

x_1	x_2	XOR
1	1	0
0	0	0
1	0	1
0	1	1

Es imposible modelar el problema con una única neurona, i.e., es imposible **separar linealmente** ambas clases

1. Ejemplo
Puerta lógica XOR

1 1 0

XOR

x_1

¿Como lo solucionamos?

0 0 1

0 1

x_2

1. Ejemplo
Puerta lógica XOR

x_1	x_2	XOR
1	1	0
1	0	1
0	1	1
0	0	0

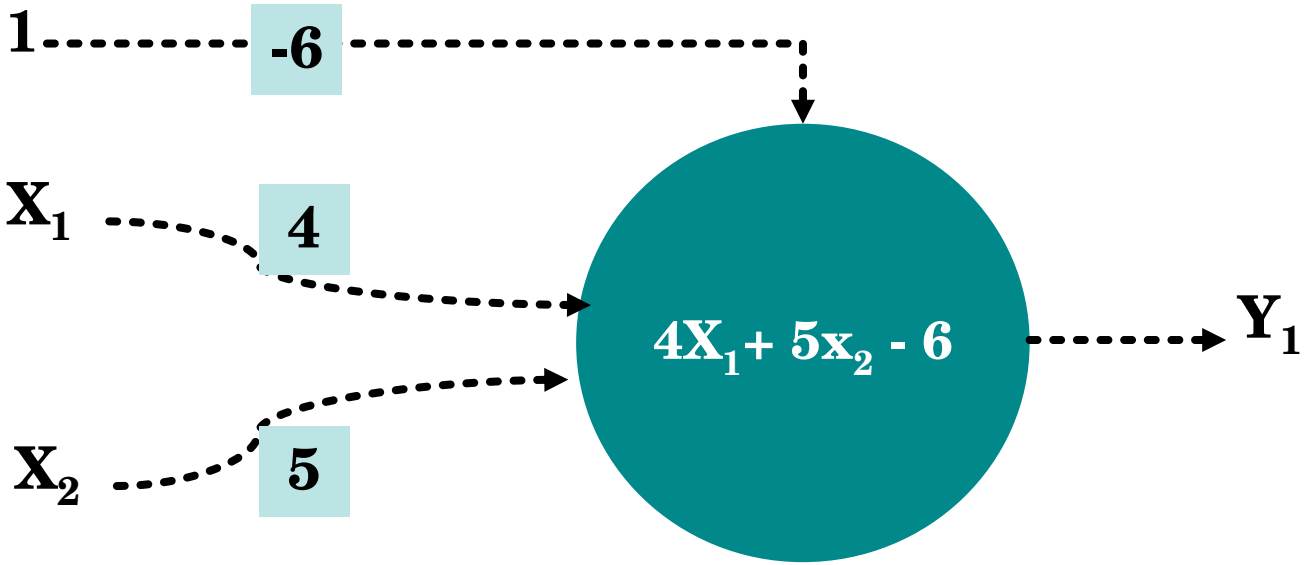

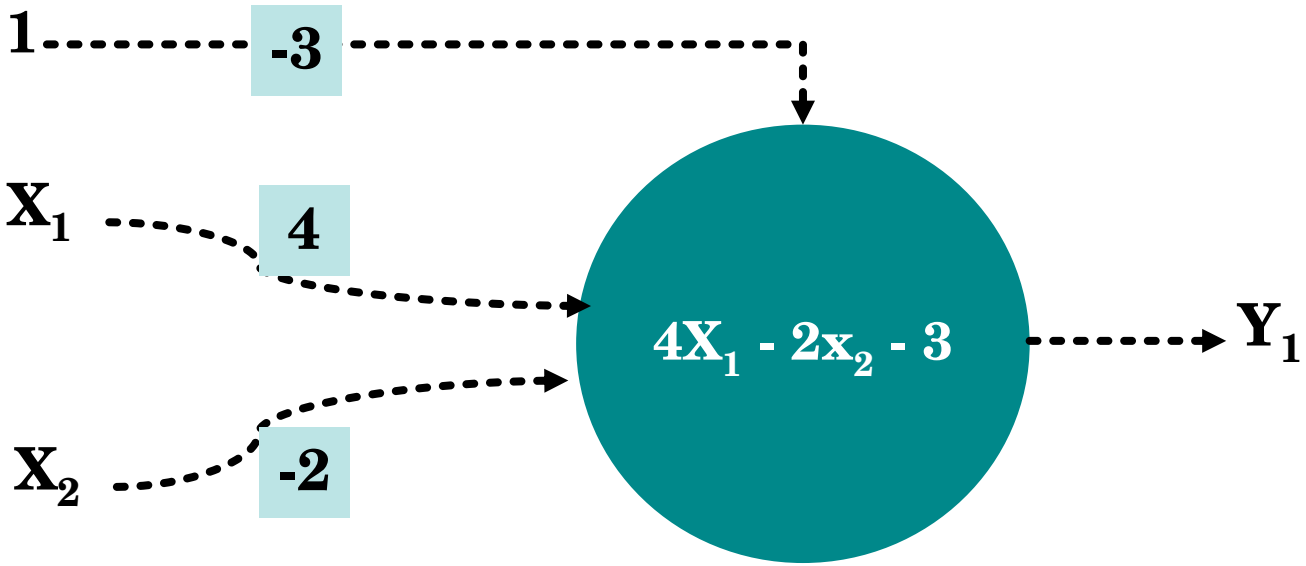

1. Ejemplo
Puerta lógica XOR

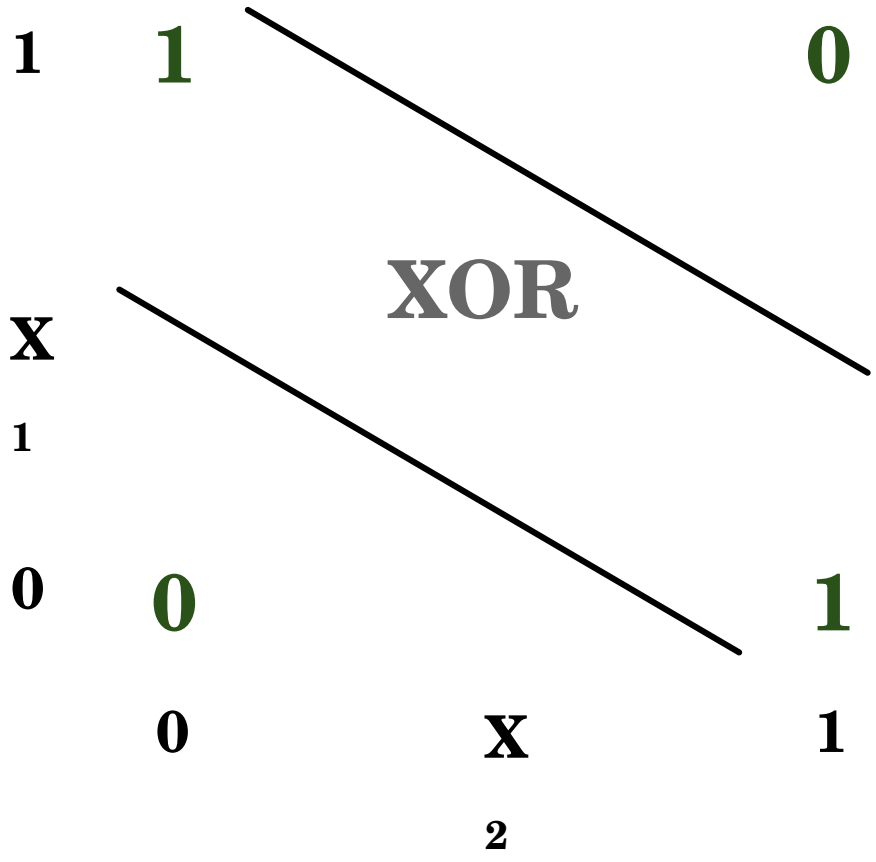

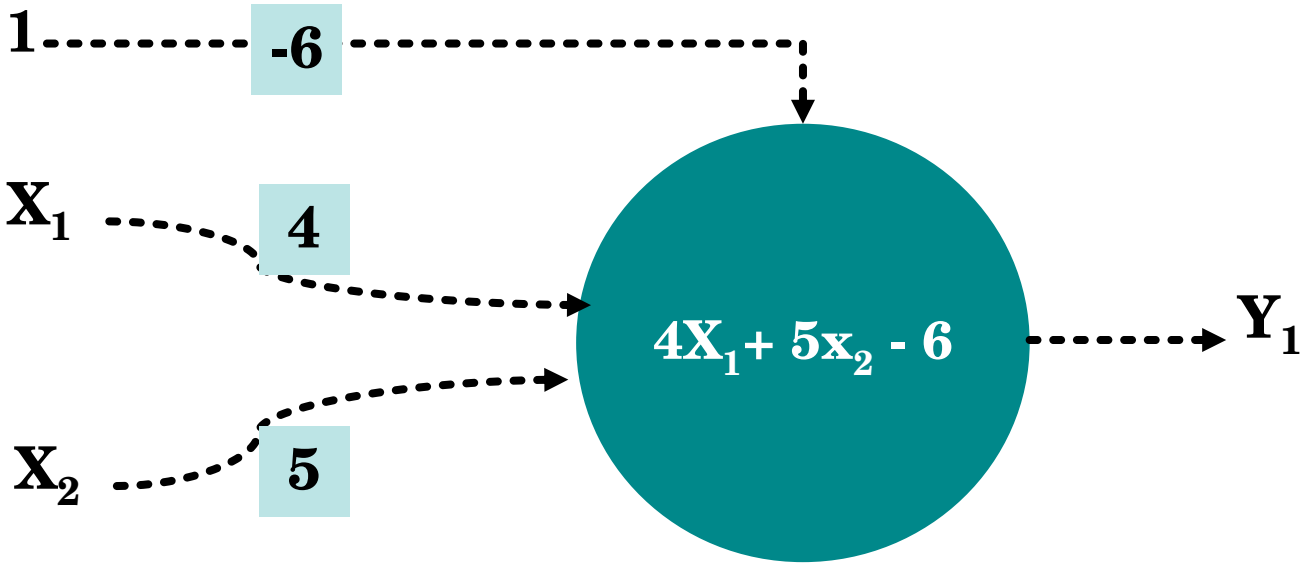

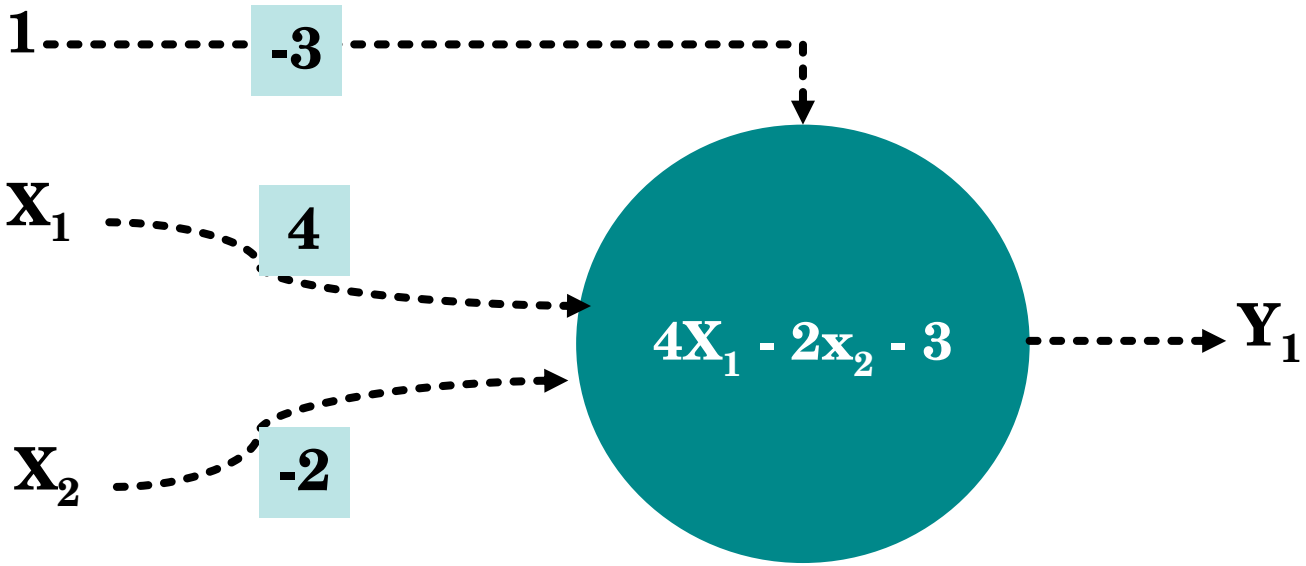

1. Ejemplo
Puerta lógica XOR

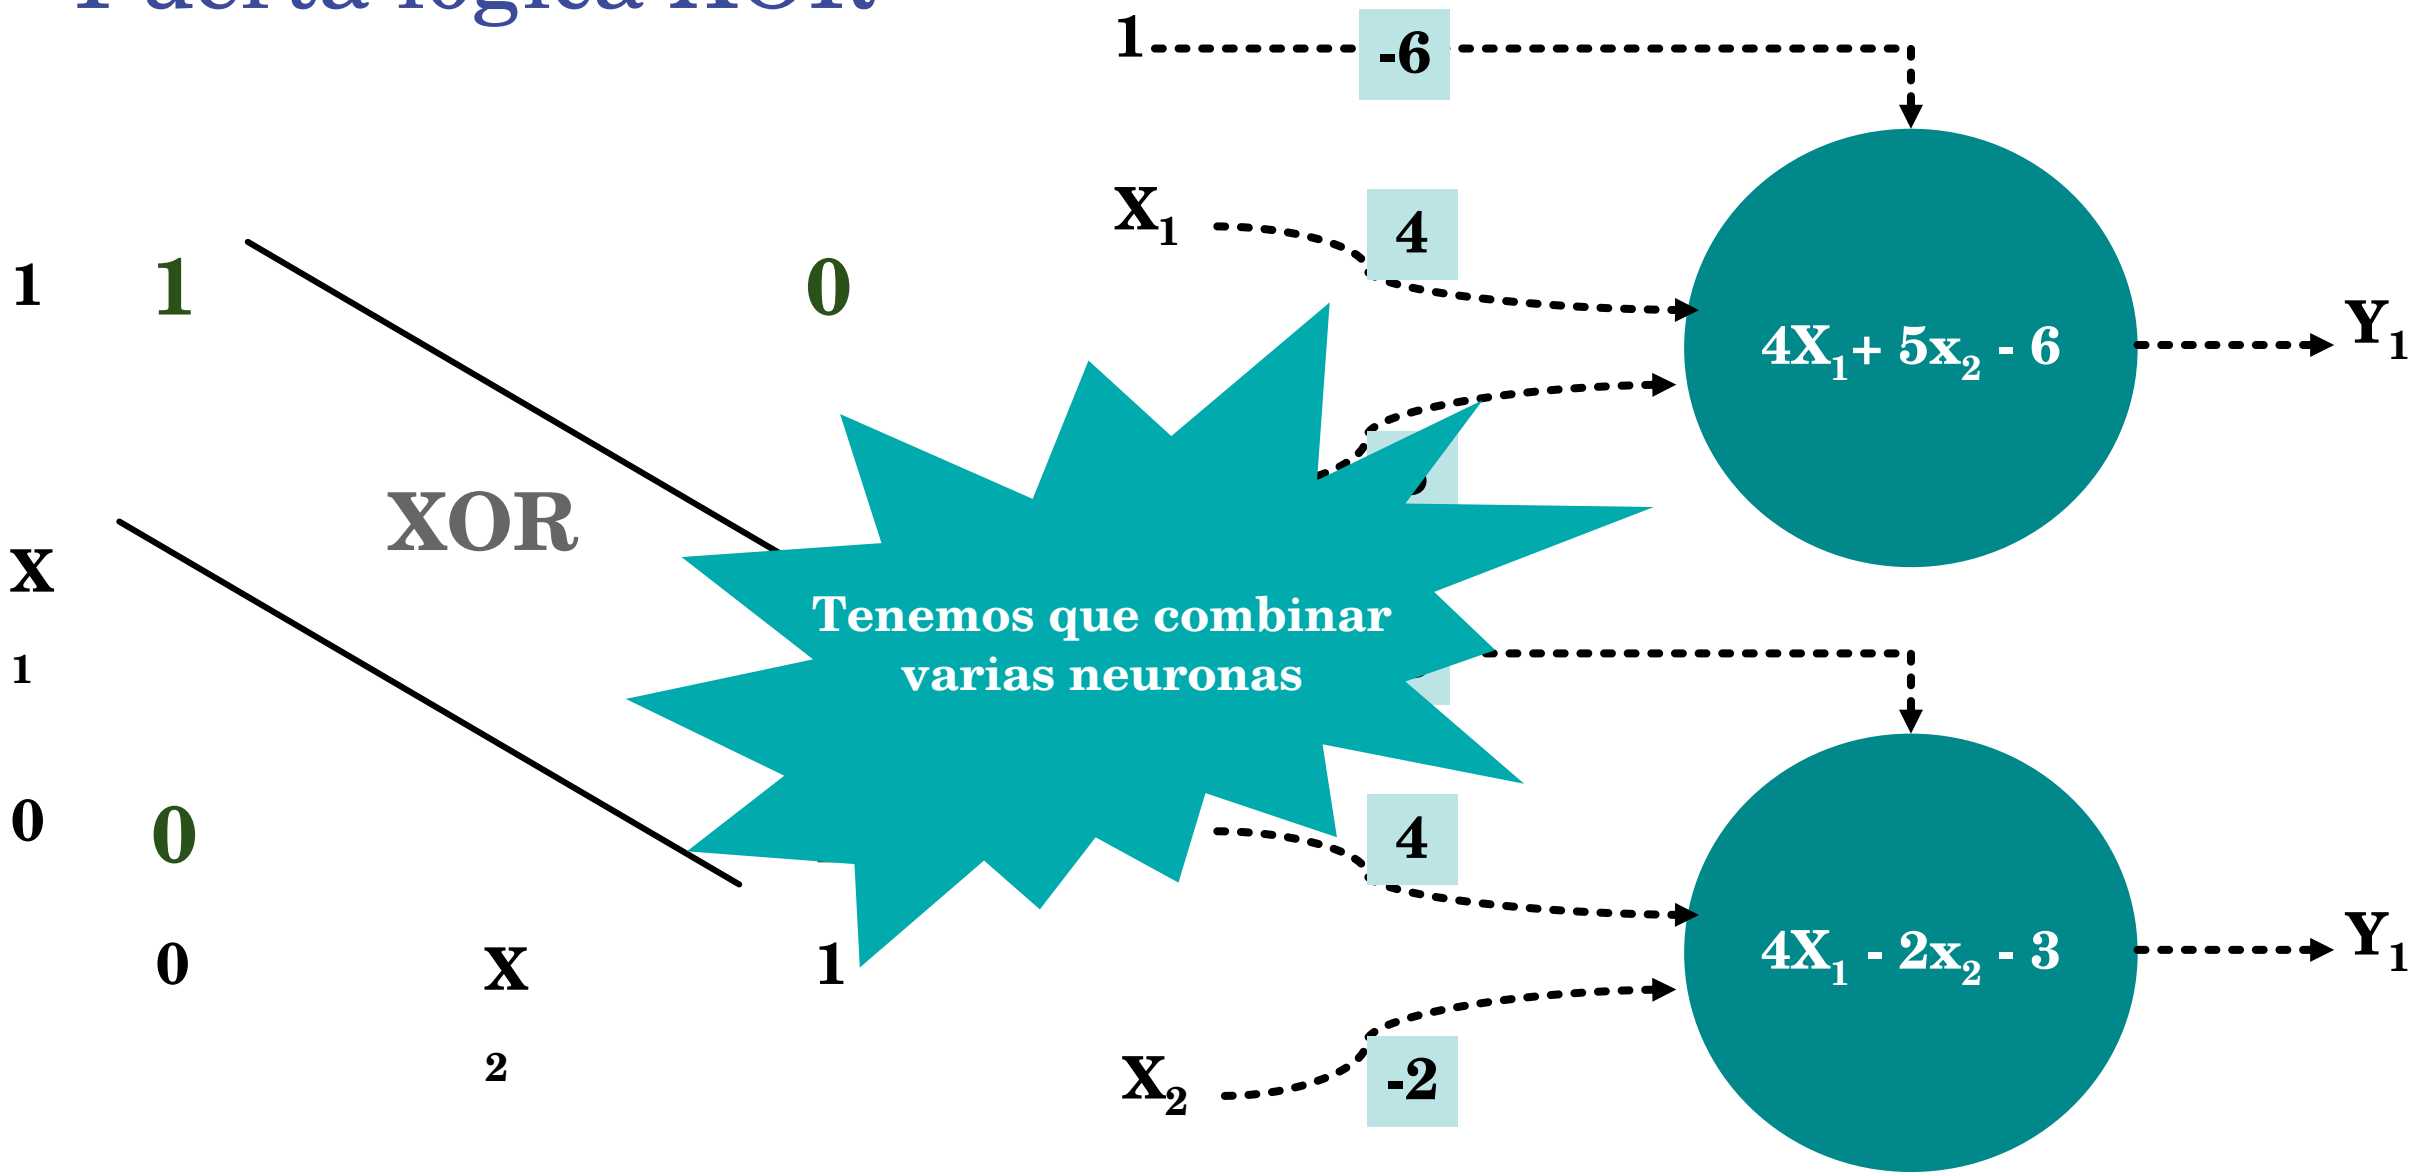

1. Ejemplo

Arquitectura de redes neuronales

- Son la base de las **redes profundas**, actualmente muy utilizadas con mucho éxito.
- Cada **capa extrae características** cada vez más complejas

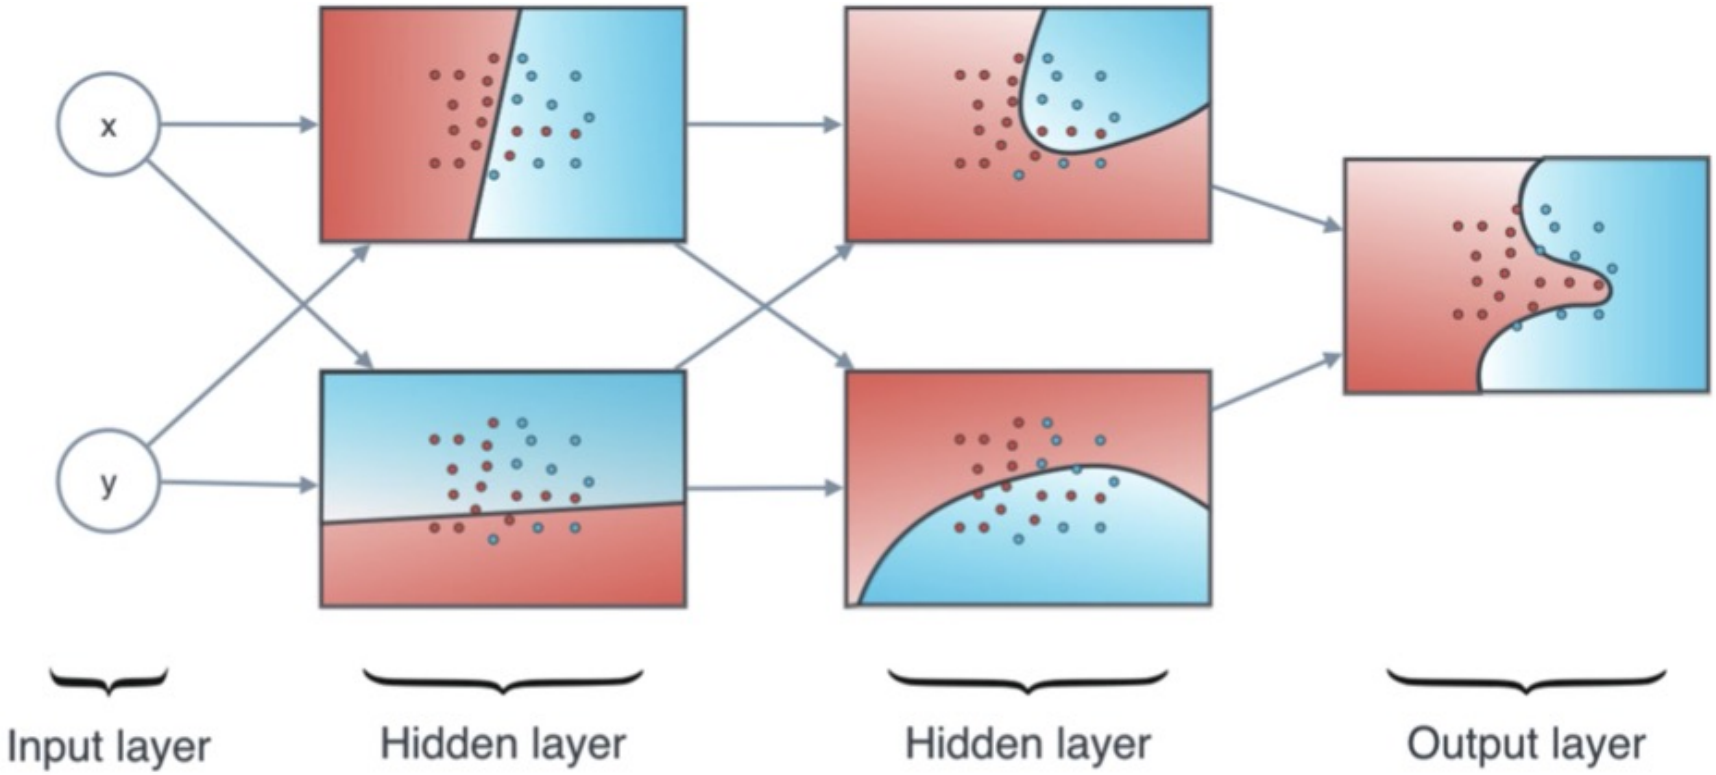

Perceptrón multicapa

ETS de Ingeniería Informática

UNED

1. Definición

- Una neurona **no puede representar** toda la información
  - Problema de linealidad como XOR
- Necesitamos una **agrupación** de neuronas

1. Definición

- Una neurona **no puede representar** toda la información
  - Problema de linealidad como XOR
- Necesitamos una **agrupación** de neuronas

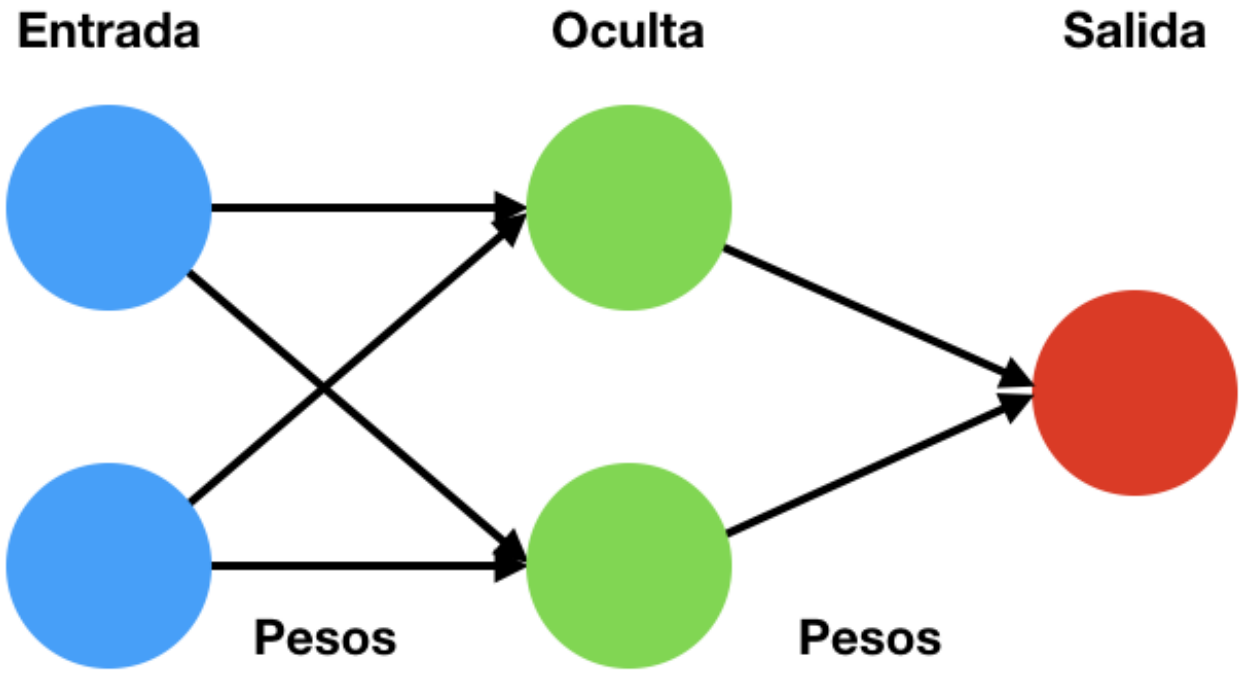

1. Definición

- Una neurona no puede representar toda la información
  - Problema de linealidad como XOR
- Necesitamos una agrupación de neuronas

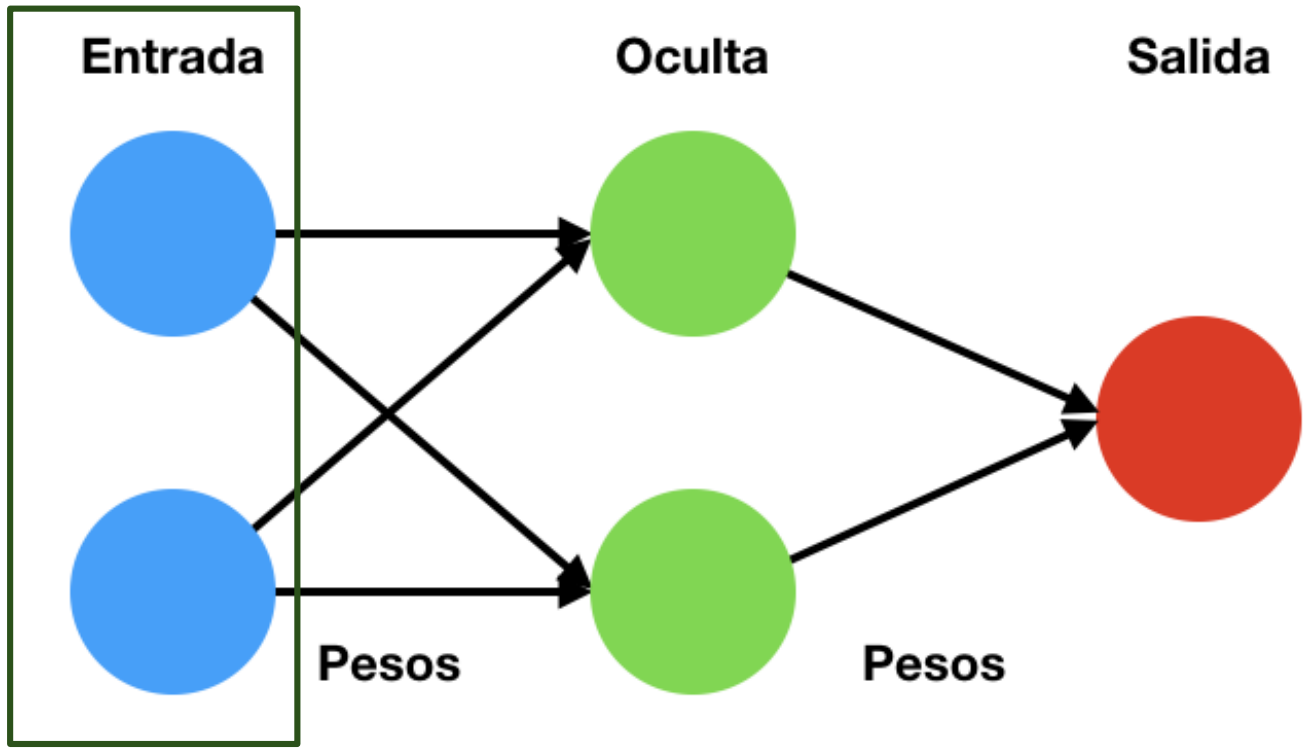

1. Definición

- Una neurona no puede representar toda la información
  - Problema de linealidad como XOR
- Necesitamos una agrupación de neuronas

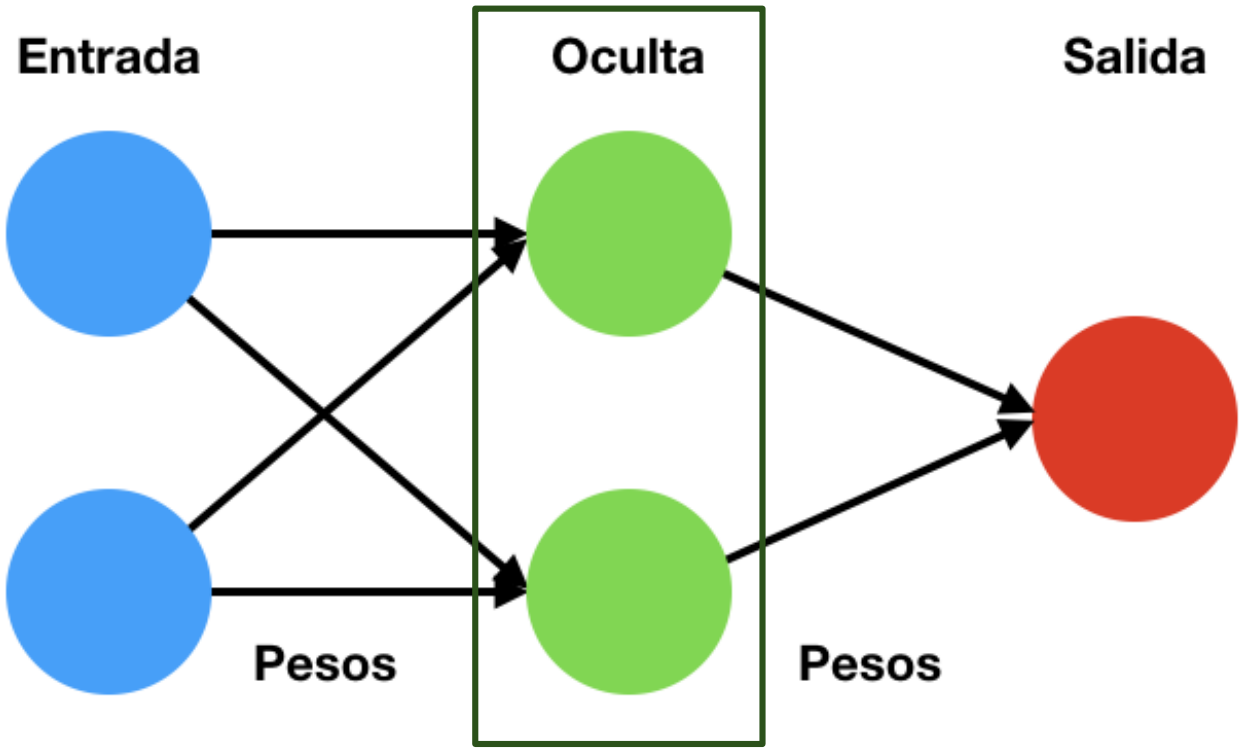

1. Definición

- Una neurona no puede representar toda la información
  - Problema de linealidad como XOR
- Necesitamos una agrupación de neuronas

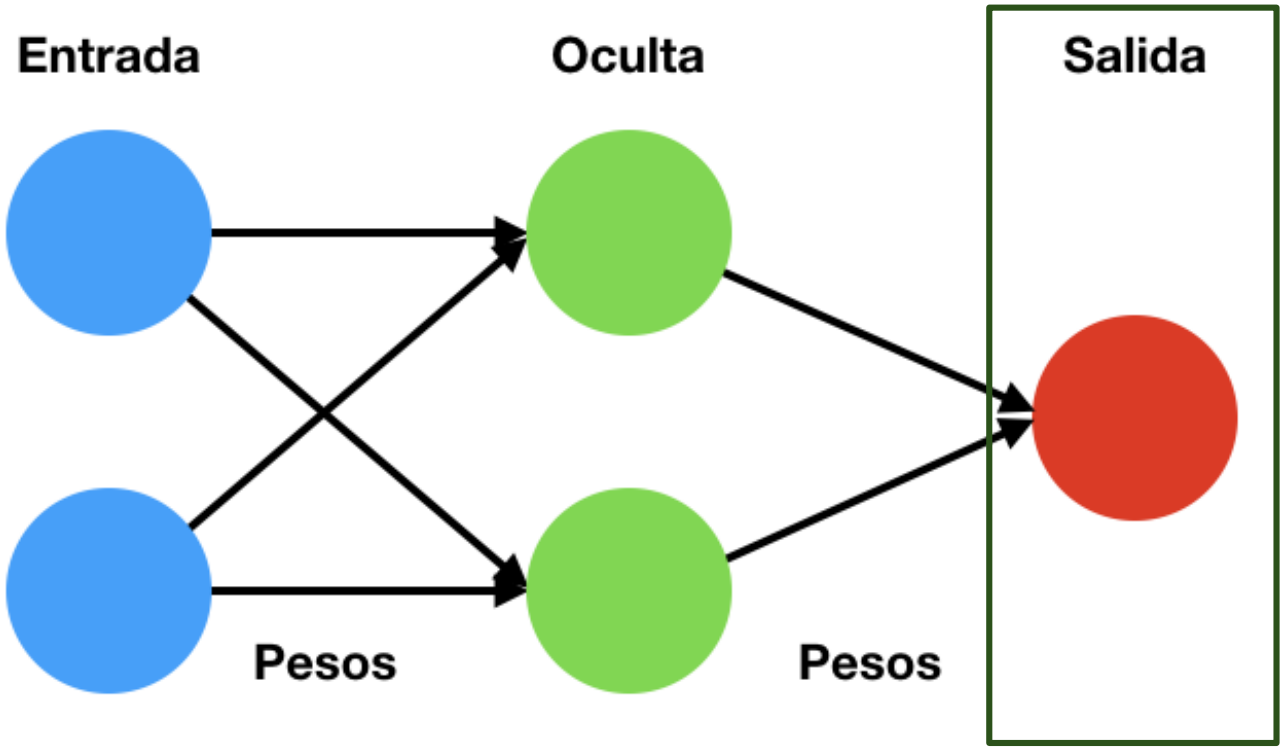

2. Secuencialidad de neuronas

- Si ponemos neuronas de forma secuencial

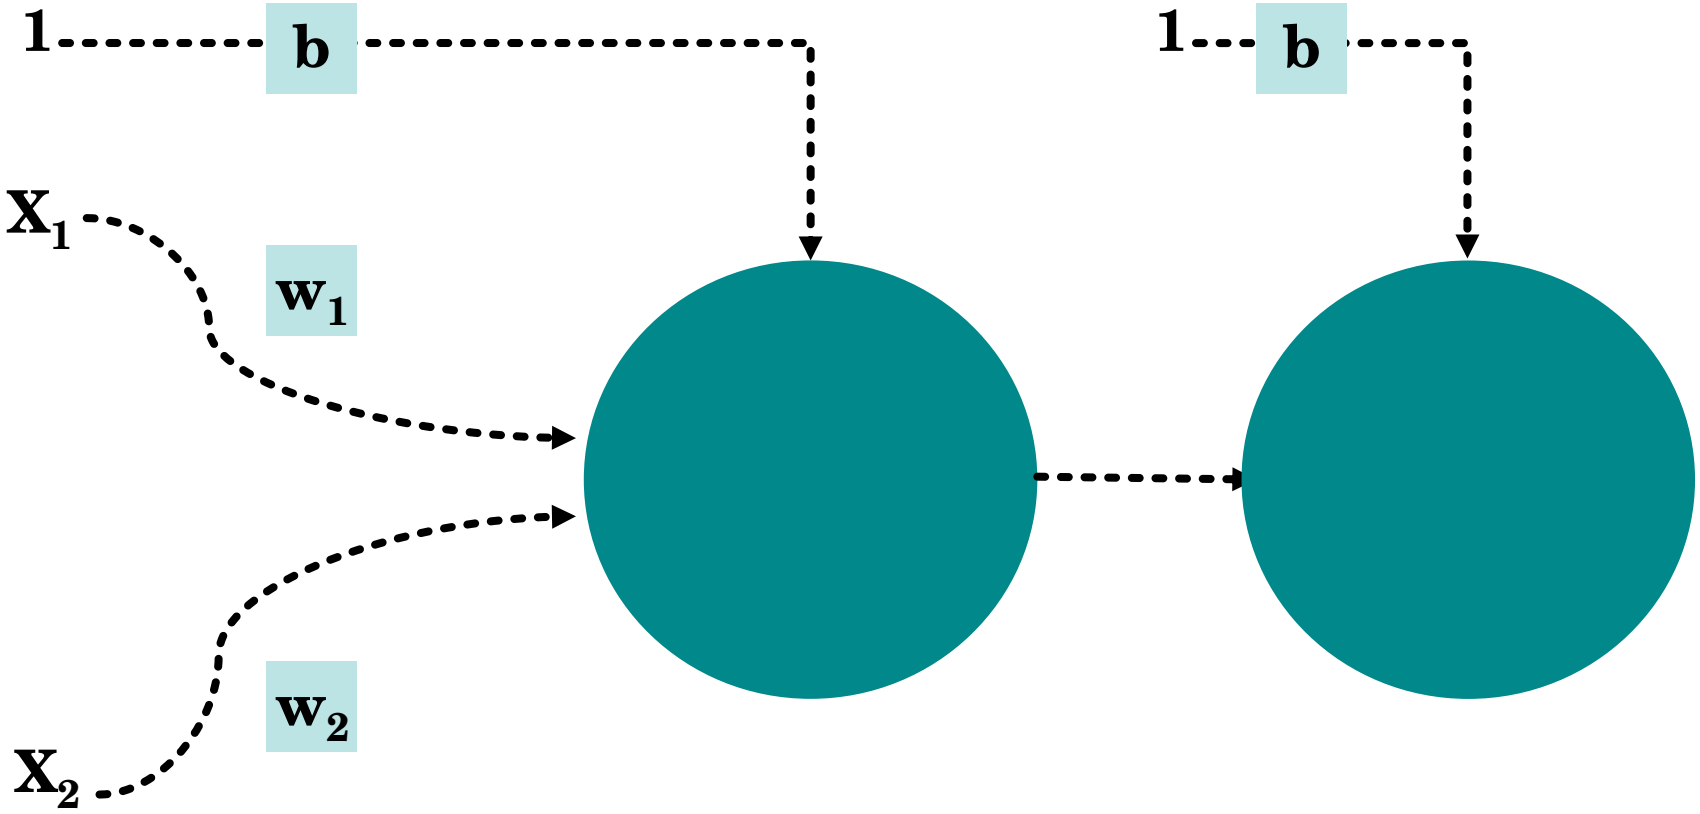

2. Secuencialidad de neuronas

- Si ponemos neuronas de forma secuencial

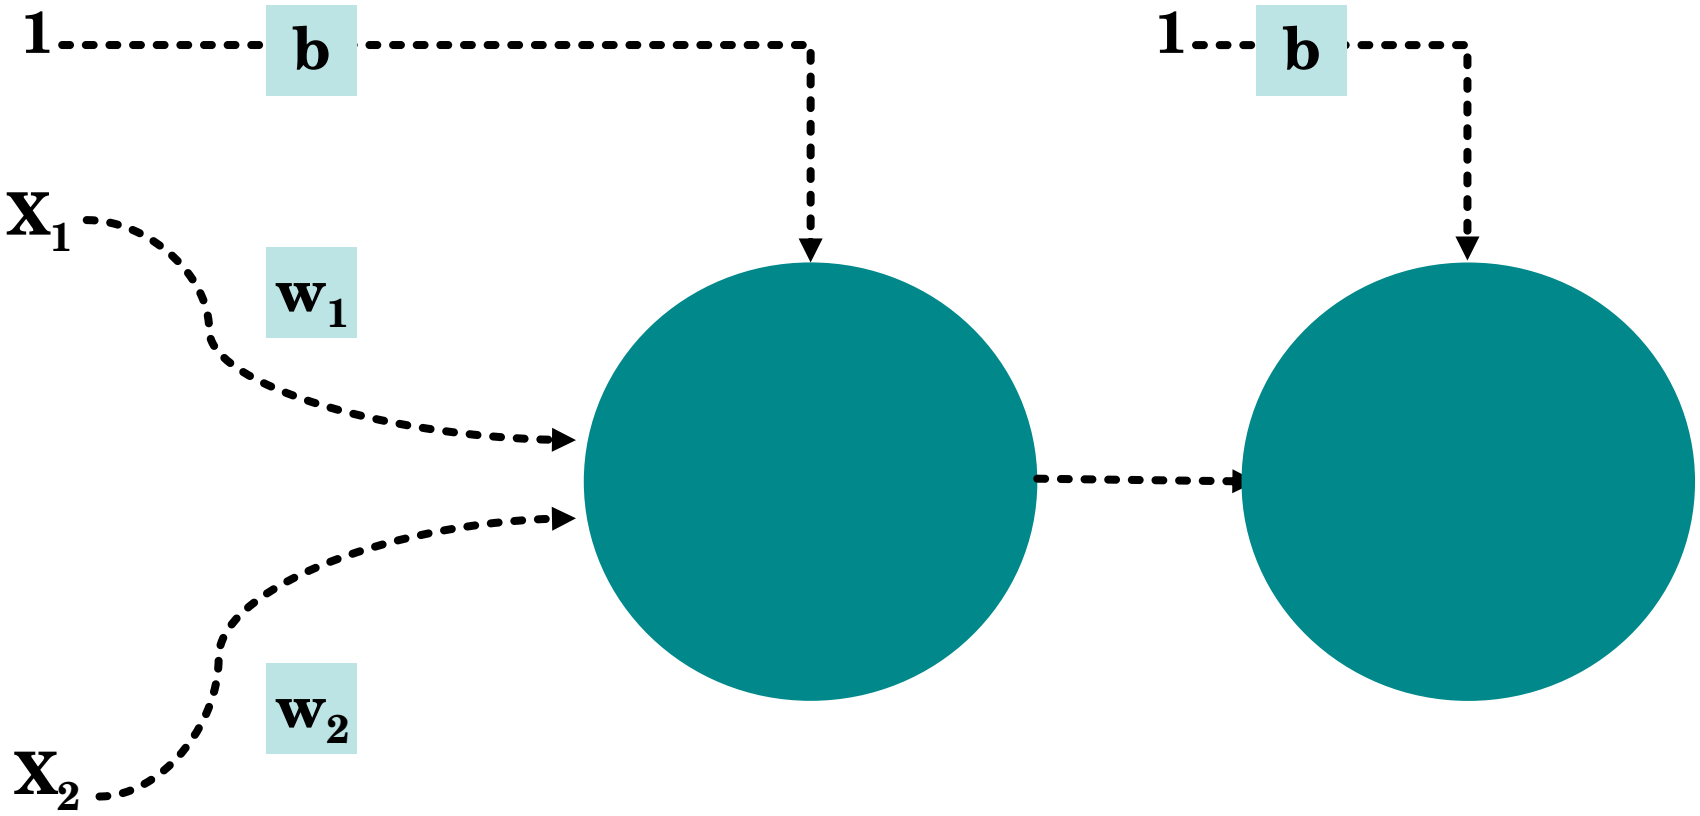

¿Qué nos aporta?

2. Secuencialidad de neuronas

- Si ponemos neuronas de forma secuencial

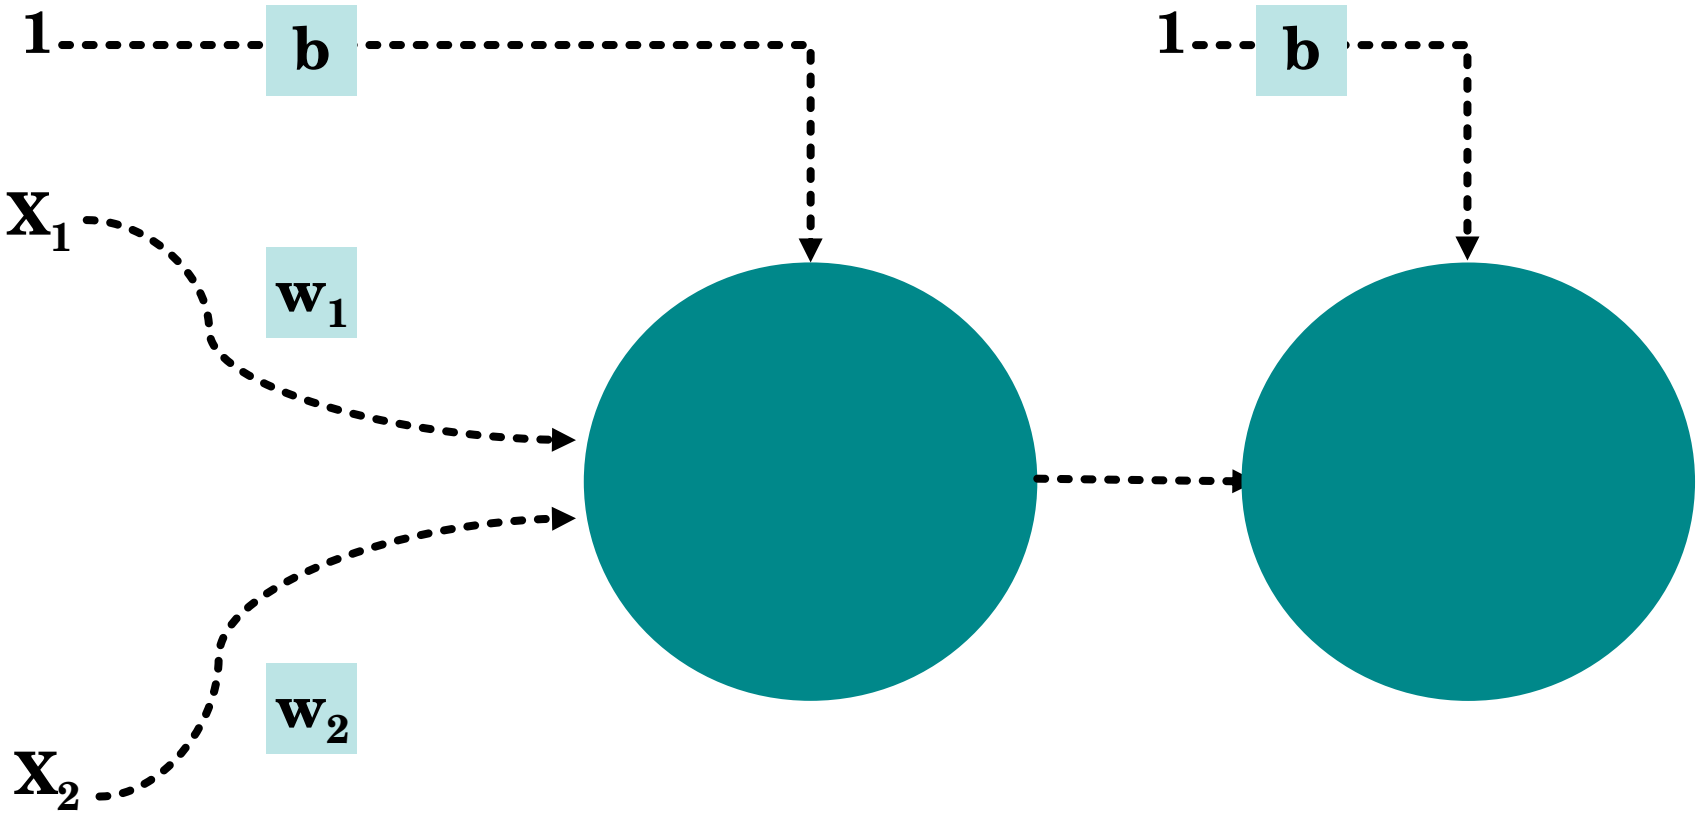

¿Qué nos aporta?
Conocimiento jerarquizado

3. Conocimiento Jerarquizado

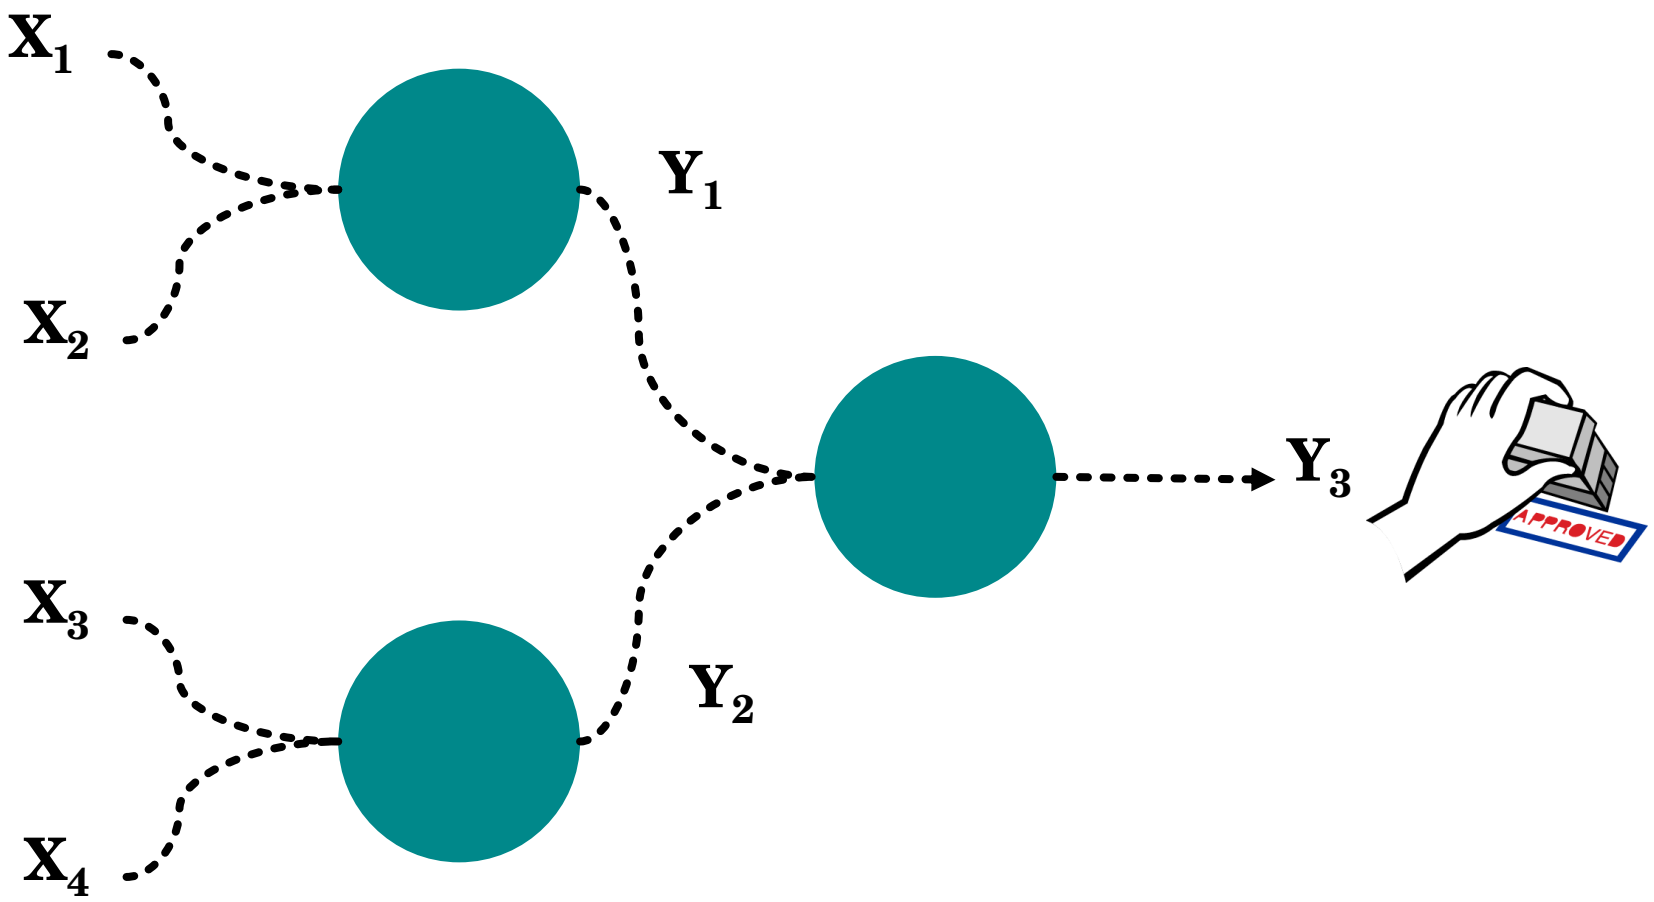

3. Conocimiento Jerarquizado

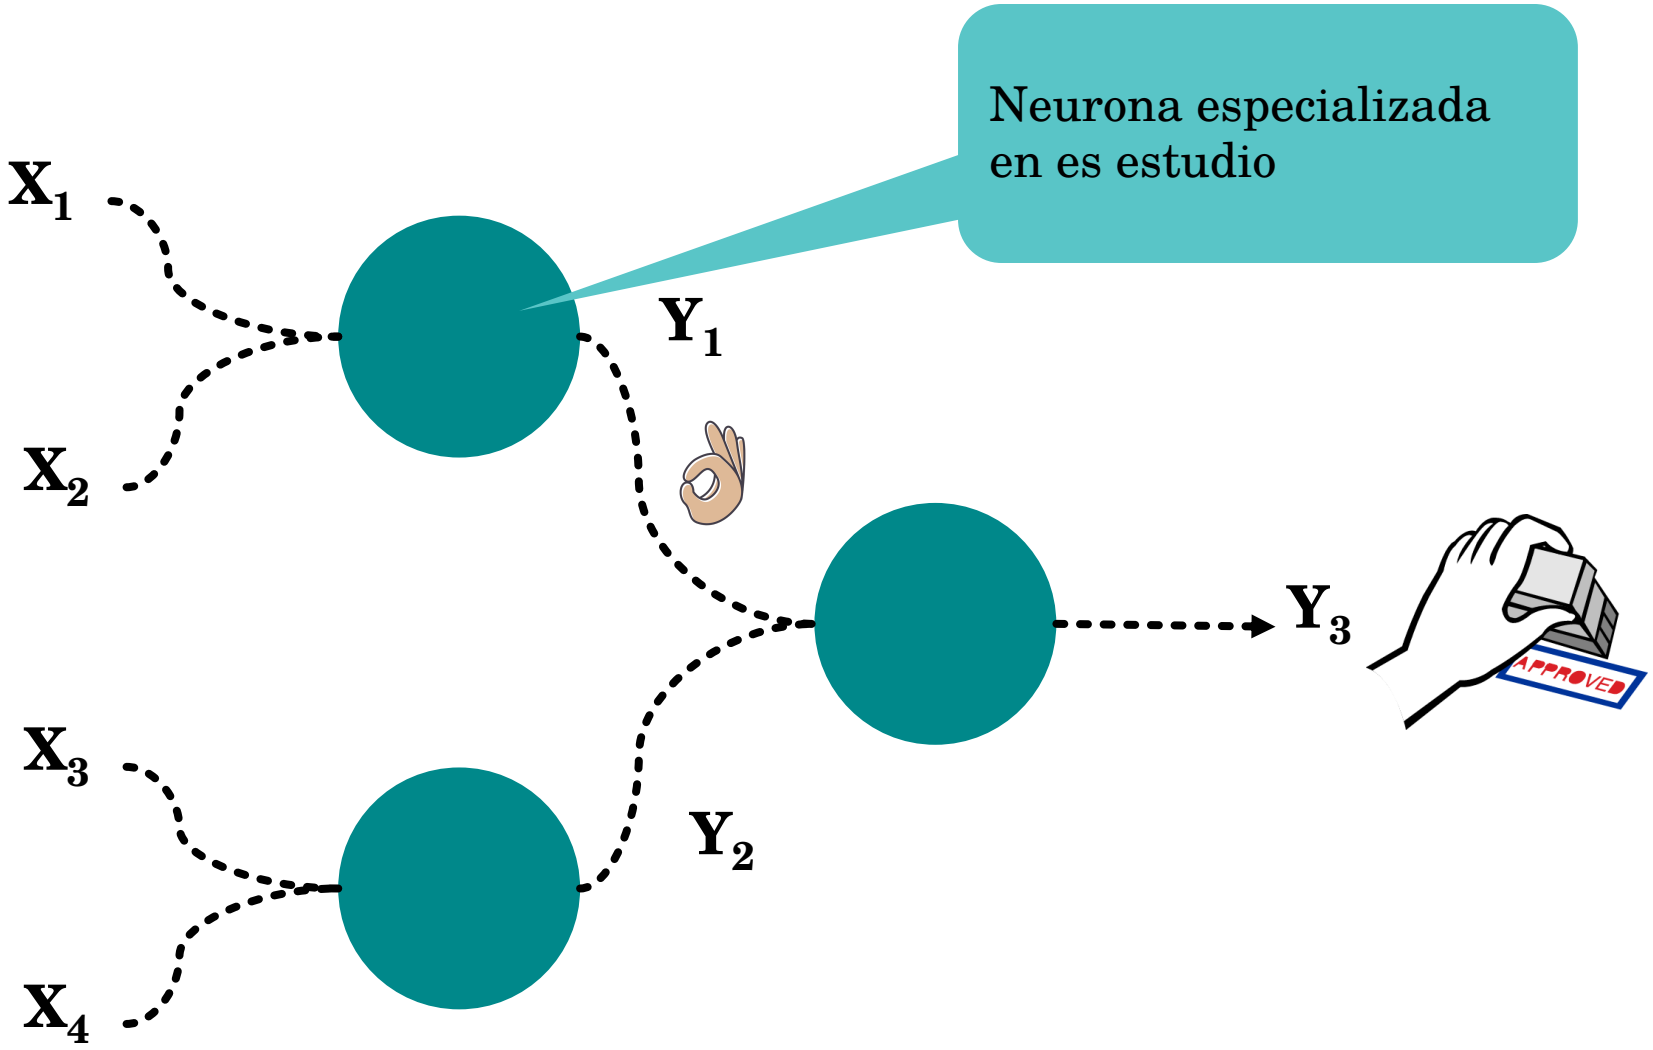

3. Conocimiento Jerarquizado

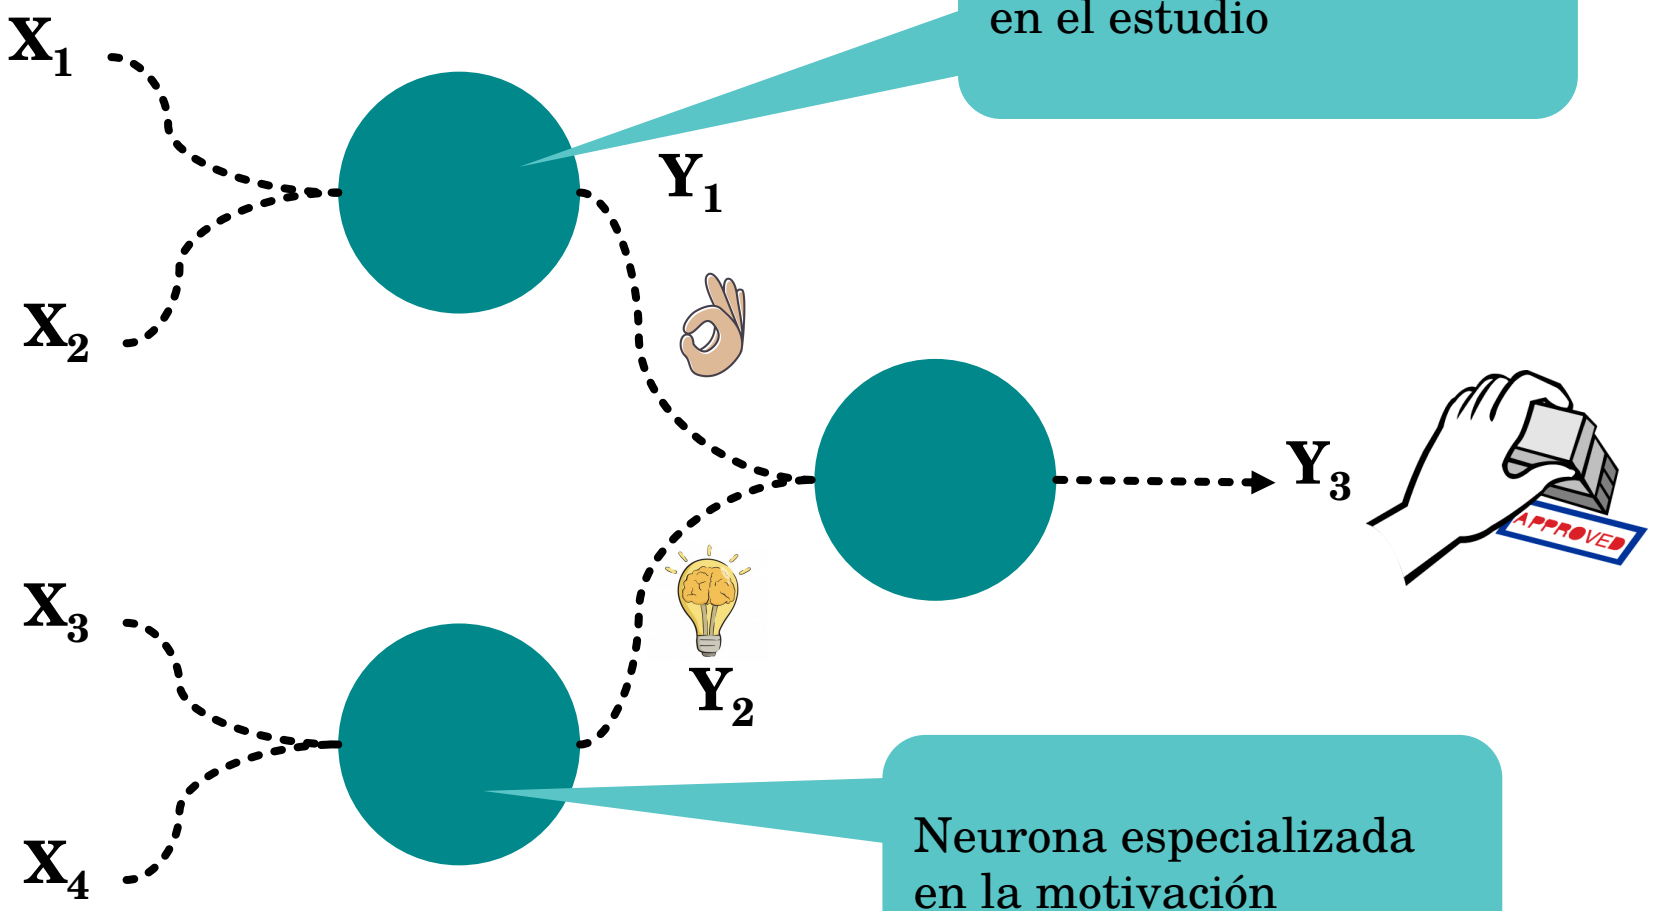

3. Conocimiento Jerarquizado

X_1

X_2

X_3

X_4

Neurona especializada en el estudio

Y_1

Neurona especializada en el resultado del examen

Y_3

Y_2

Neurona especializada en la motivación

3. Conocimiento Jerarquizado

Ejemplo

X_1

X_2

X_3

X_4

Y_1

Y_2

Y_3

Si el estudio es bajo y motivación alto → posiblemente suspenda

4. Problema

- El problema es que la concatenación de regresiones lineales es **igual** a una regresión lineal

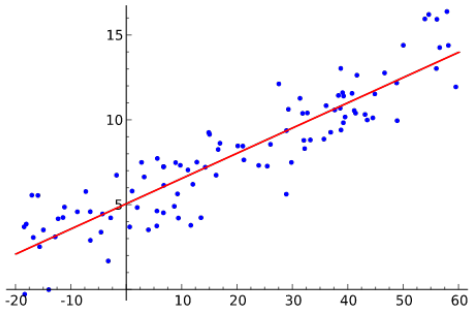

+ … +

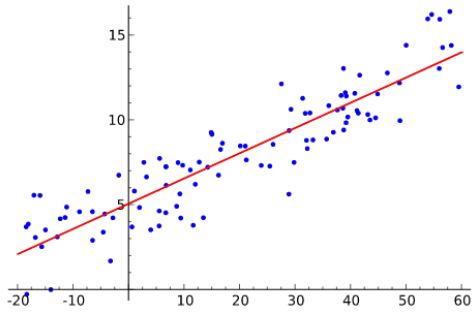

=

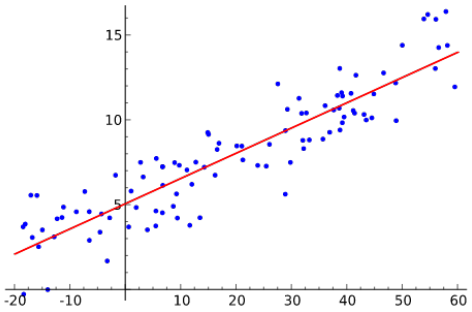

4. Problema

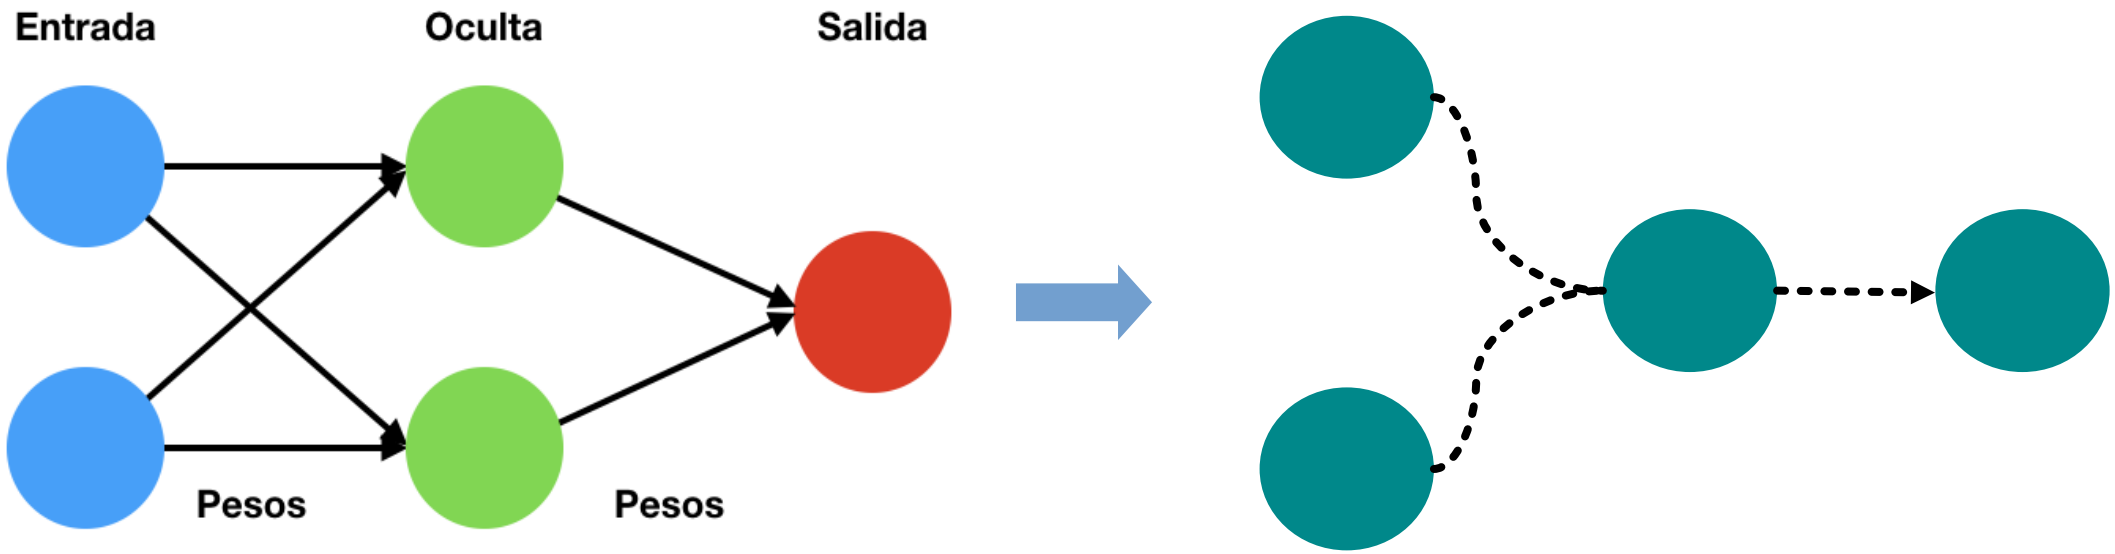

4. Problema

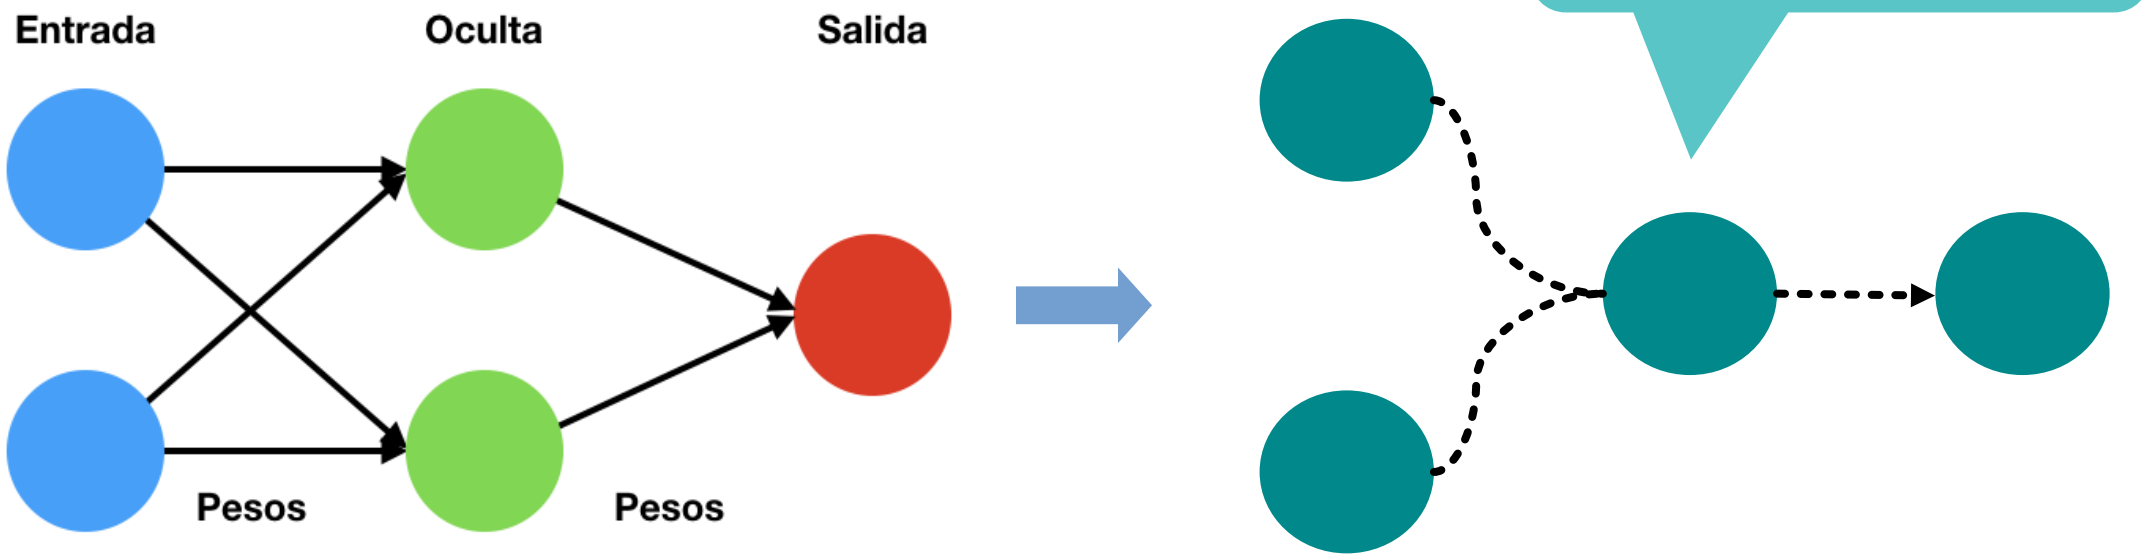
Entrada
Oculta
Salida
Pesos
Pesos
Nuestra red colapsa
como tener una neurona

4. Problema

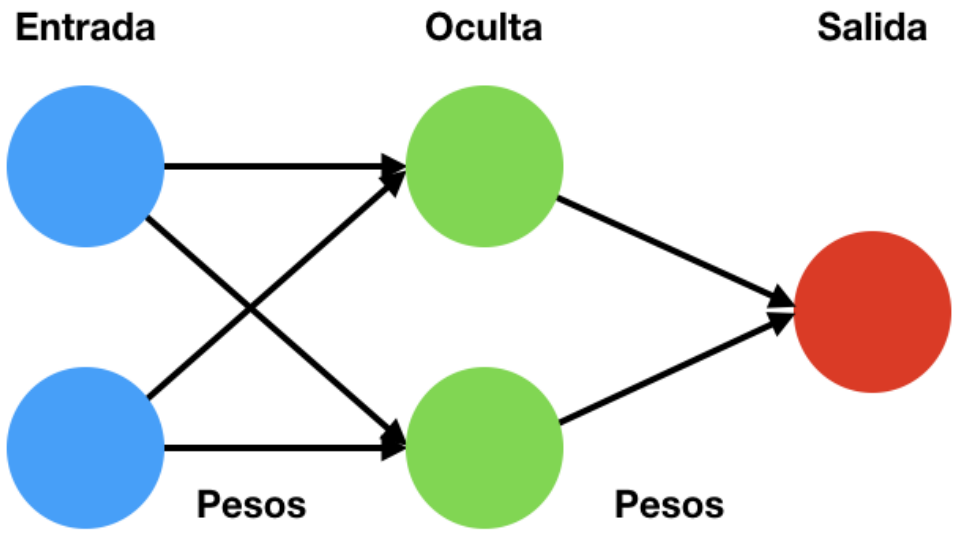
Entrada
Oculta
Salida
Pesos
Pesos

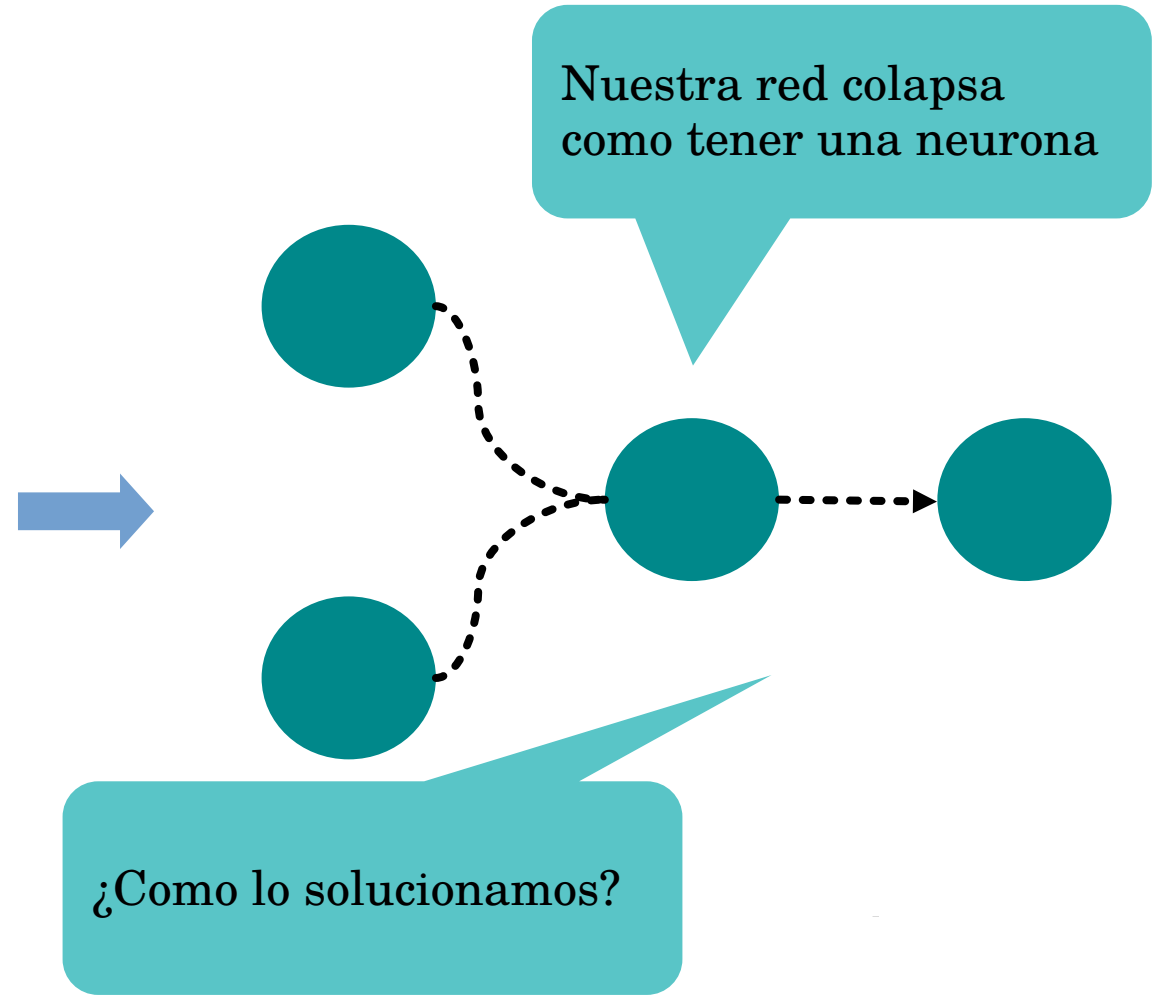
Nuestra red colapsa
como tener una neurona
¿Como lo solucionamos?

4. Problema

- Que nuestras funciones sufran una distorsión para romper la linealidad

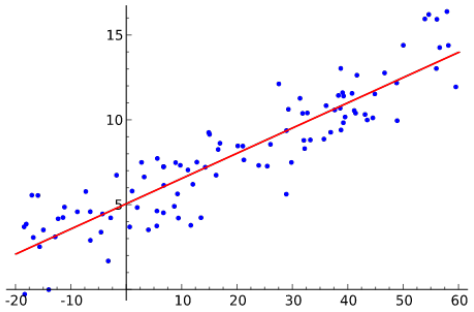

+ … +

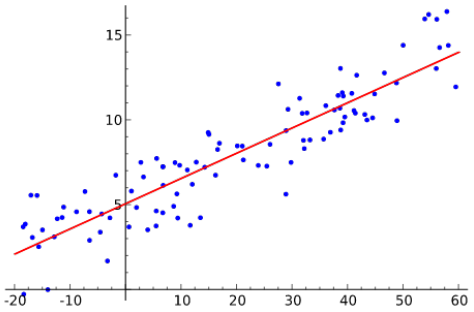

=

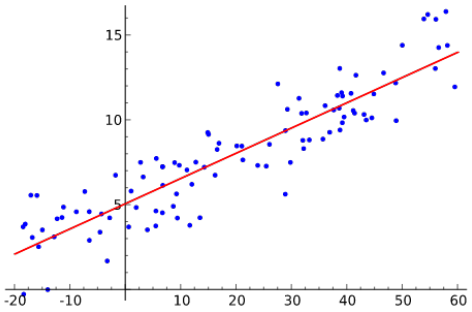

¿Entoces distosionamos las funciones?

4. Problema

- Que nuestras funciones sufran una distorsión para romper la linealidad

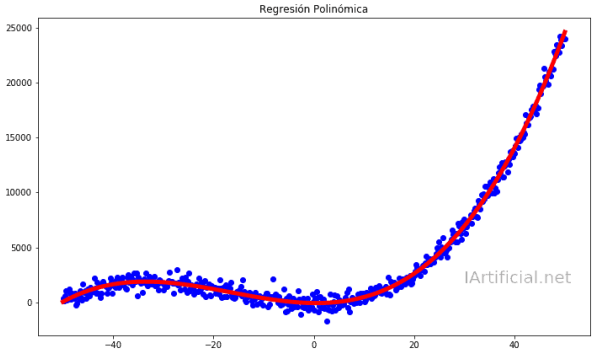

+ … +

Polynomial Regression → $y = W_1x^3 + W_2x^2 + W_3x + W_4$

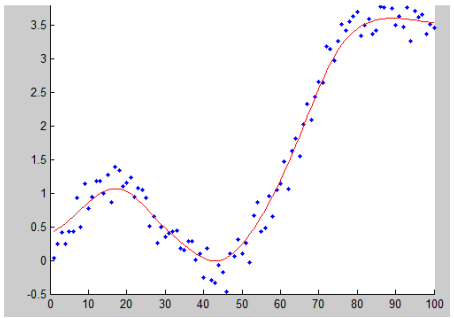

=/=

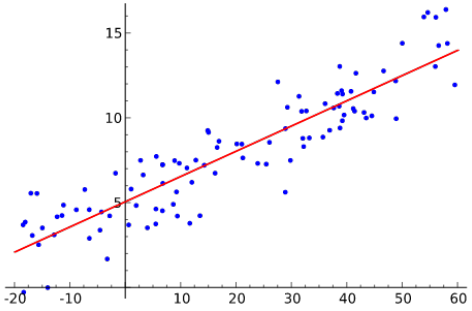

Así el resultado **no es Lineal**

4. Problema

- Que nuestras funciones sufran una distorsión para romper la linealidad

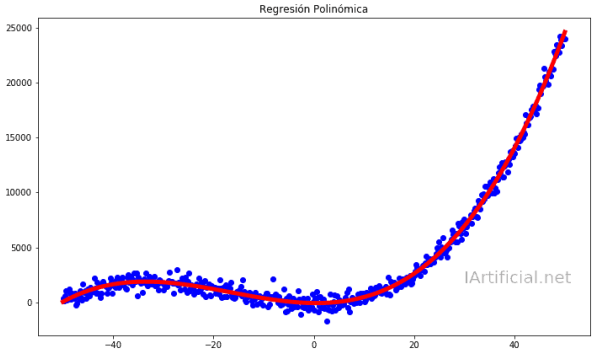

+ … +

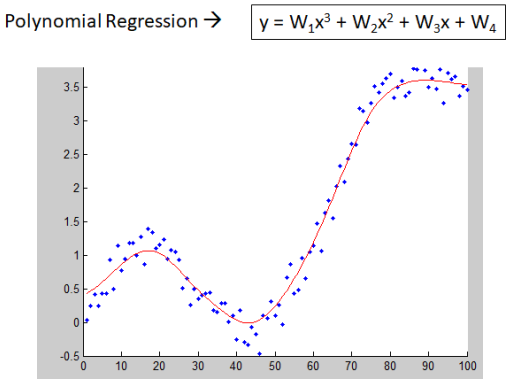

=/=

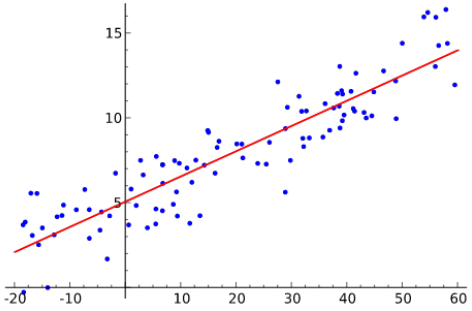

Añadimos **funciones de activación**

5. Arquitectura de redes neuronales

- Son la base de las **redes profundas**, actualmente muy utilizadas con mucho éxito.
- Cada **capa extrae características** cada vez más complejas

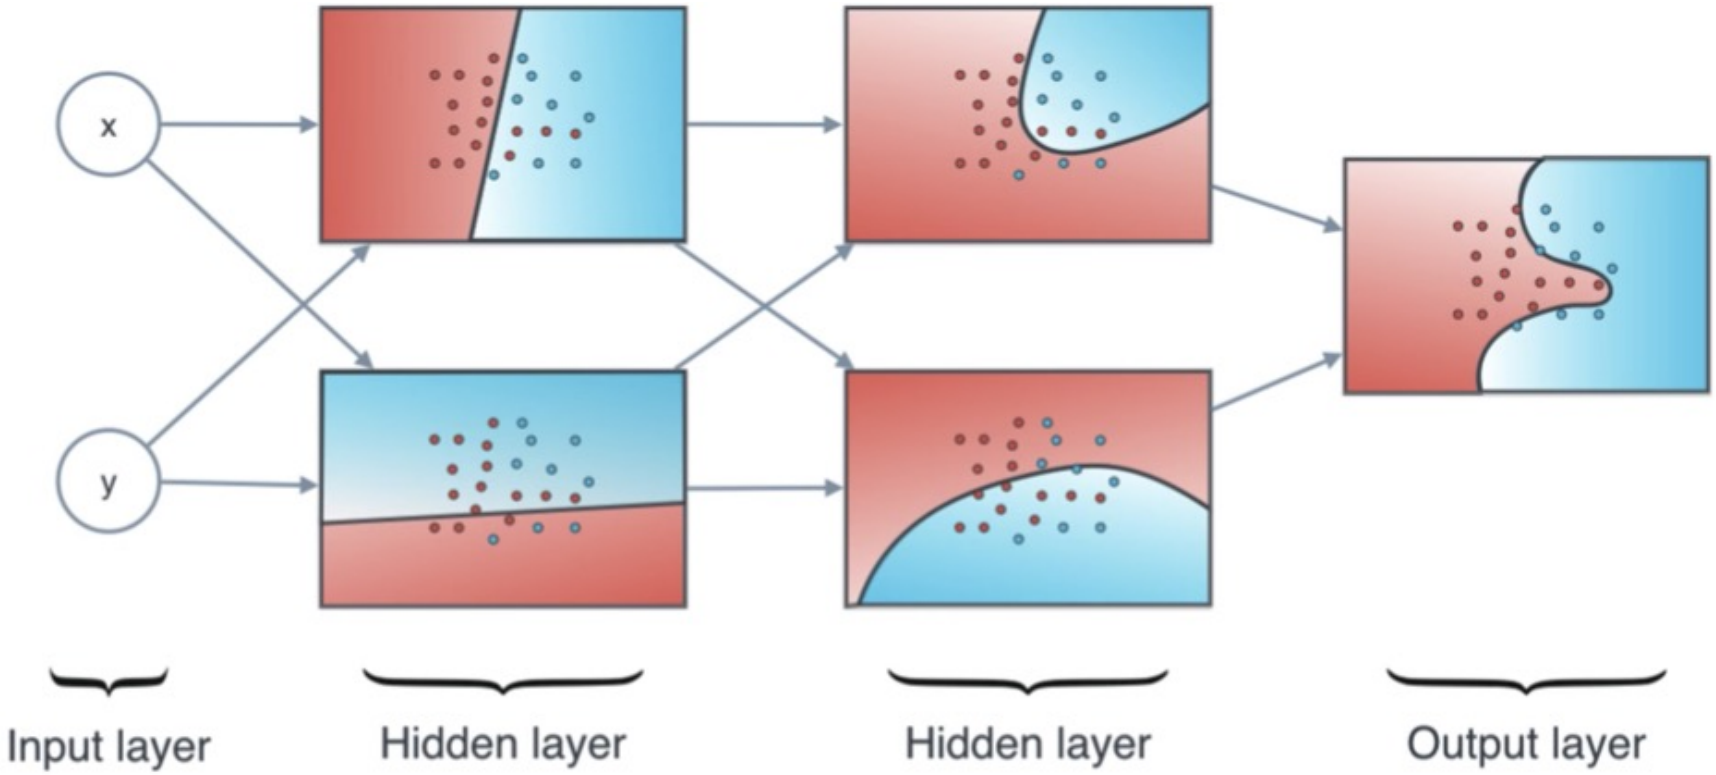

Función de activación

ETS de Ingeniería Informática

UNED

1. ¿Donde se encuentra?

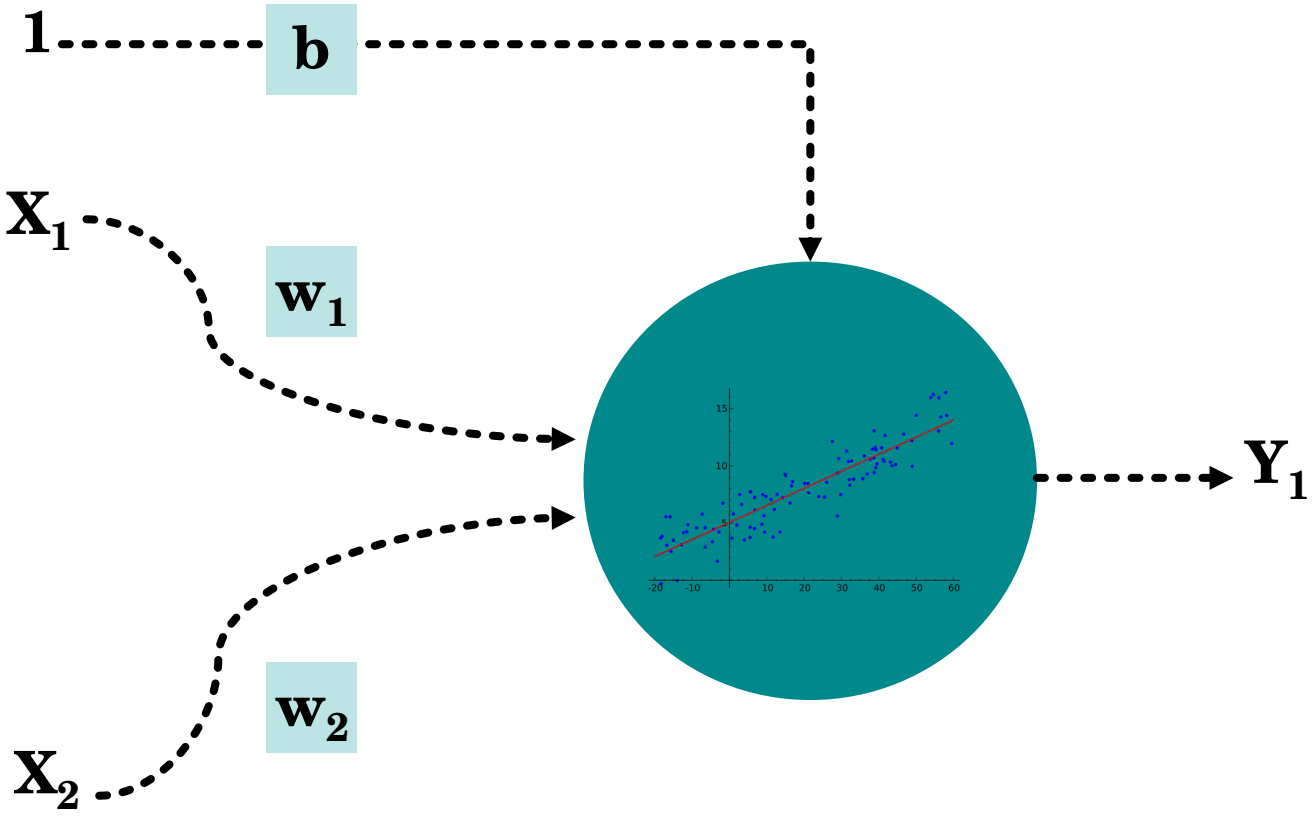

$$y = w_1x_1 + w_2x_2 + b$$

1. ¿Donde se encuentra?

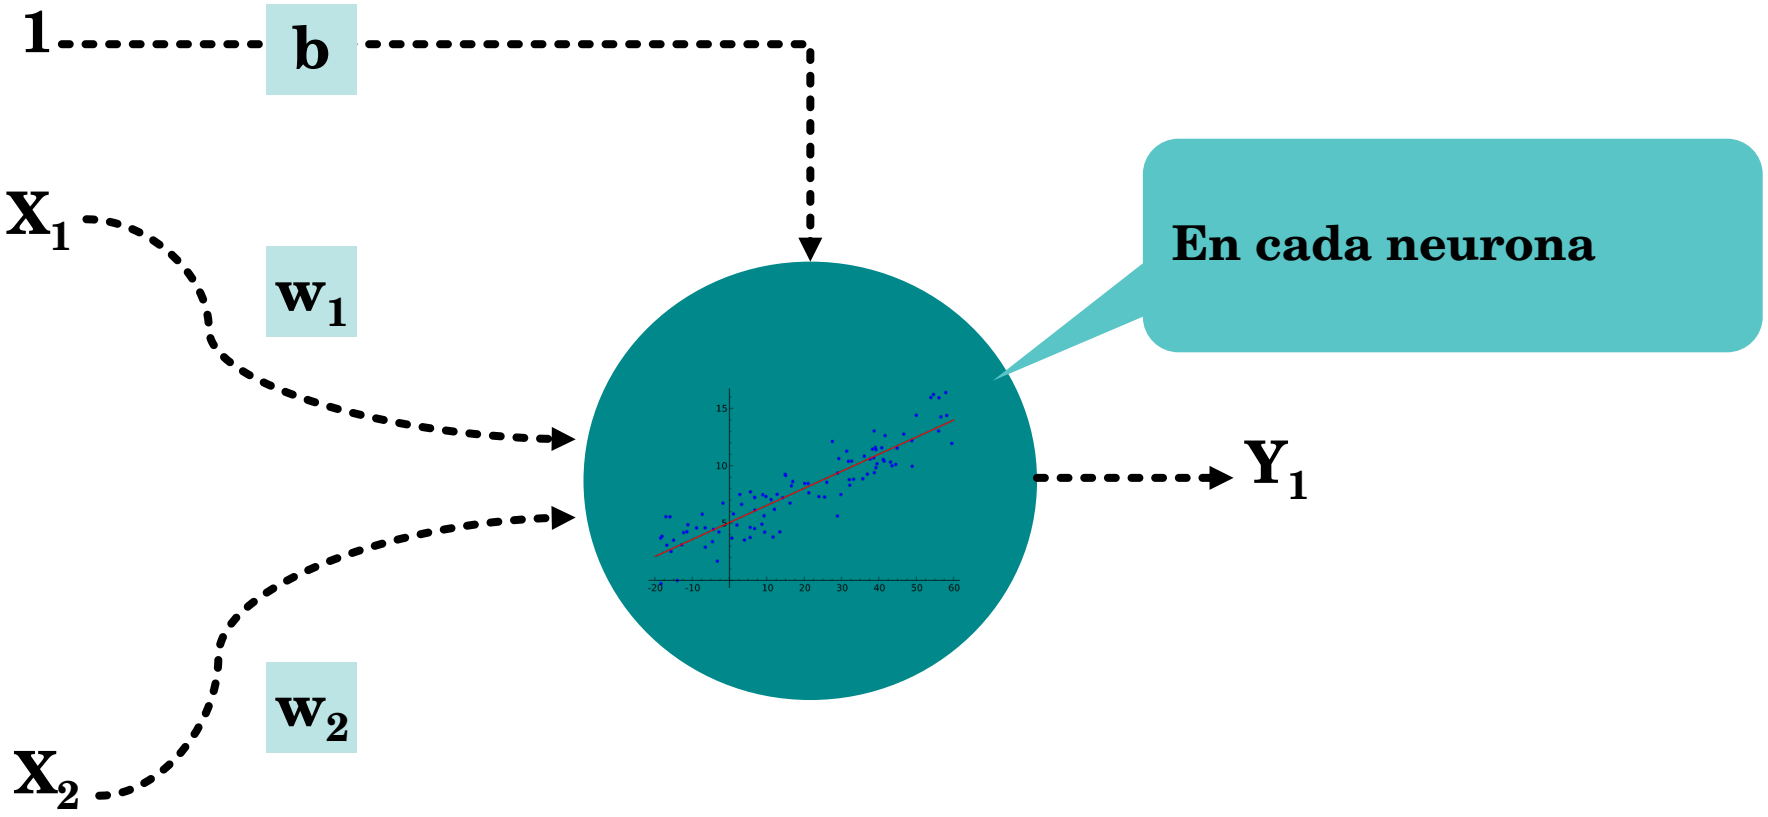

$$y = w_1x_1 + w_2x_2 + b$$

2. ¿Como la representamos?

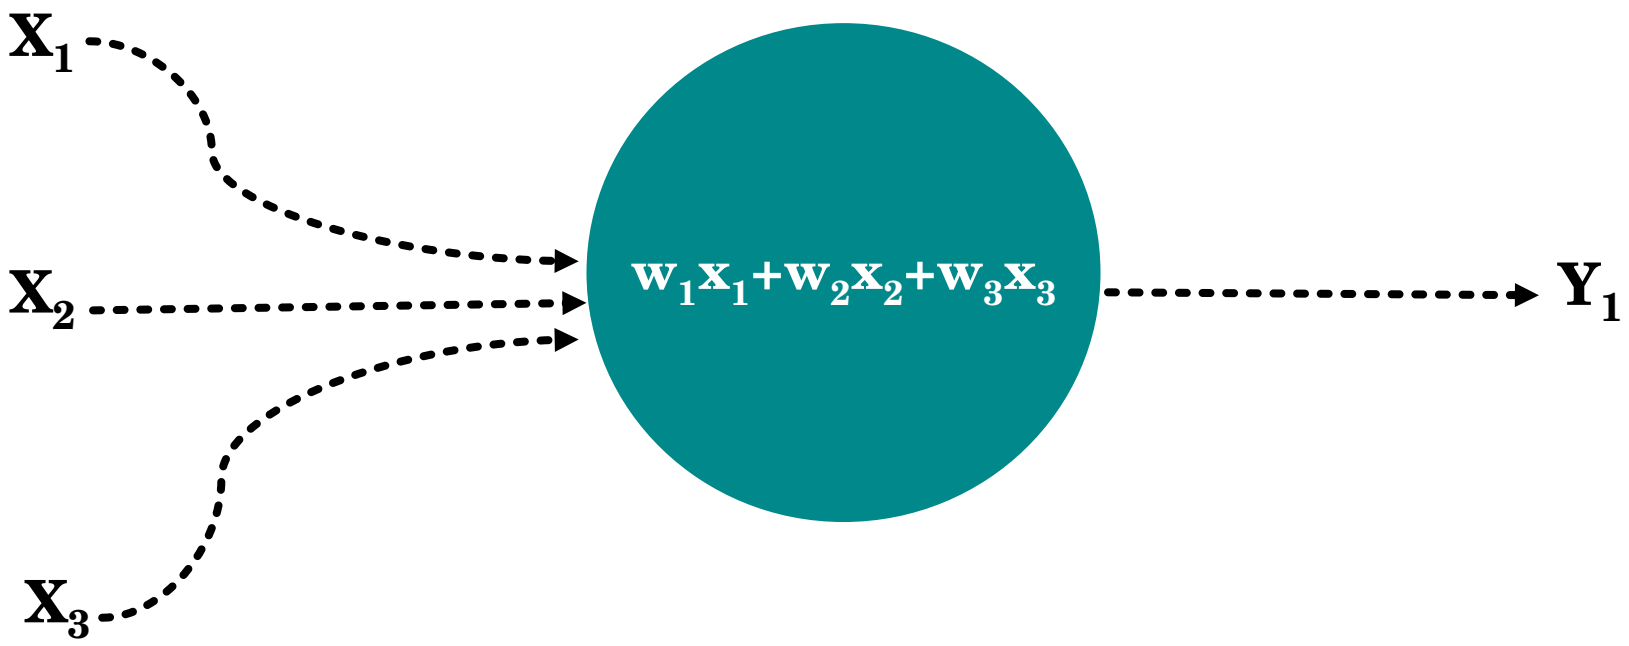

2. ¿Como la representamos?

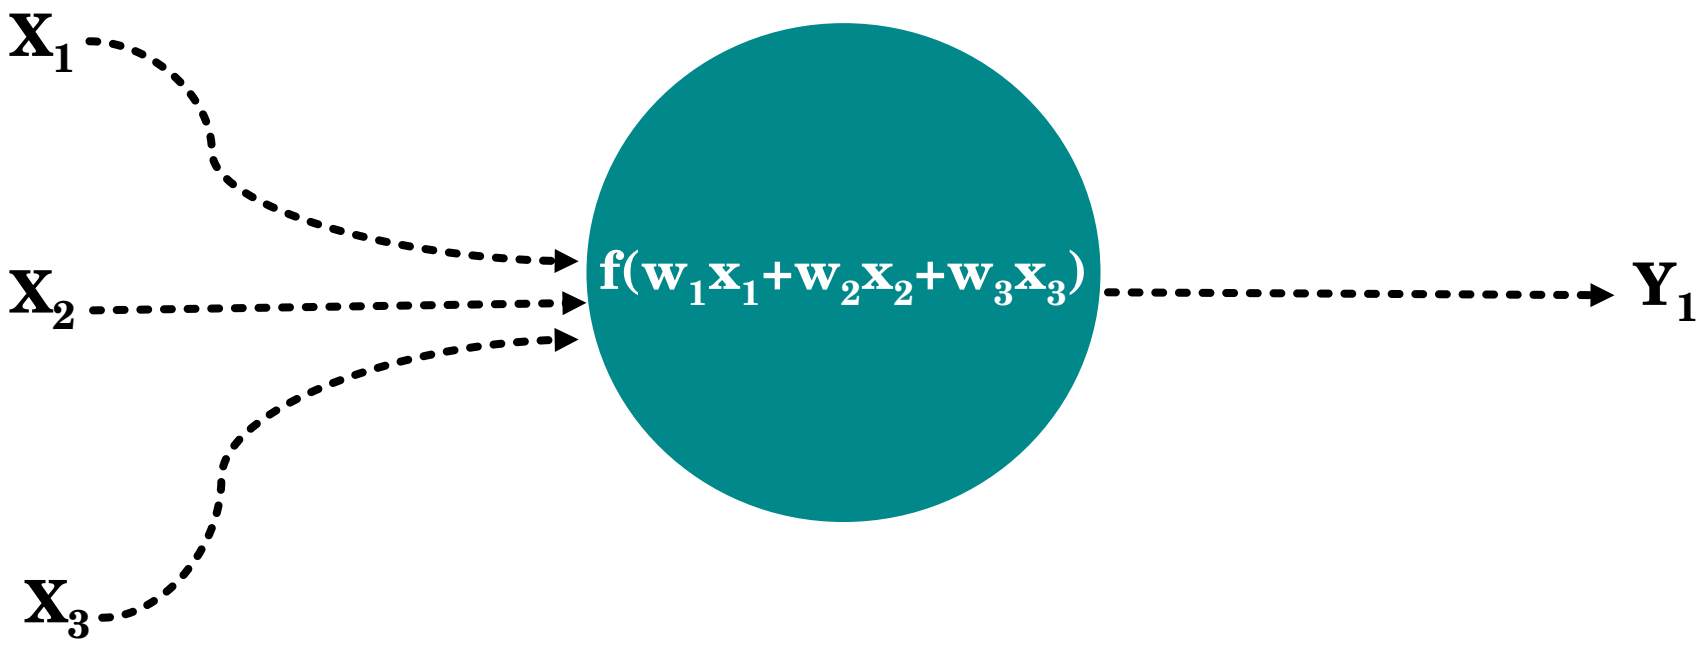

2. ¿Como la representamos?

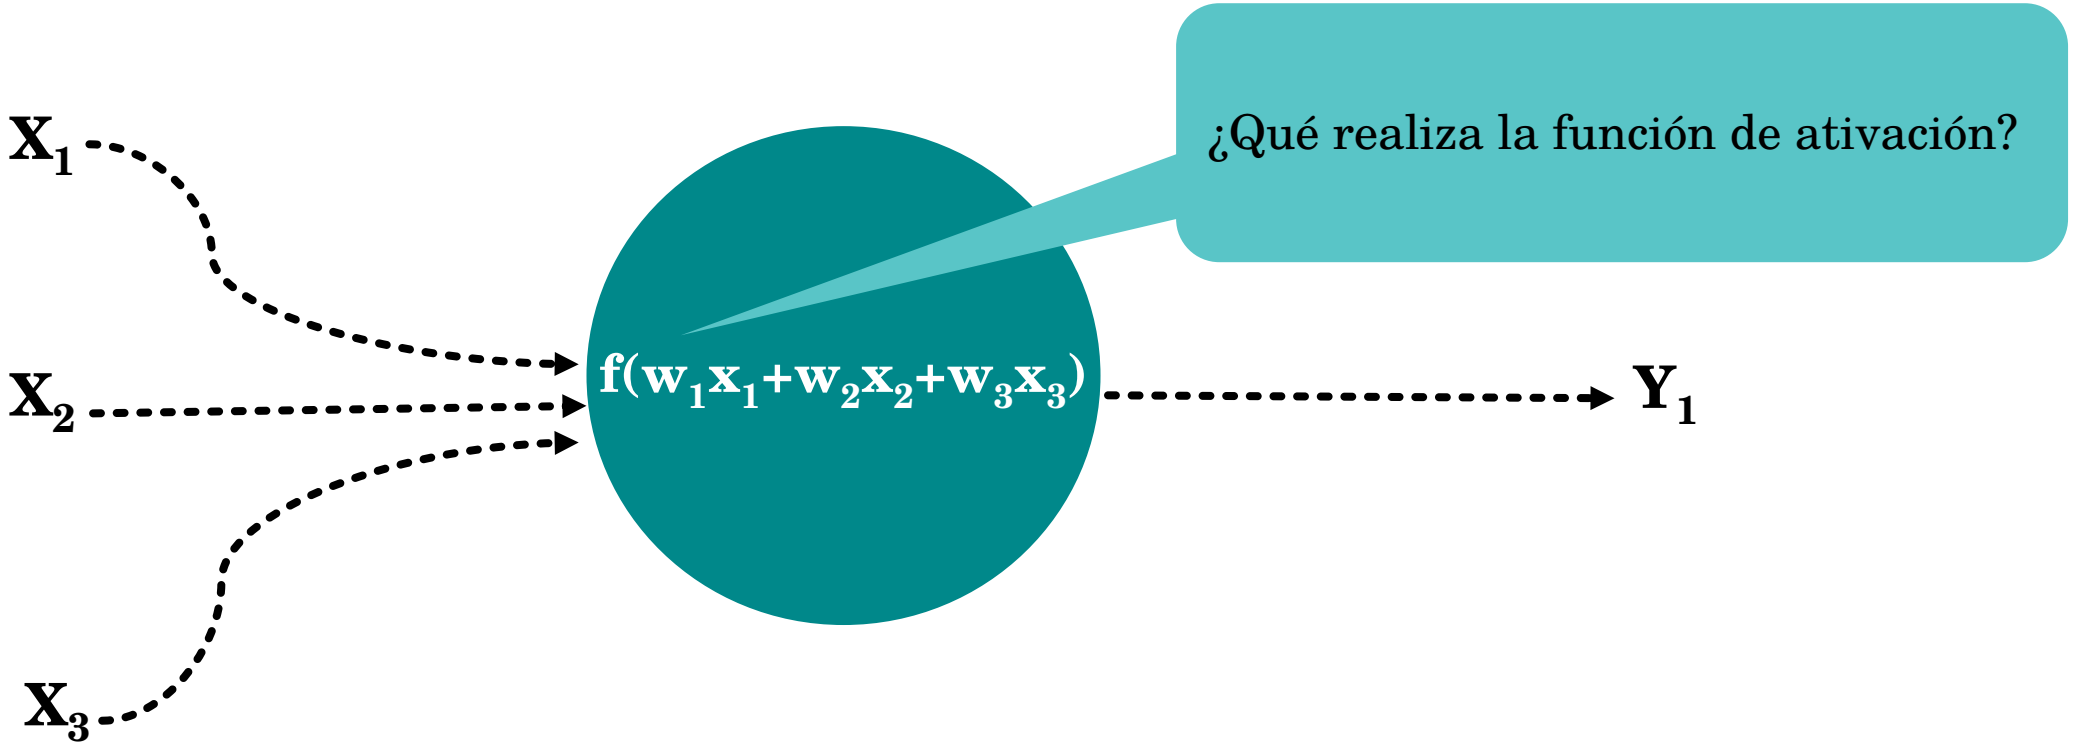

2. ¿Como la representamos?

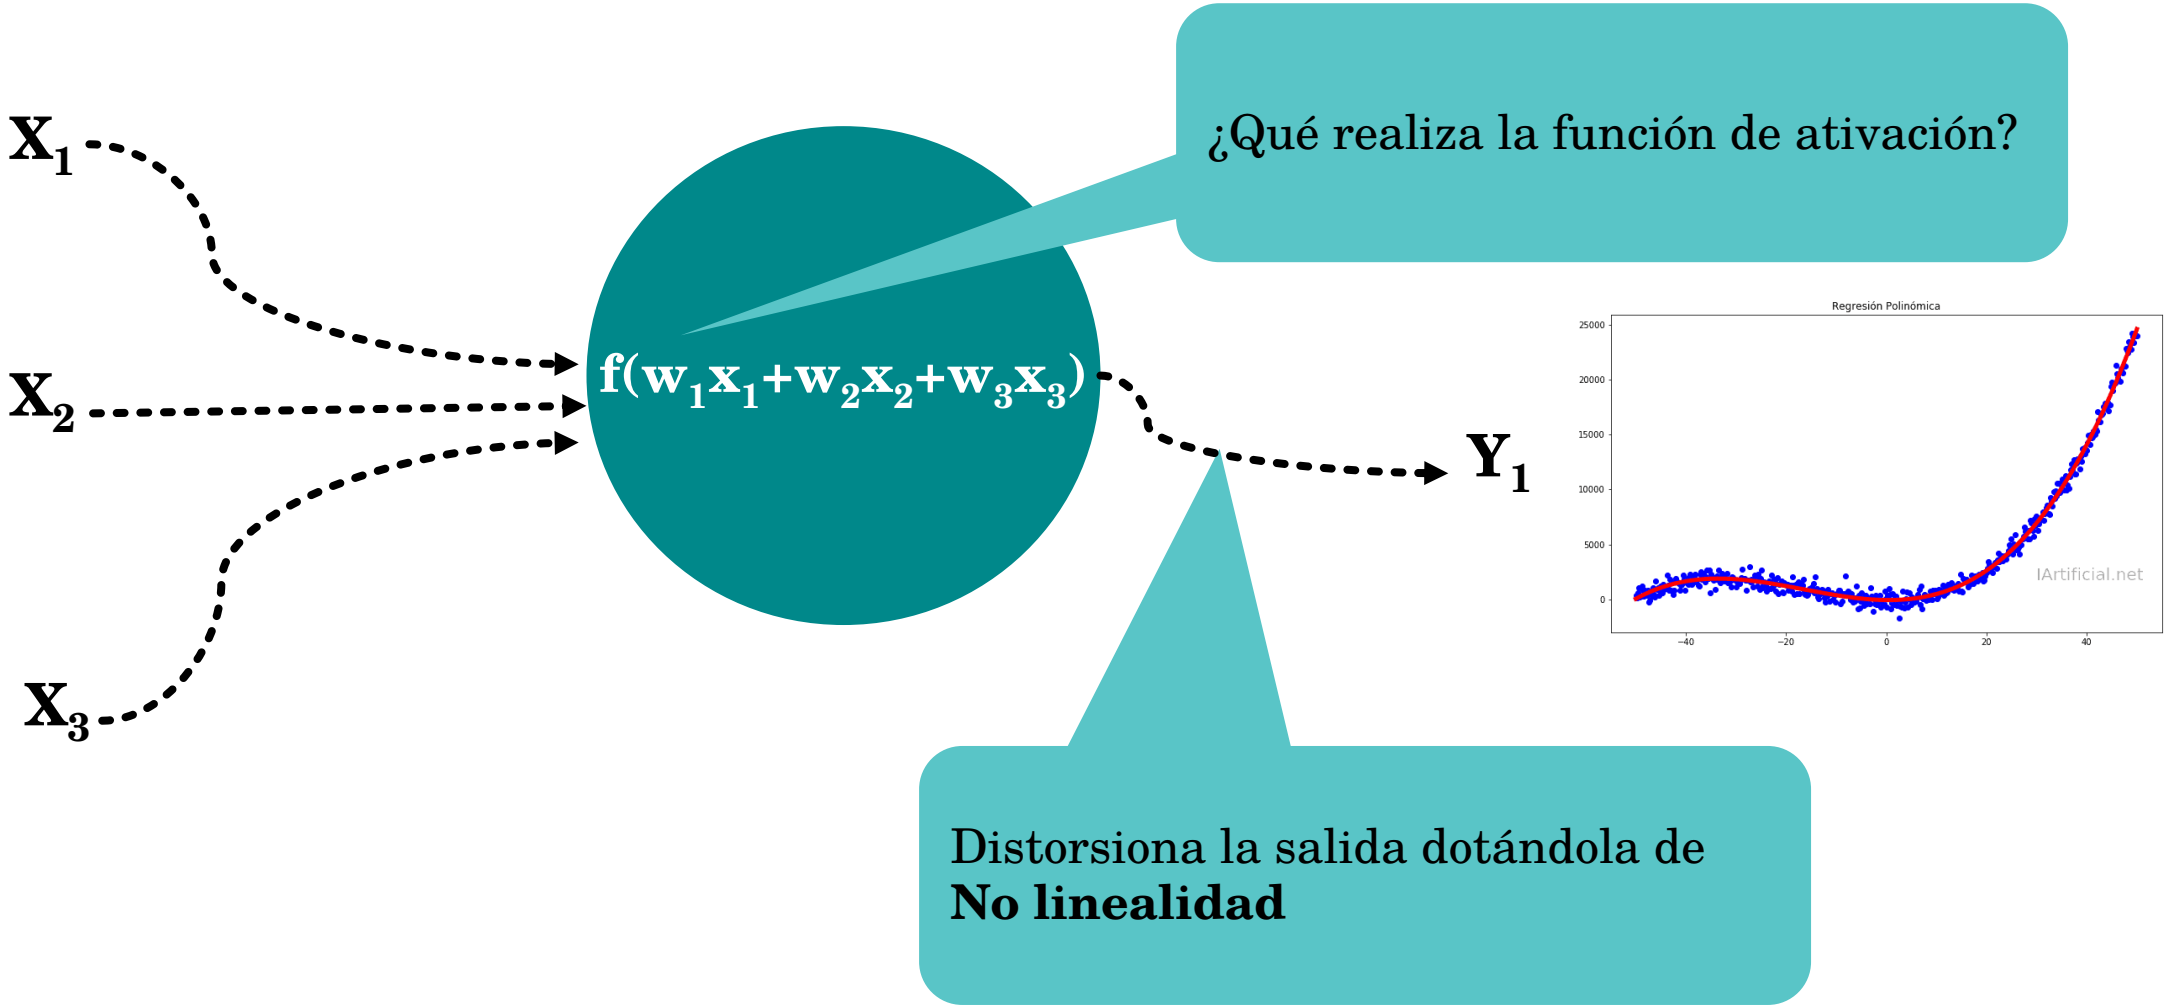

Cómo opera el MLP

ETS de Ingeniería Informática

UNED

1. Problema

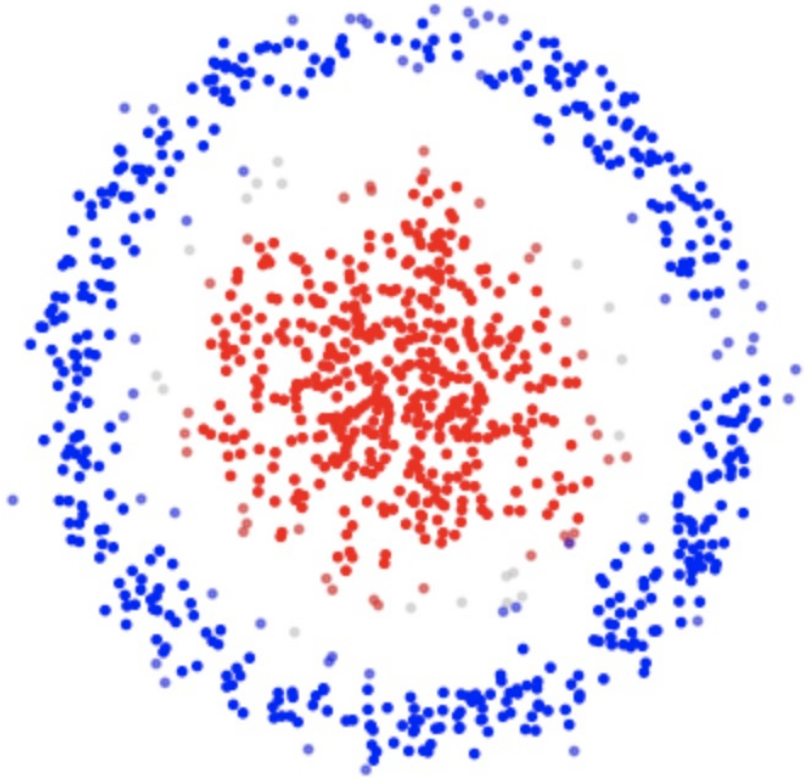

1. Problema

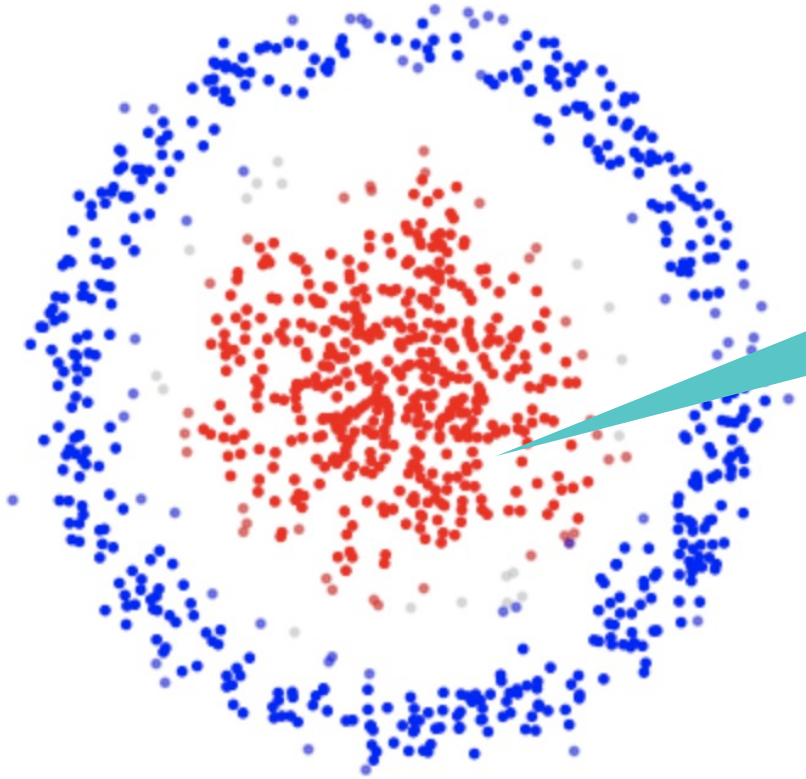

¿Cómo ver geométricamente el efecto de una función de activación?

2. Función de activación binaria

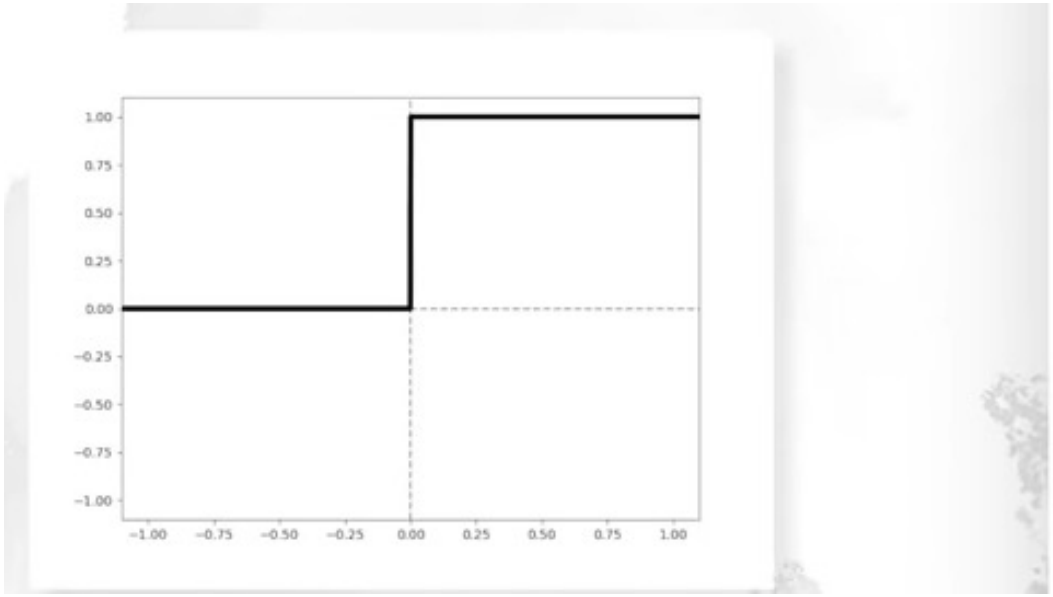

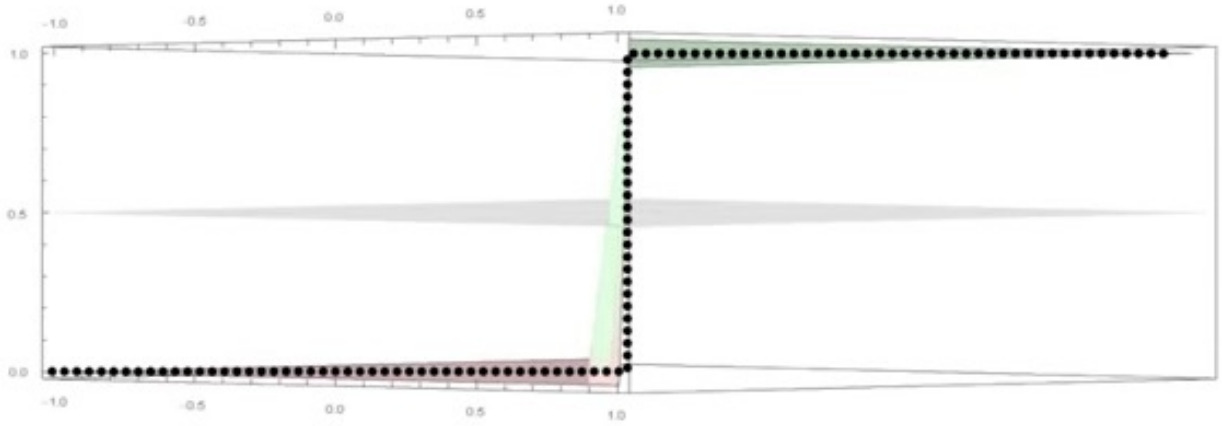

2. Función de activación binaria

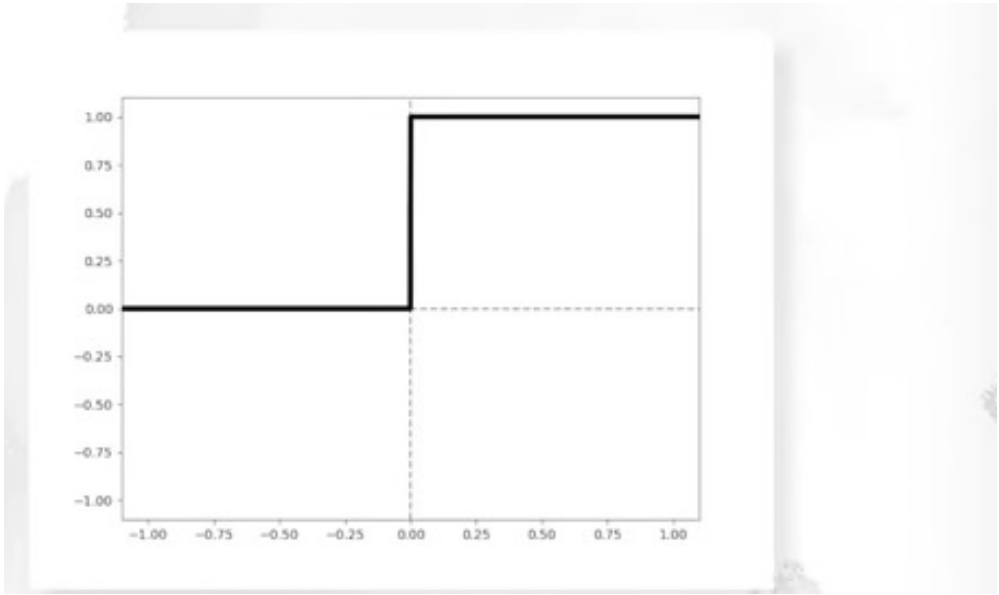

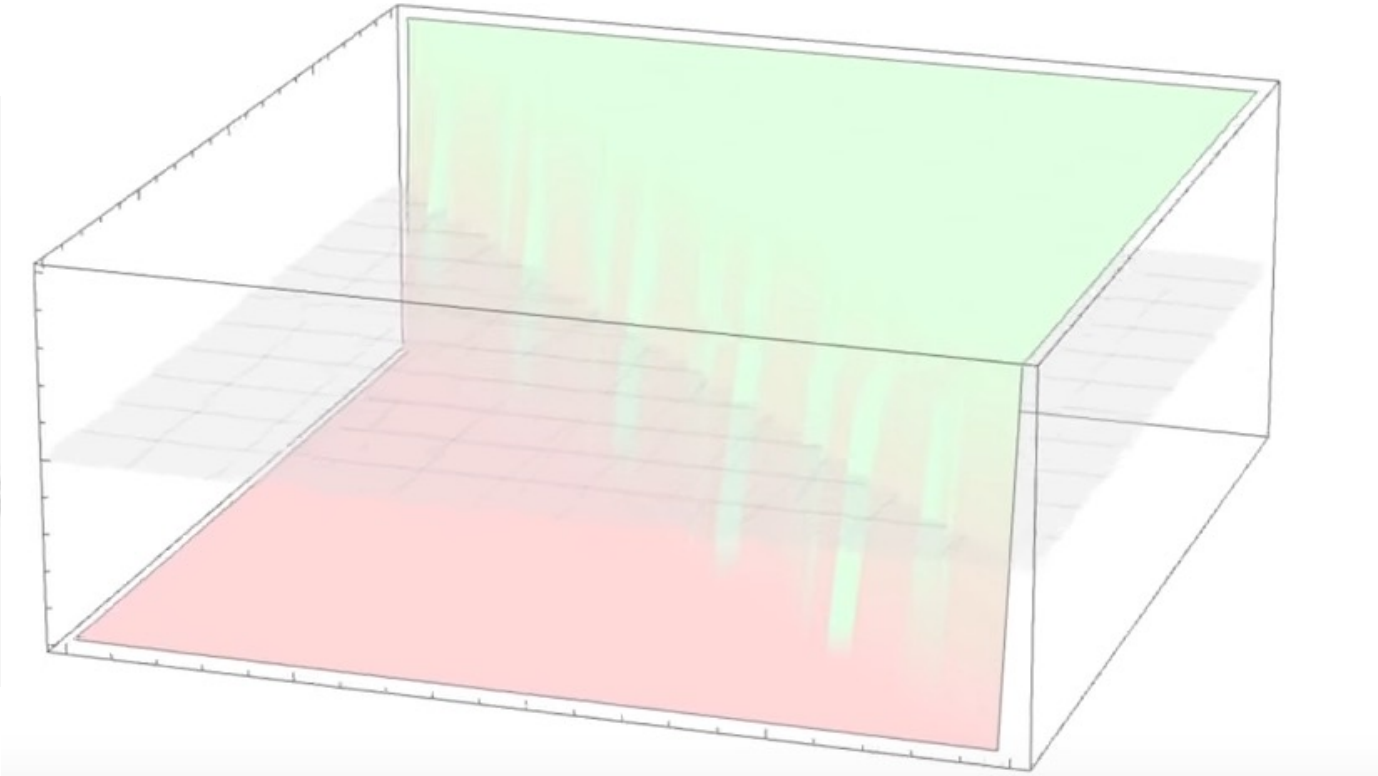

2. Función de activación binaria

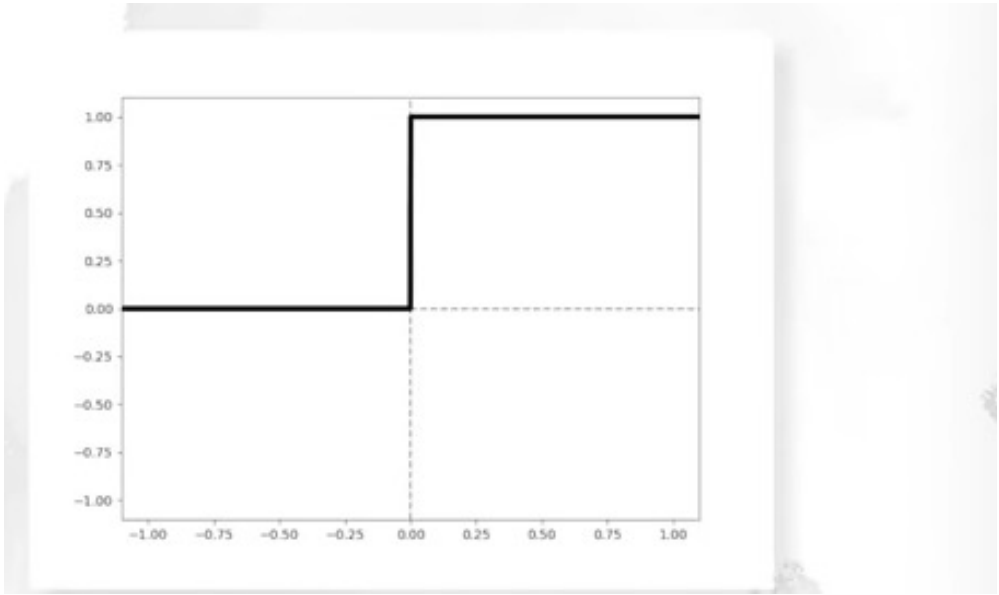

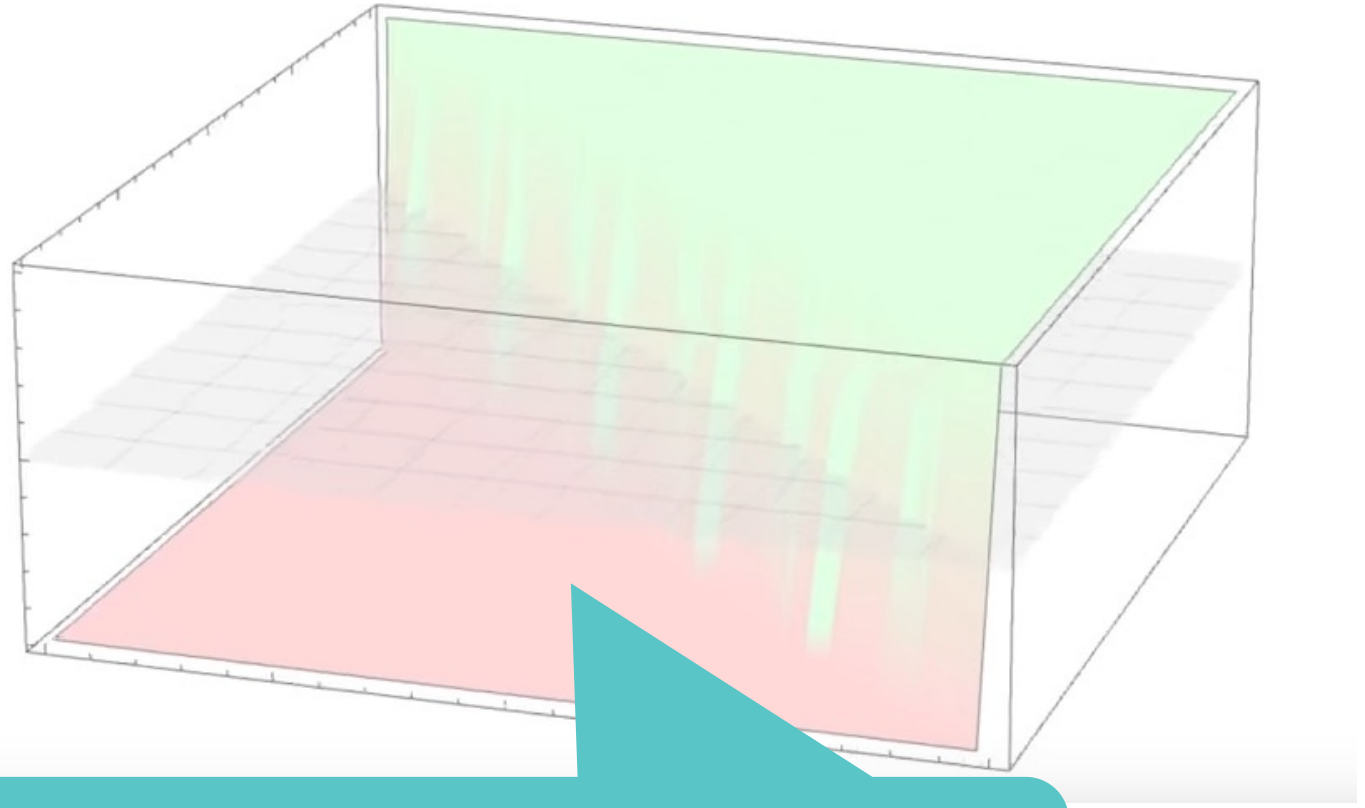

Todo lo que está encima del hiperplano será una clase y lo que está debajo otra

2. Función de activación binaria

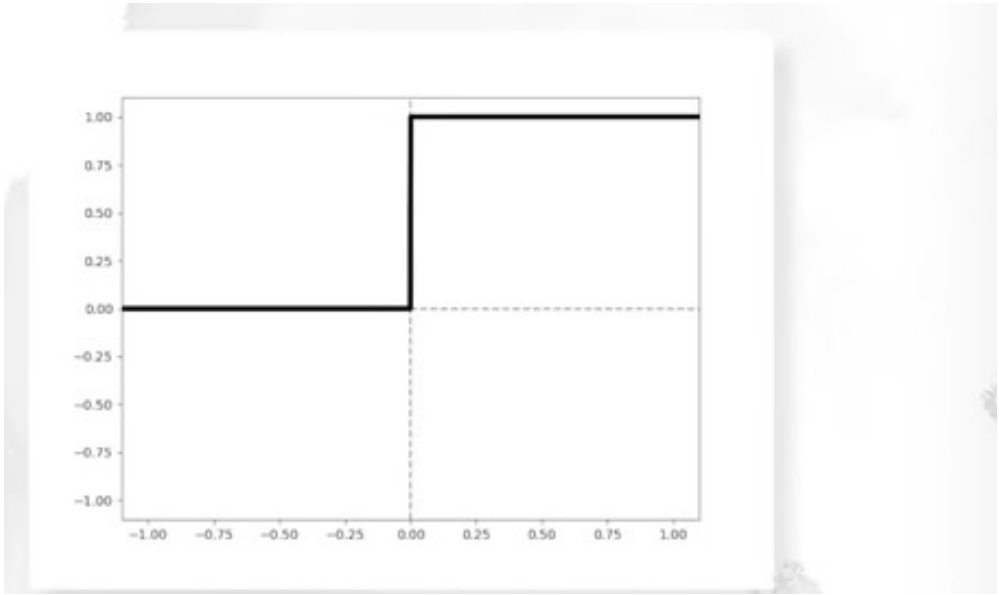

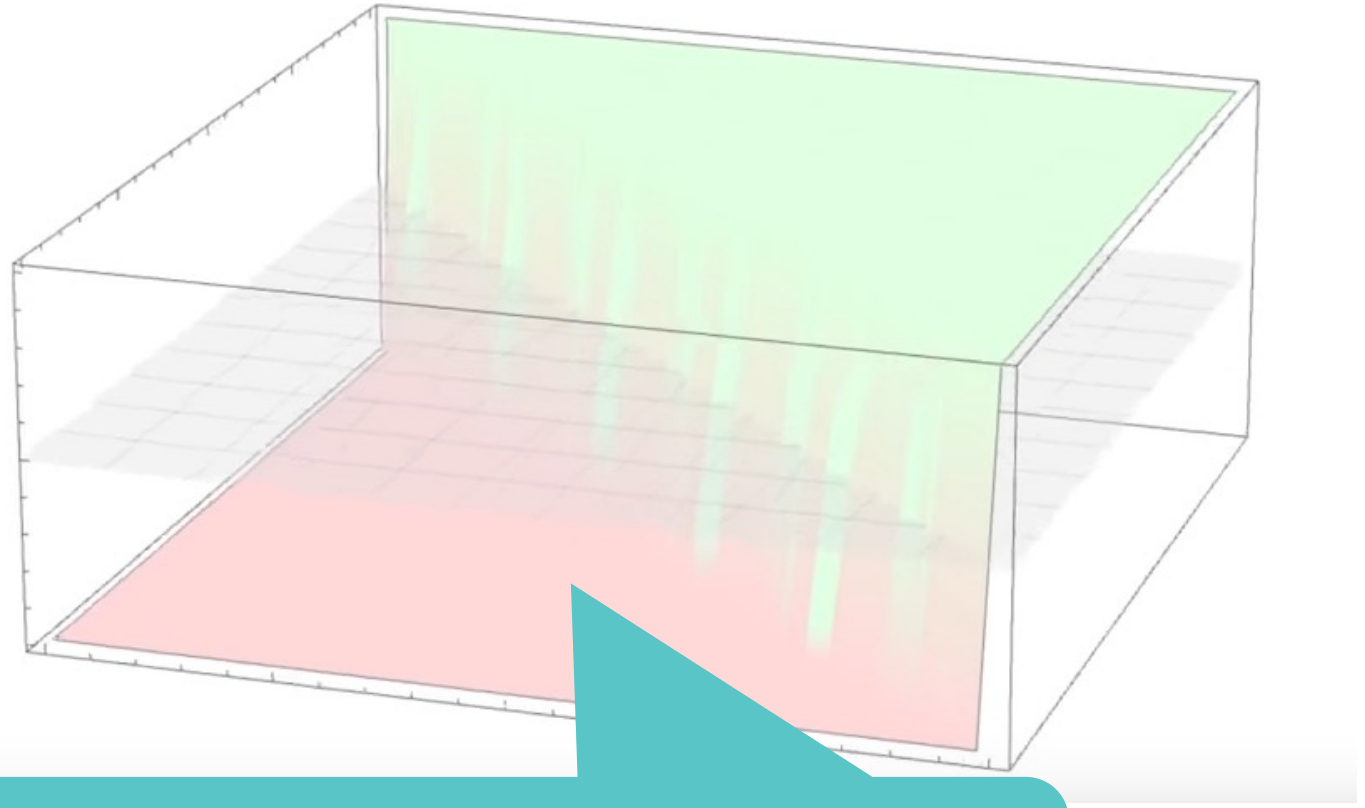

Necesitamos distorsionar la señal para acomodar el problema inicial

3. Otras Funciones de activación

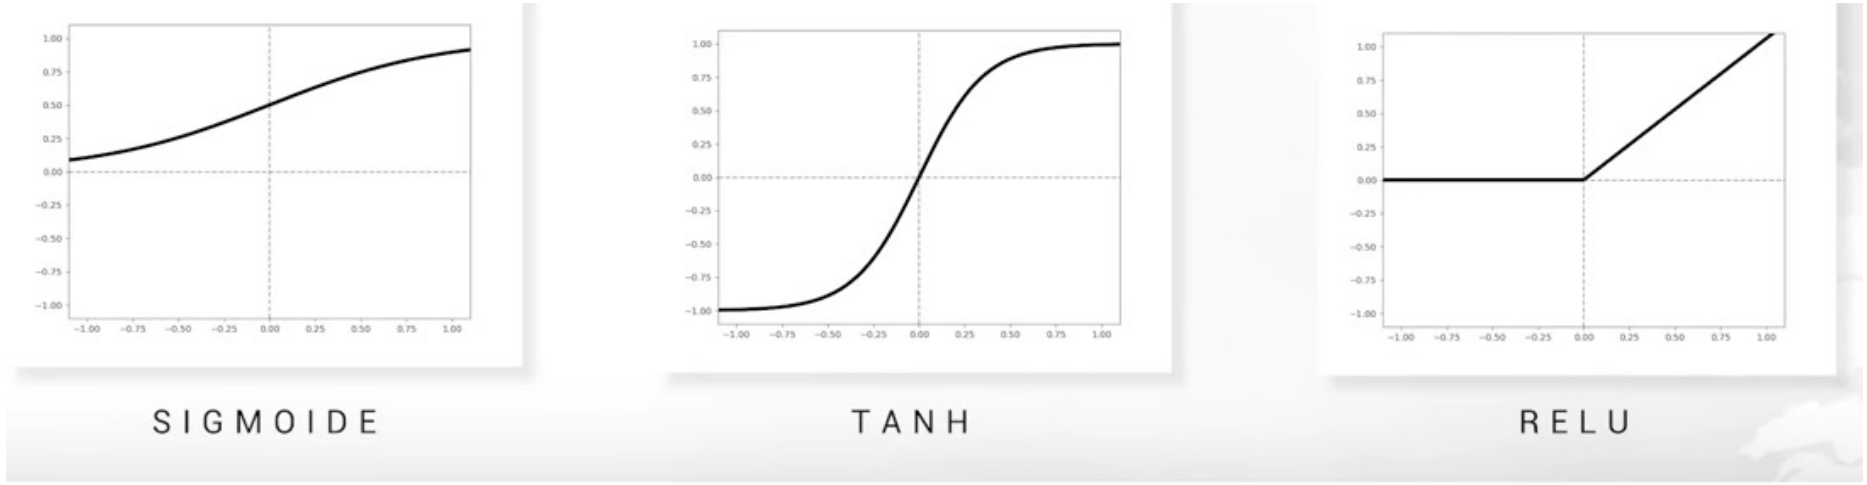

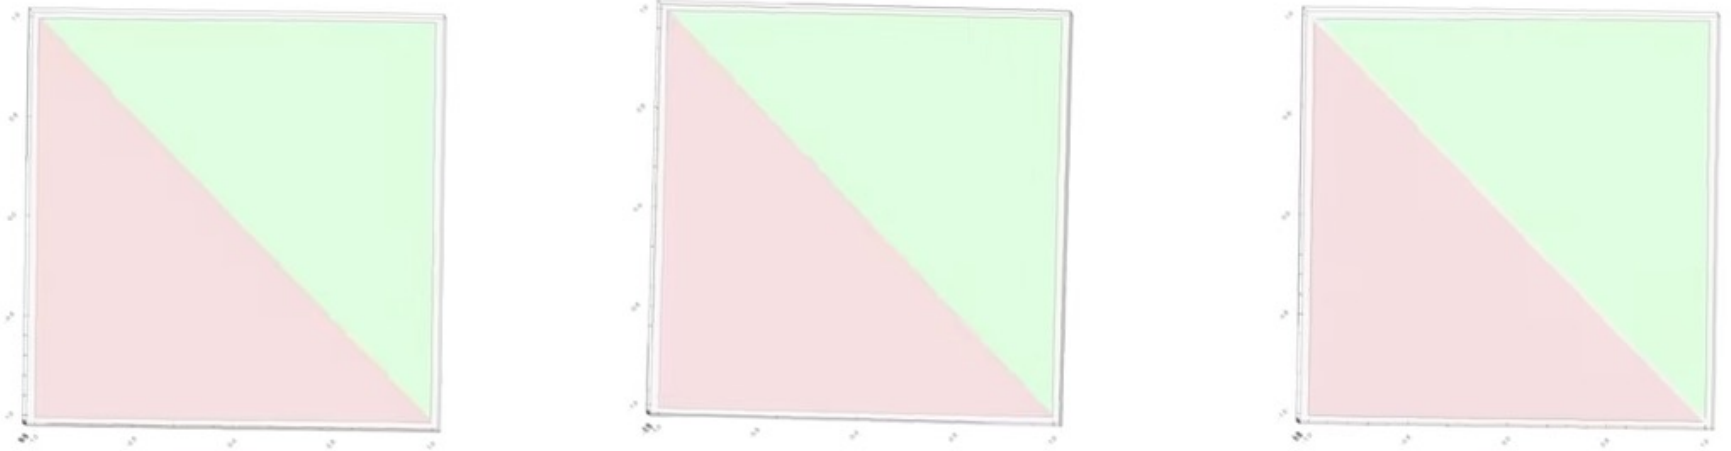

3. Otras Funciones de activación

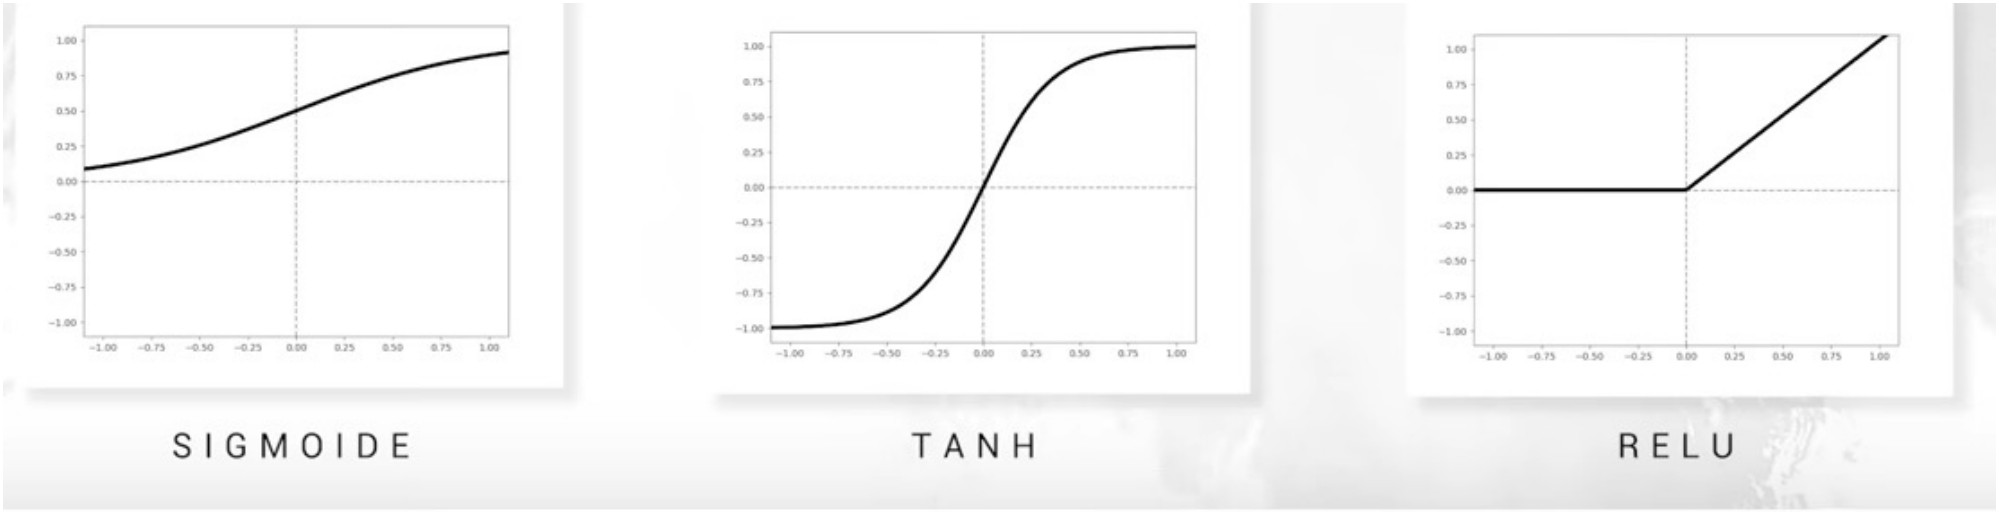

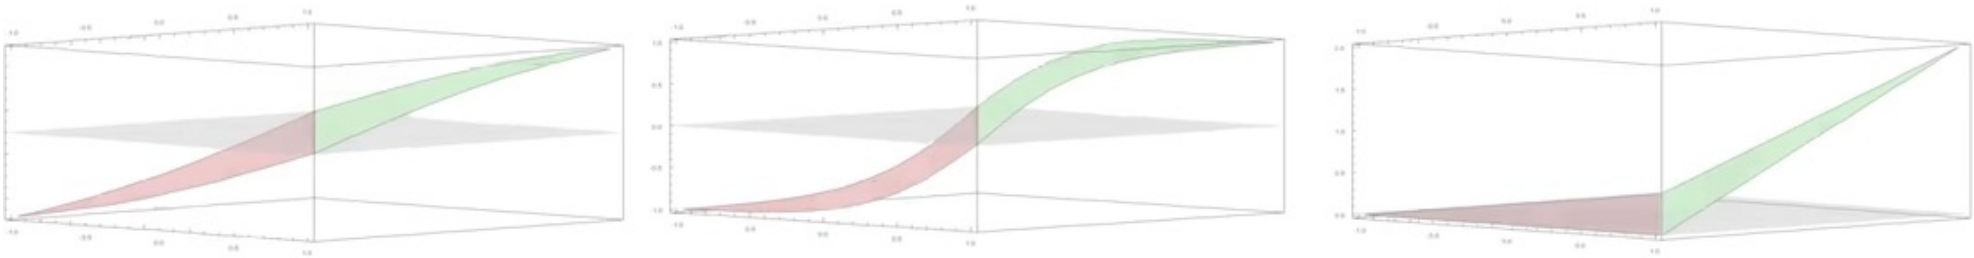

3. Otras Funciones de activación

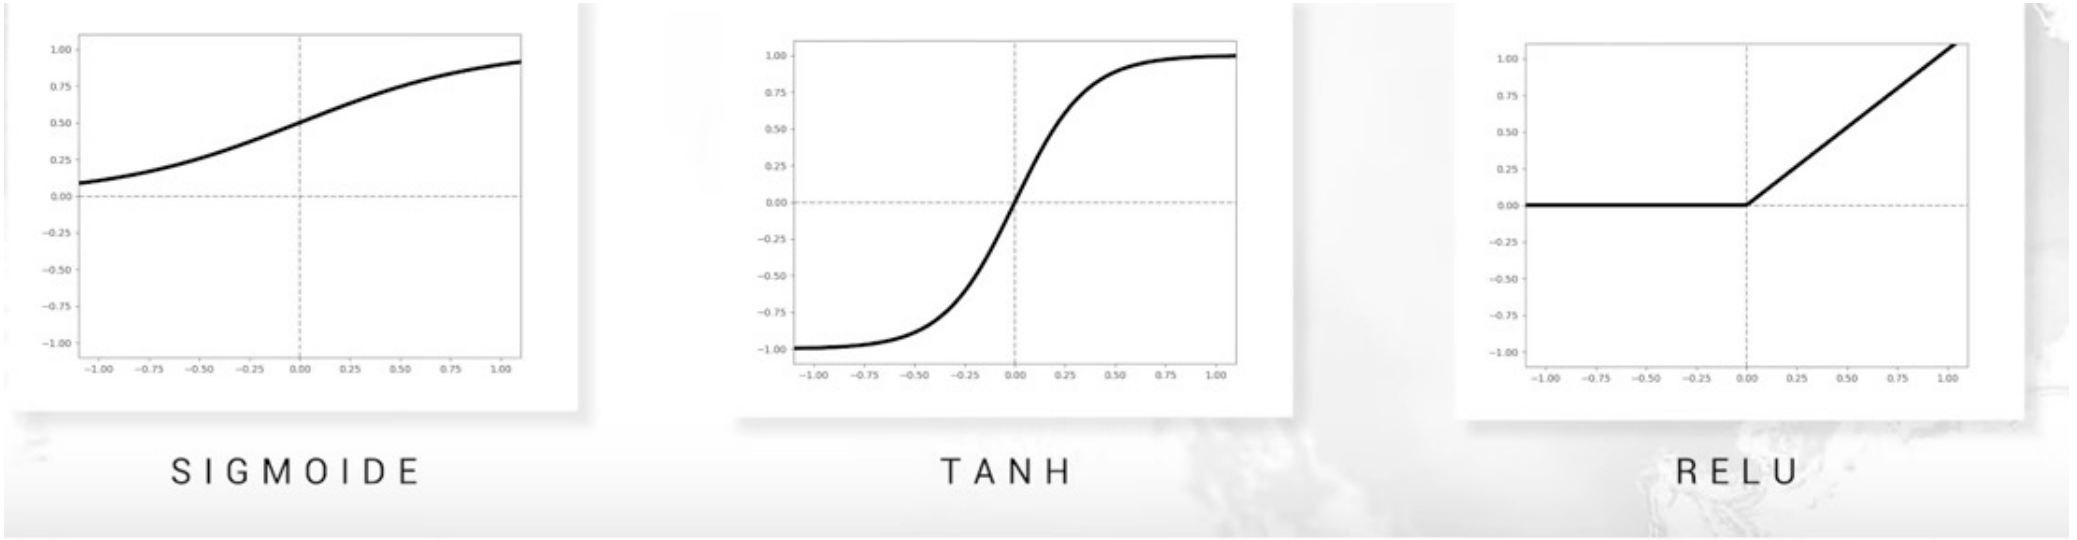

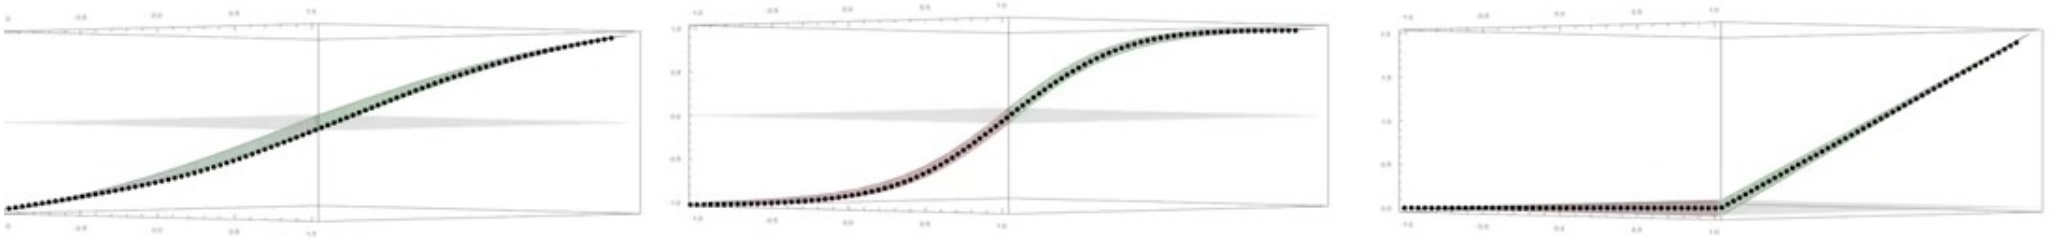

3. Otras Funciones de activación

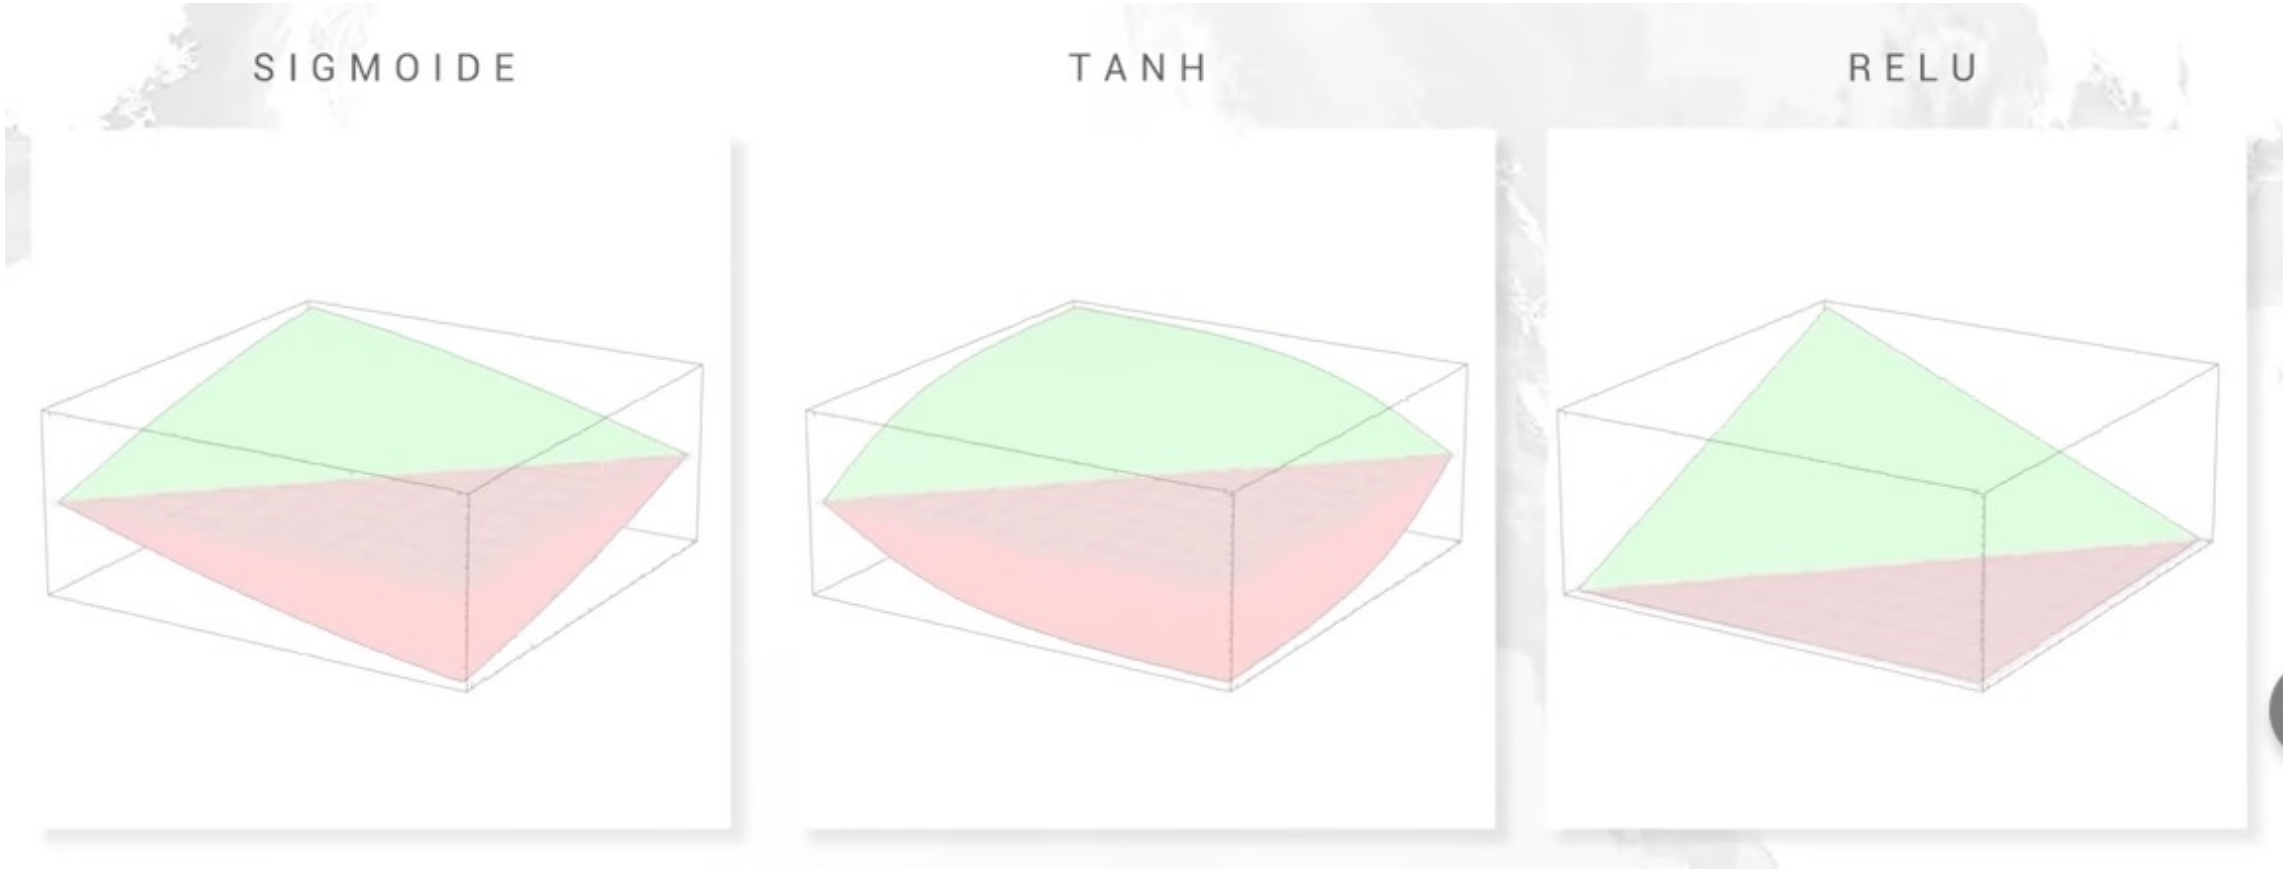

3. Otras Funciones de activación

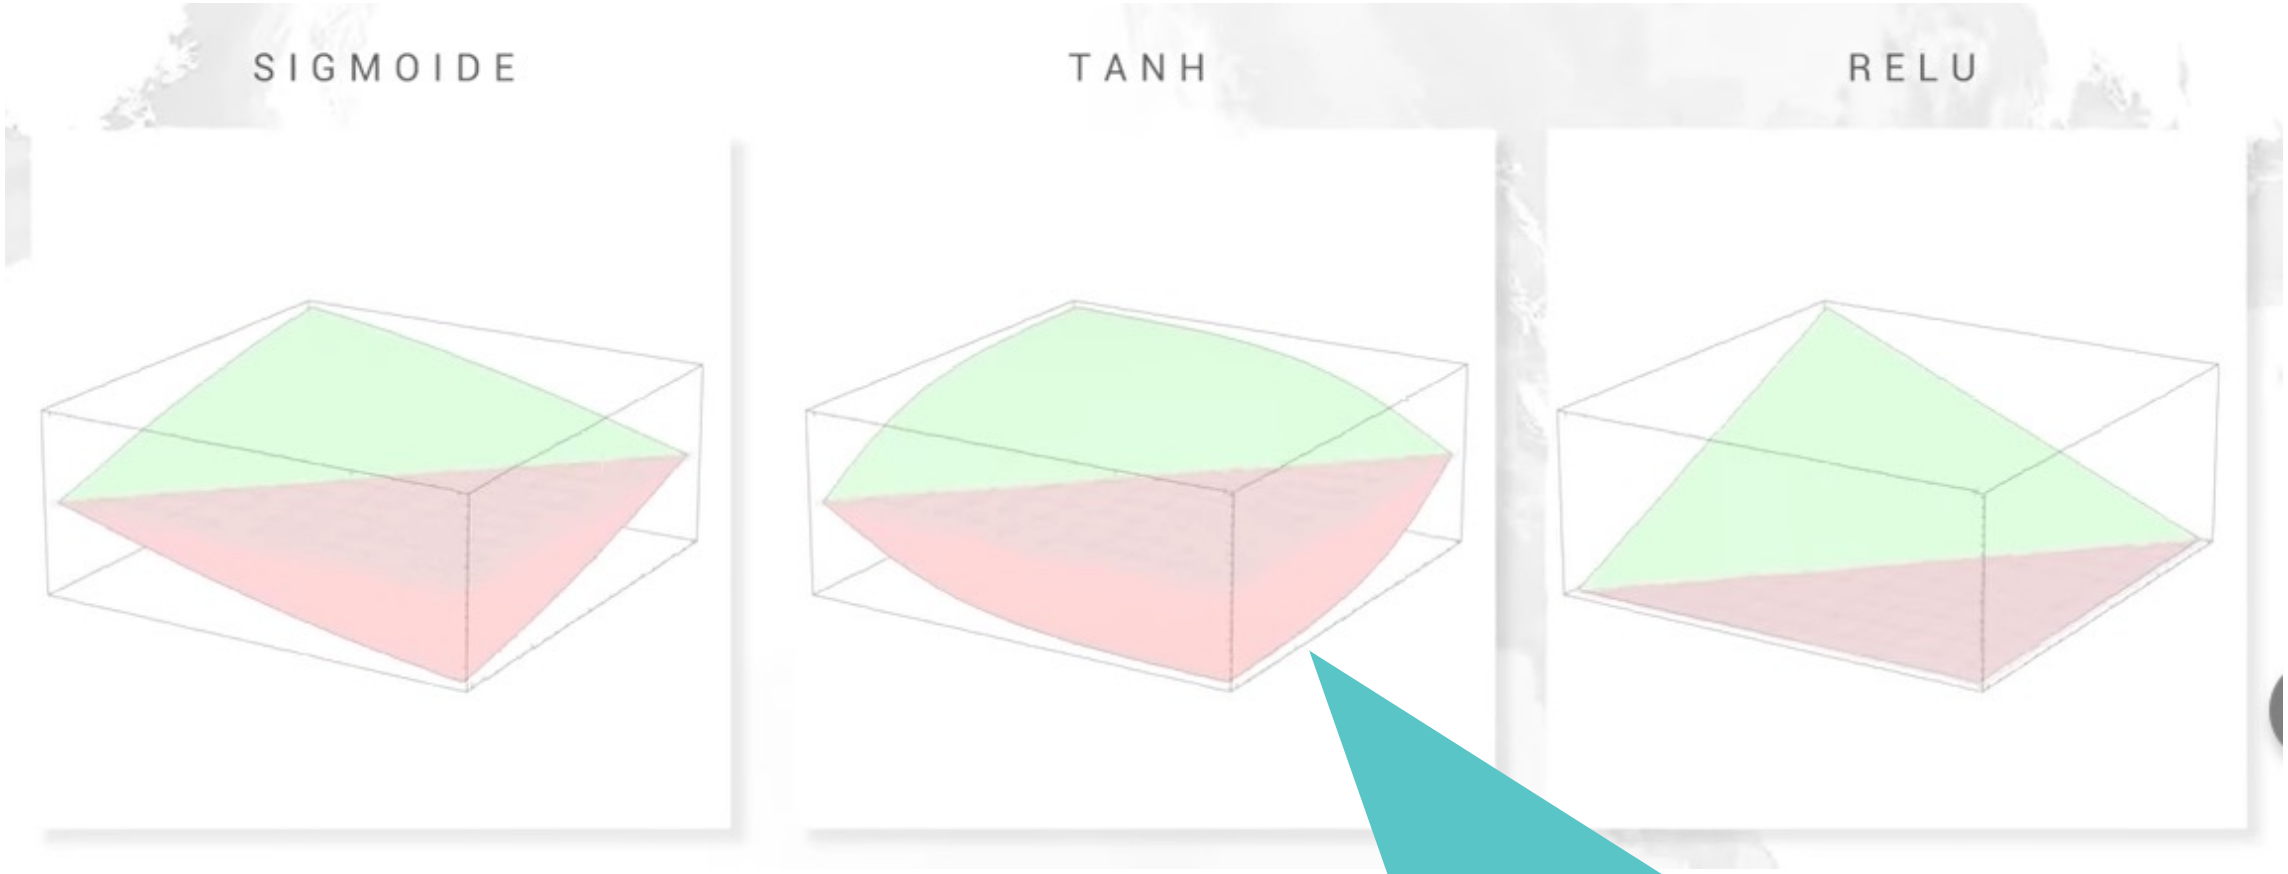

Pero la frontera no deja de ser una
Línea recta, ¿Cómo resolvemos el problema?

4. Encontrar el hiperplano

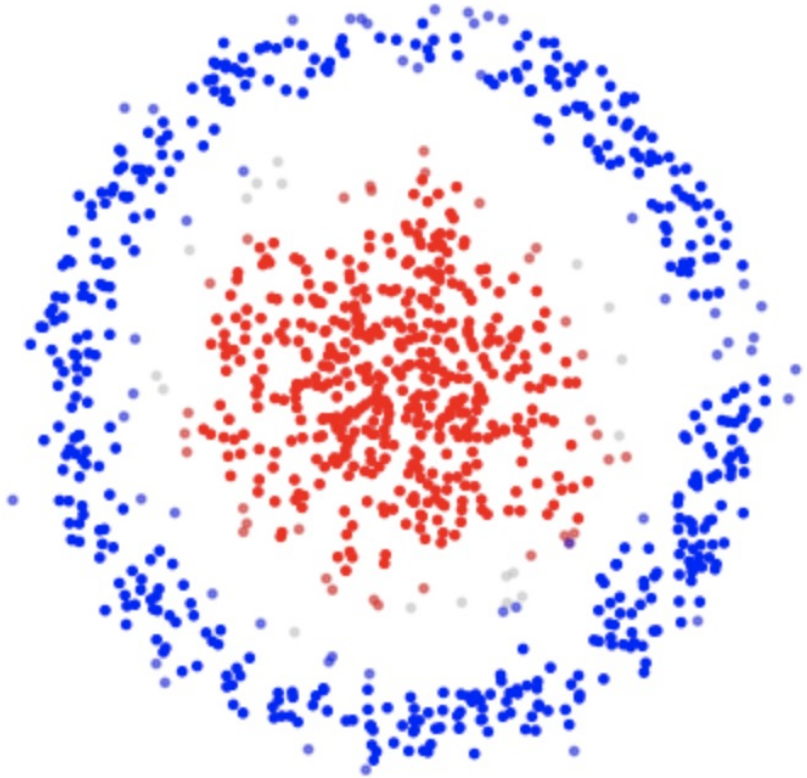

4. Encontrar el hiperplano

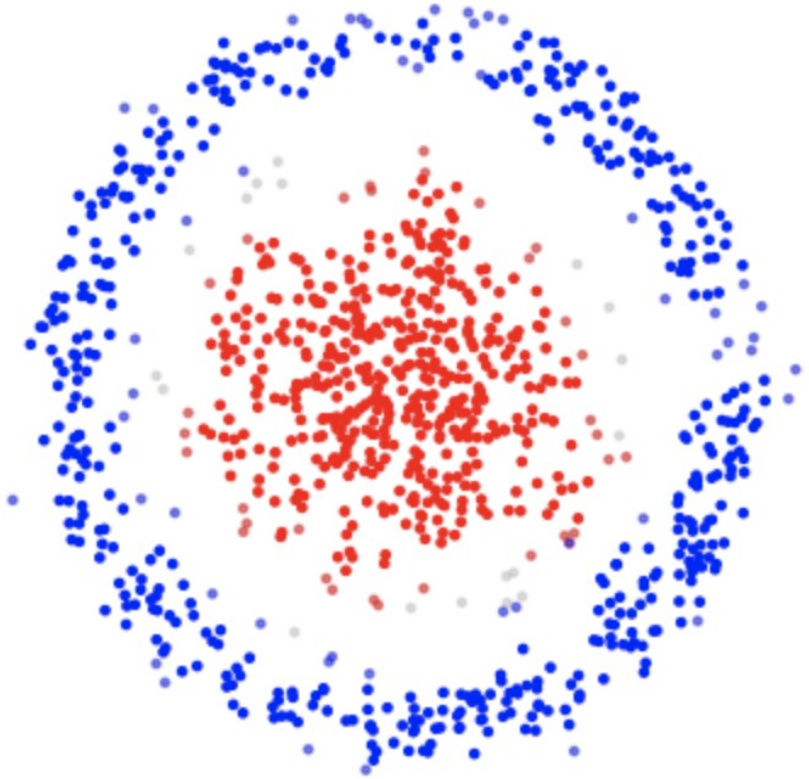

4. Encontrar el hiperplano

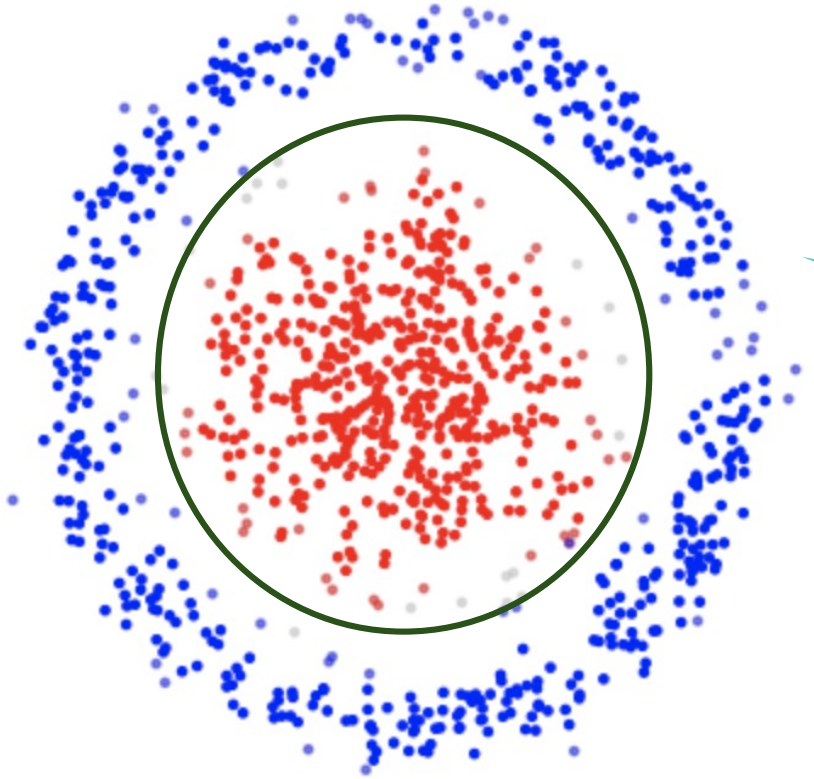

¿Cómo trazar esa frontera?

4. Encontrar el hiperplano

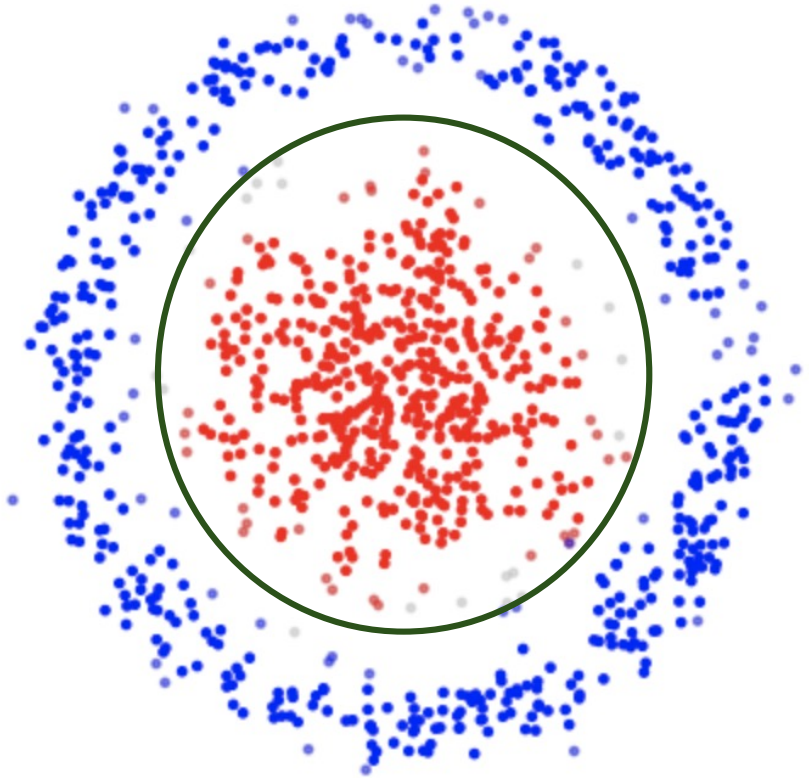

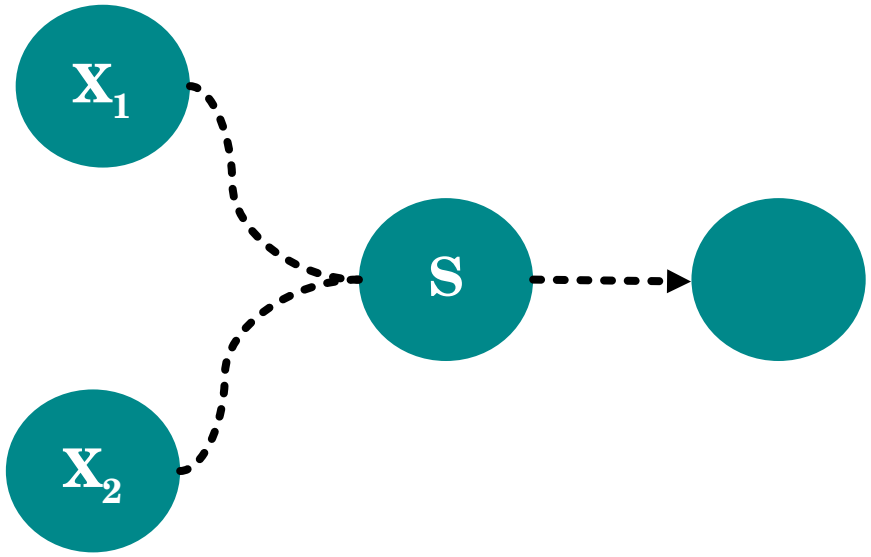

4. Encontrar el hiperplano

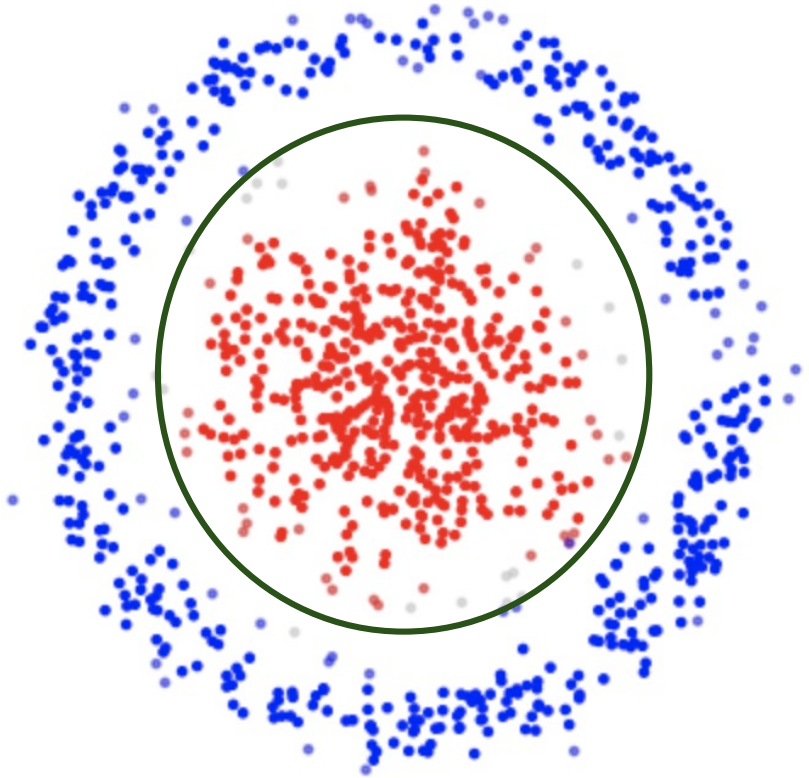

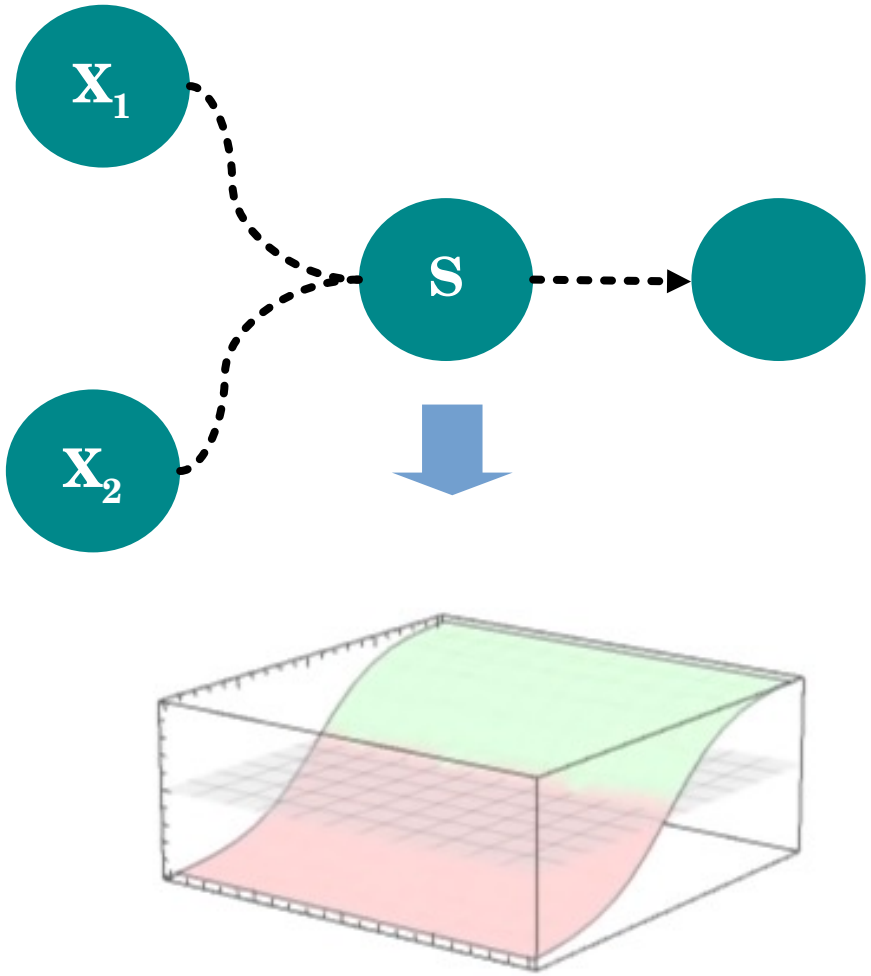

4. Encontrar el hiperplano

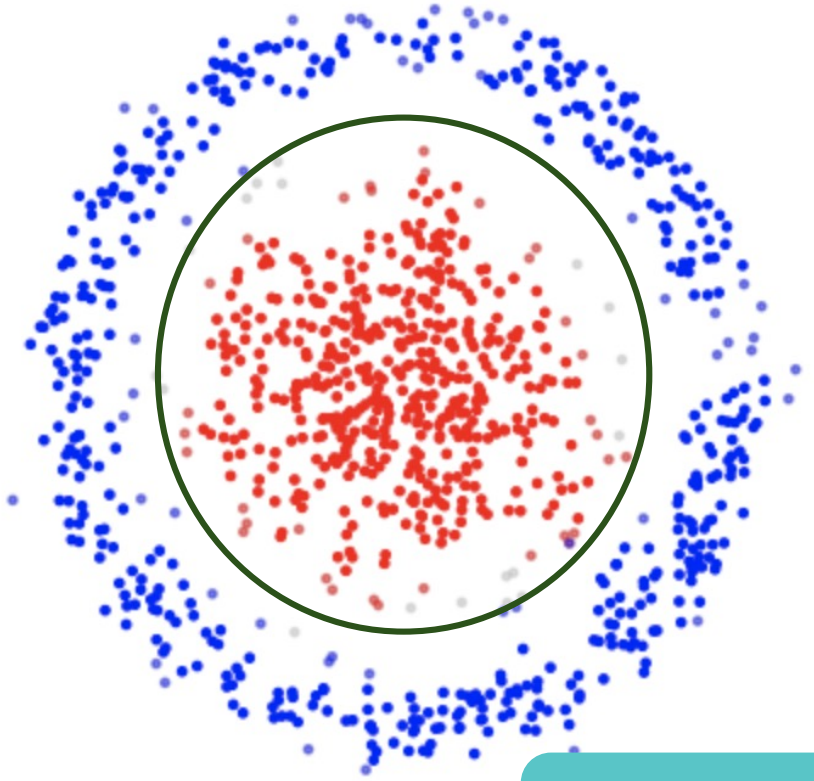

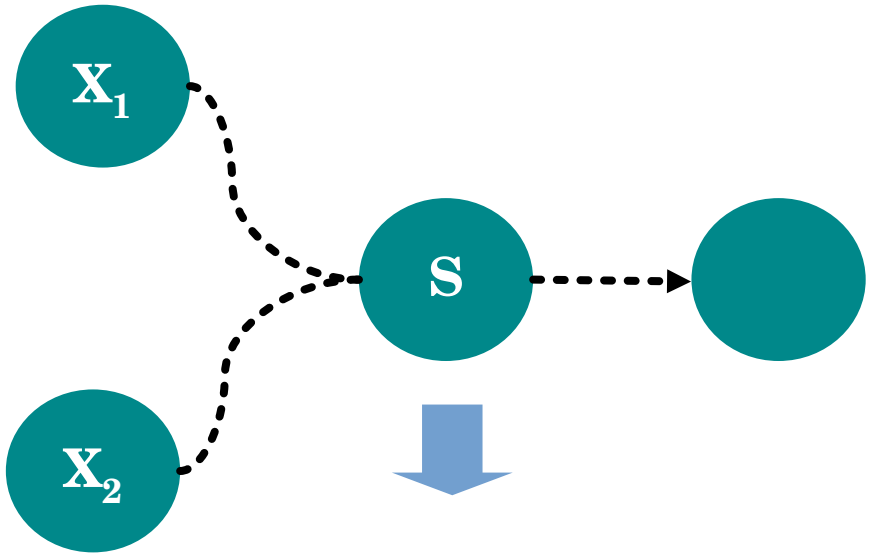

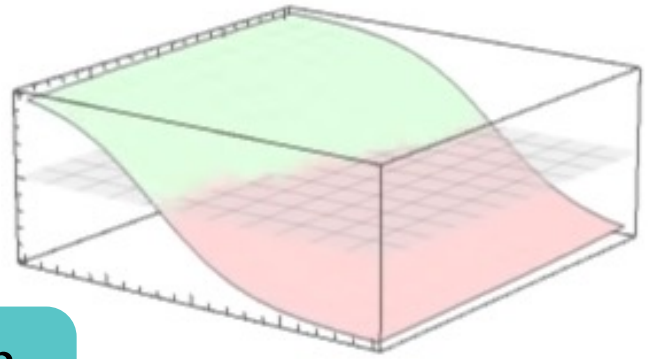

Puede cambiar la orientación cambiando parámetros

4. Encontrar el hiperplano

Aumentamos las neuronas

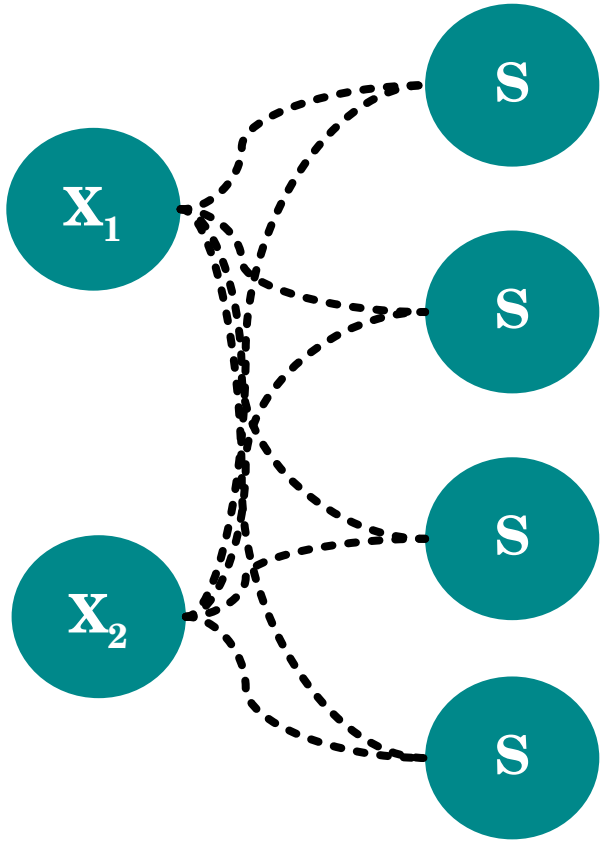

4. Encontrar el hiperplano

Aumentamos las neuronas

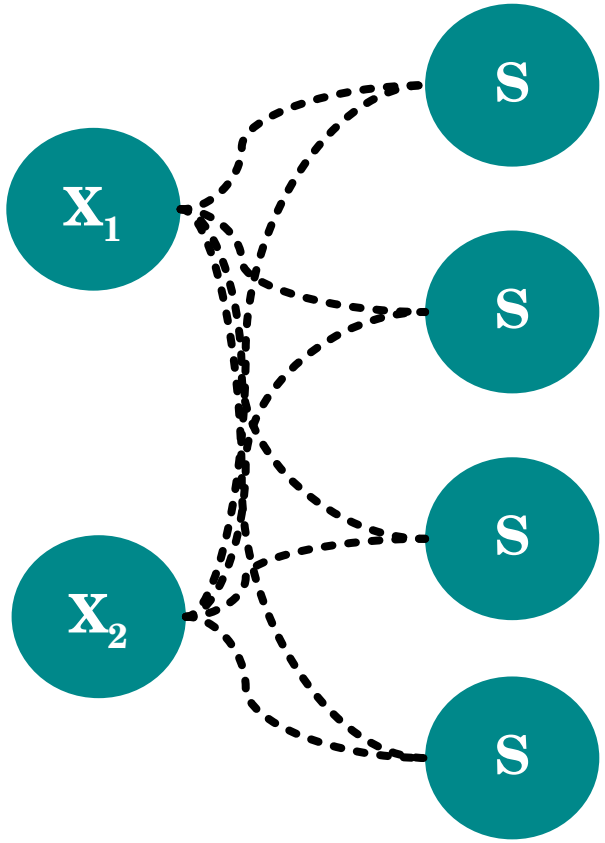

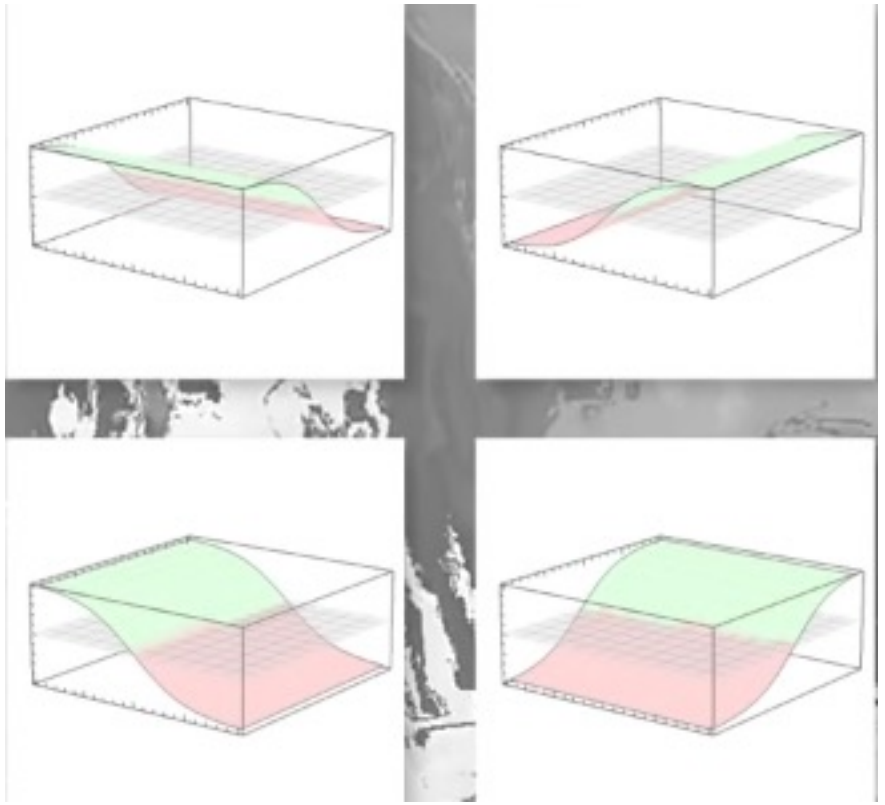

4. Encontrar el hiperplano

Aumentamos las neuronas

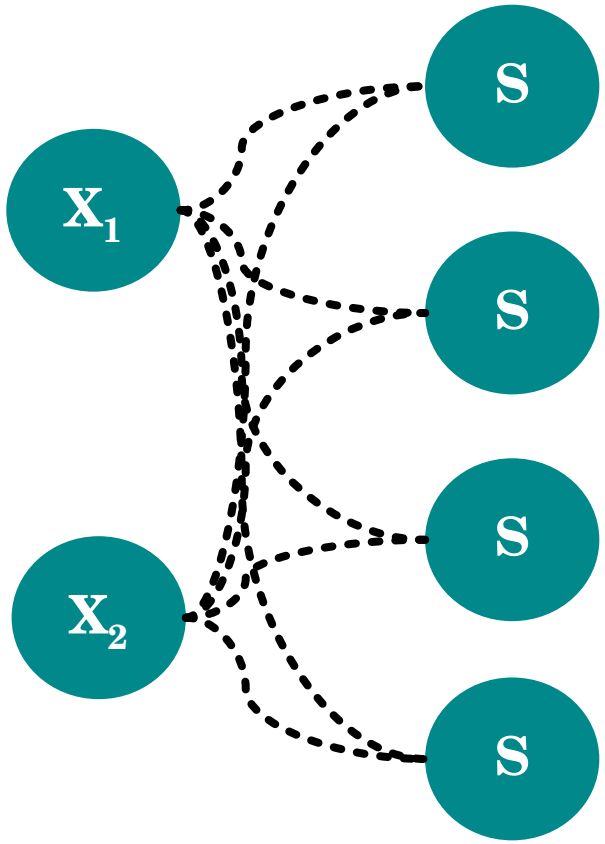

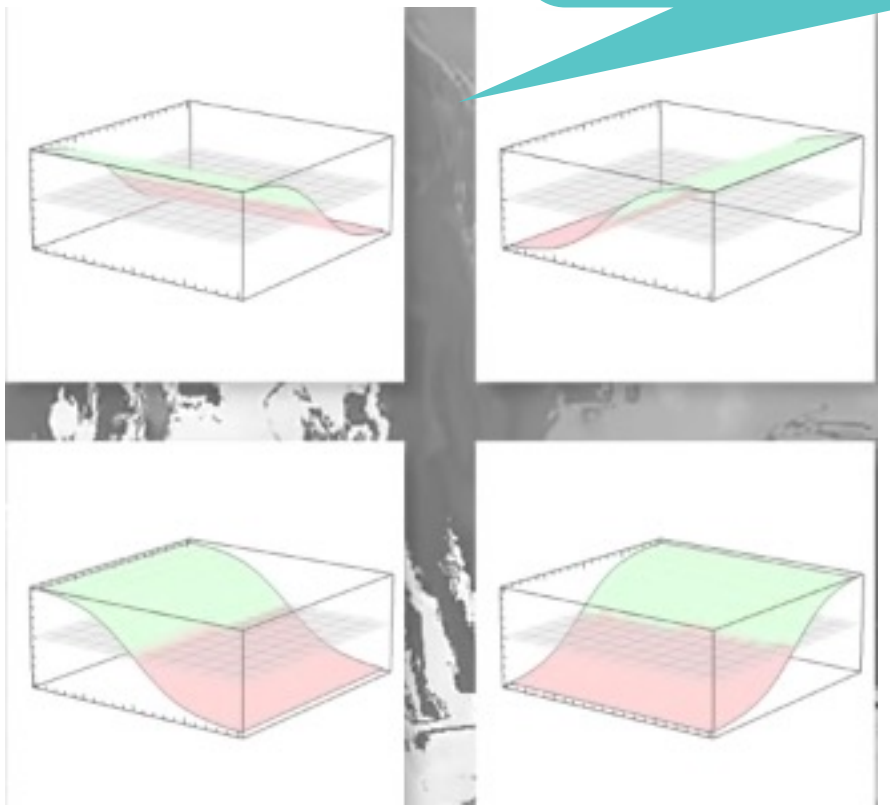

Pero cada una tiene una orientación diferente
Las juntamos...

4. Encontrar el hiperplano

Segunda capa oculta

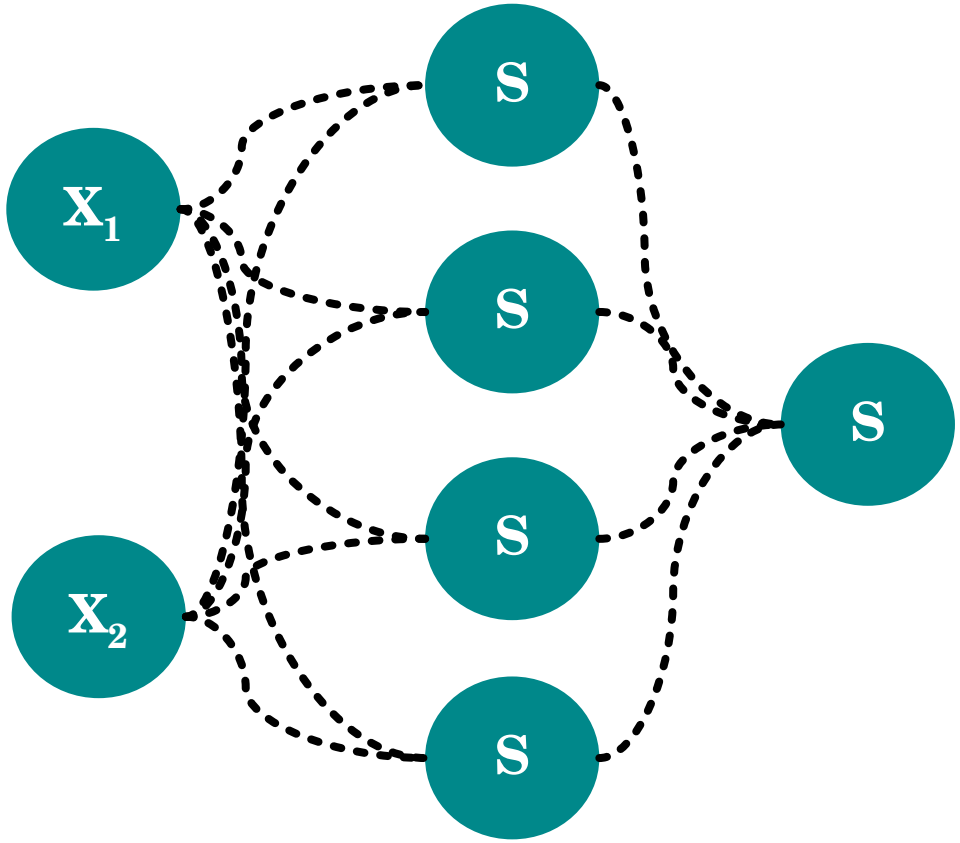

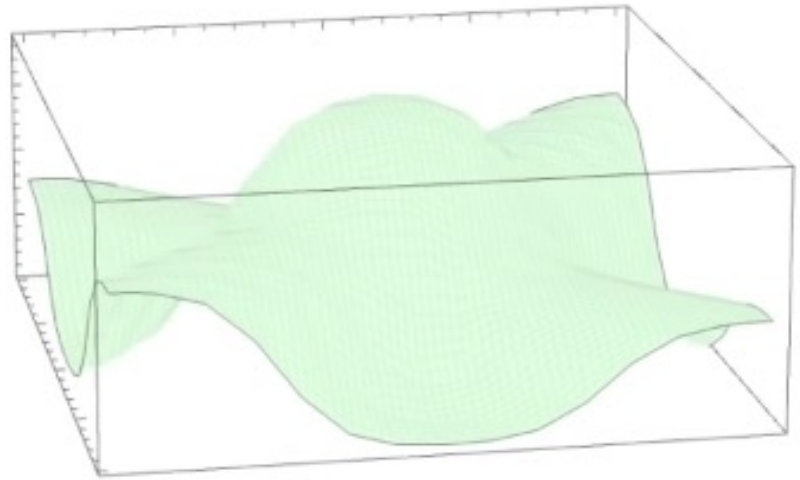

4. Encontrar el hiperplano

Segunda capa oculta

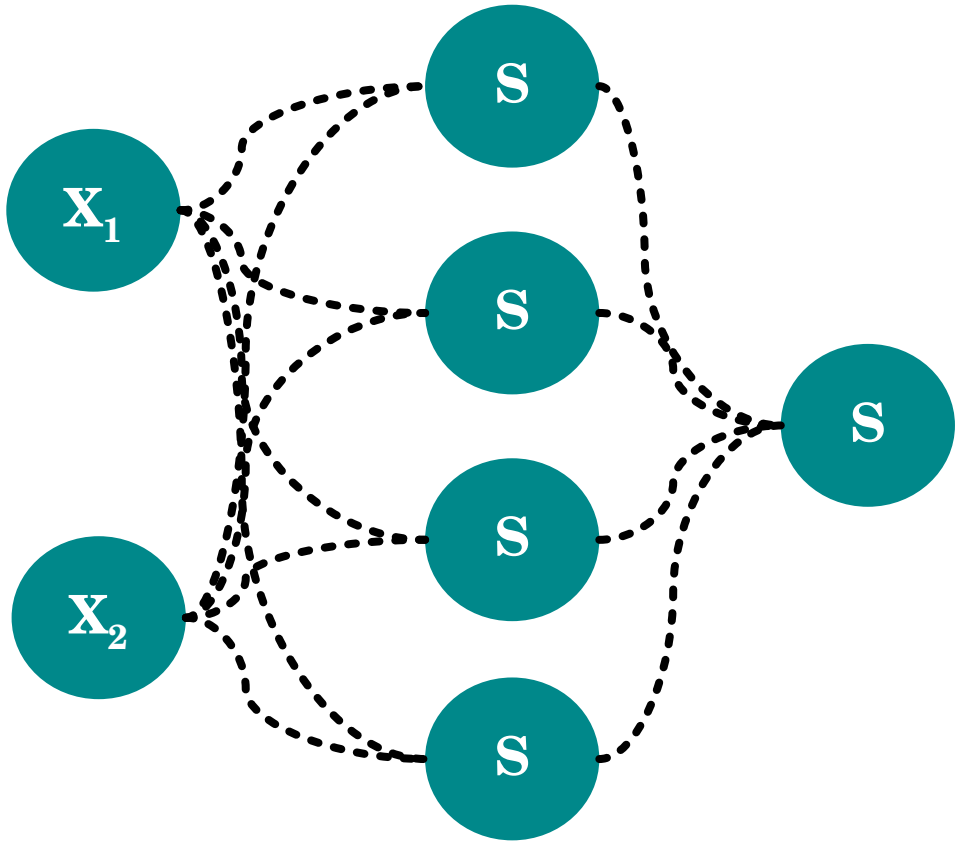

Obtenemos la superposción geométrica con un “bulto” al medio

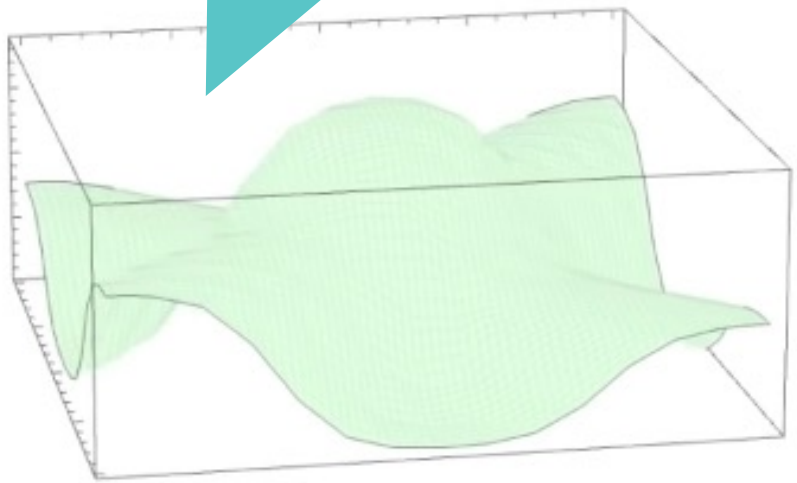

4. Encontrar el hiperplano

Segunda capa oculta

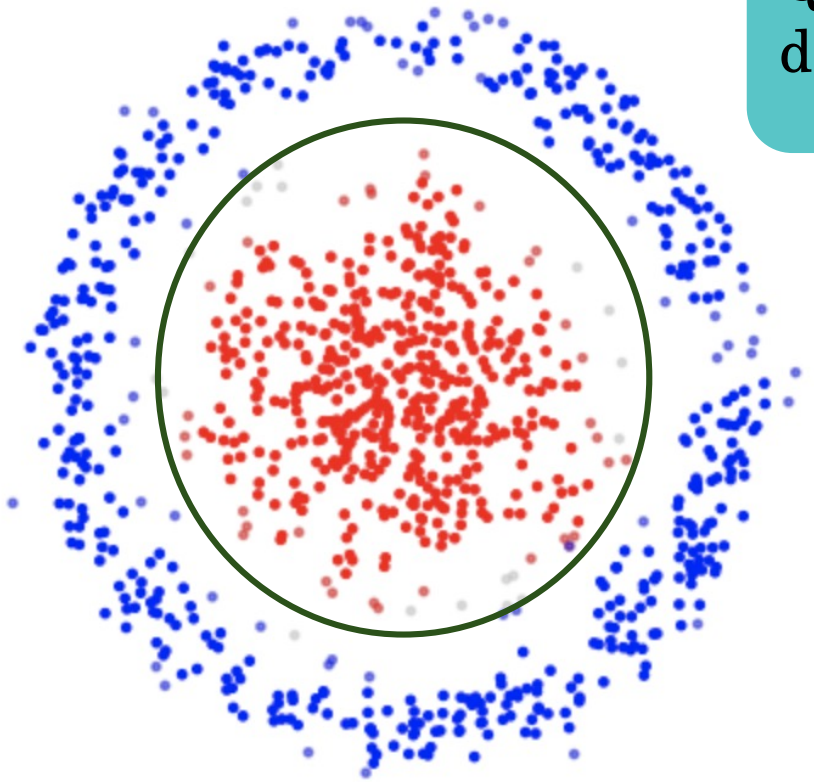

Qué podemos “cortar” con la intersección del hiperplano con la “montaña”

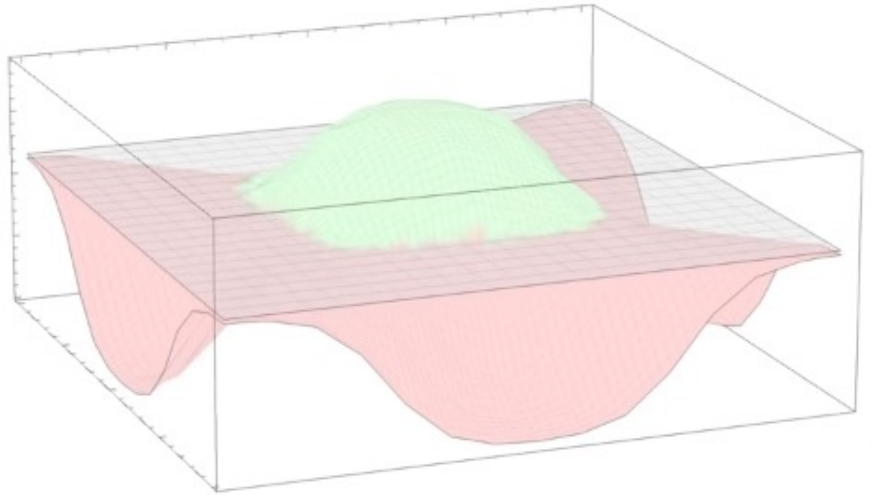

4. Encontrar el hiperplano

Segunda capa oculta

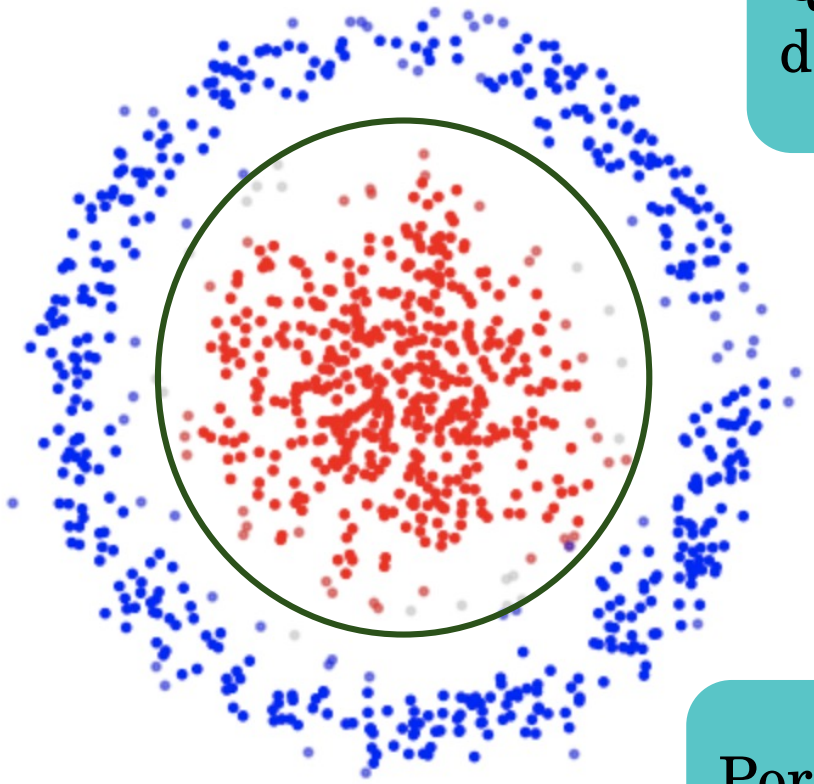

Qué podemos “cortar” con la intersección del hiperplano con la “montaña”

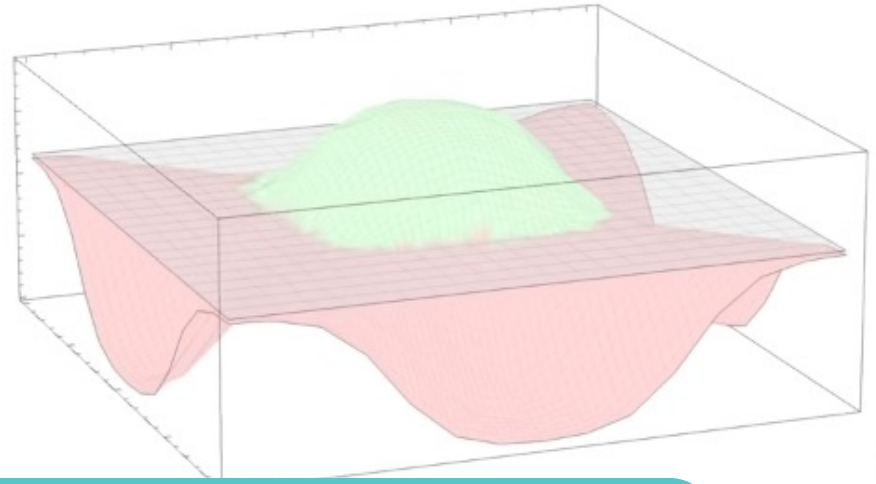

Por lo que se pueden resolver problemas complejos

5. Arquitectura de redes neuronales

- Son la base de las **redes profundas**, actualmente muy utilizadas con mucho éxito.
- Cada **capa extrae características** cada vez más complejas
  - Necesitamos un conjunto de neuronas para resolver problemas no lineales.

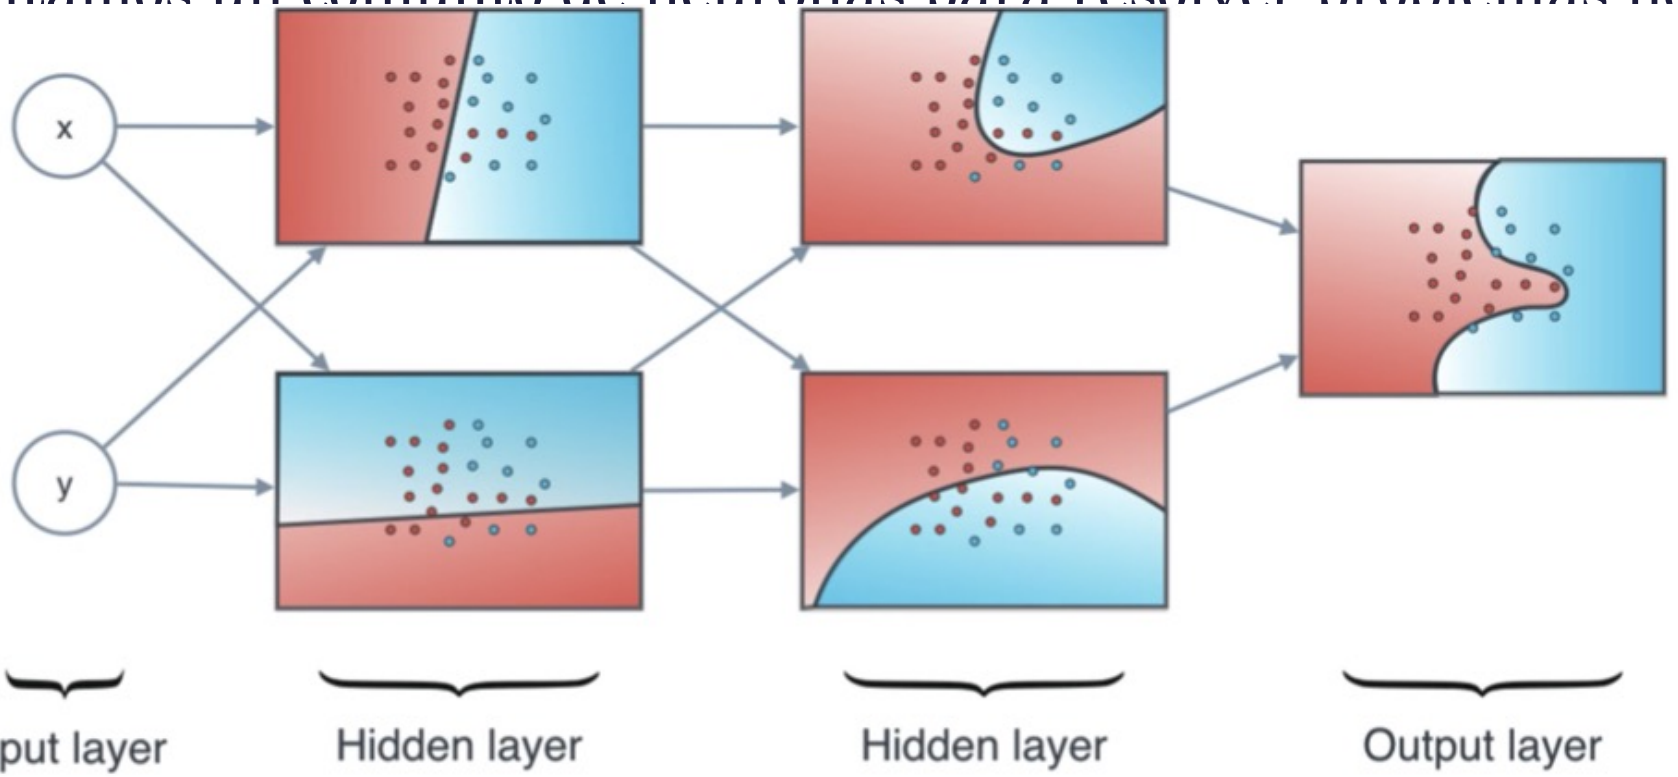

Backpropagation

ETS de Ingeniería Informática

UNED

1. Contexto

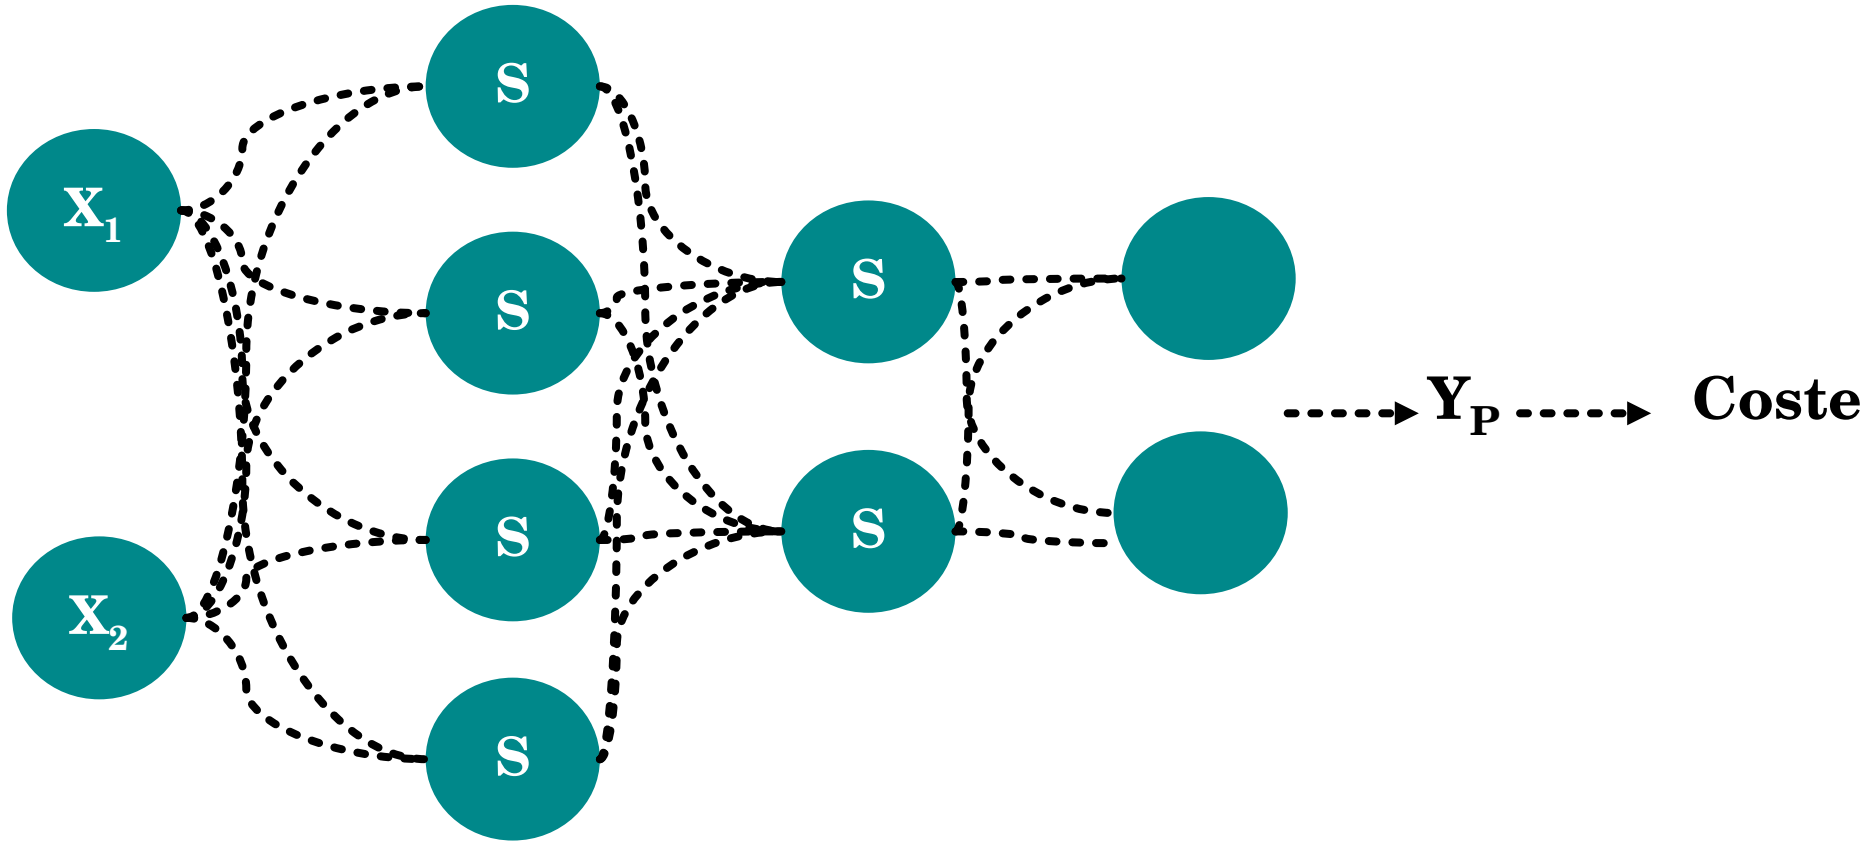

2. Conexiones e iteraciones

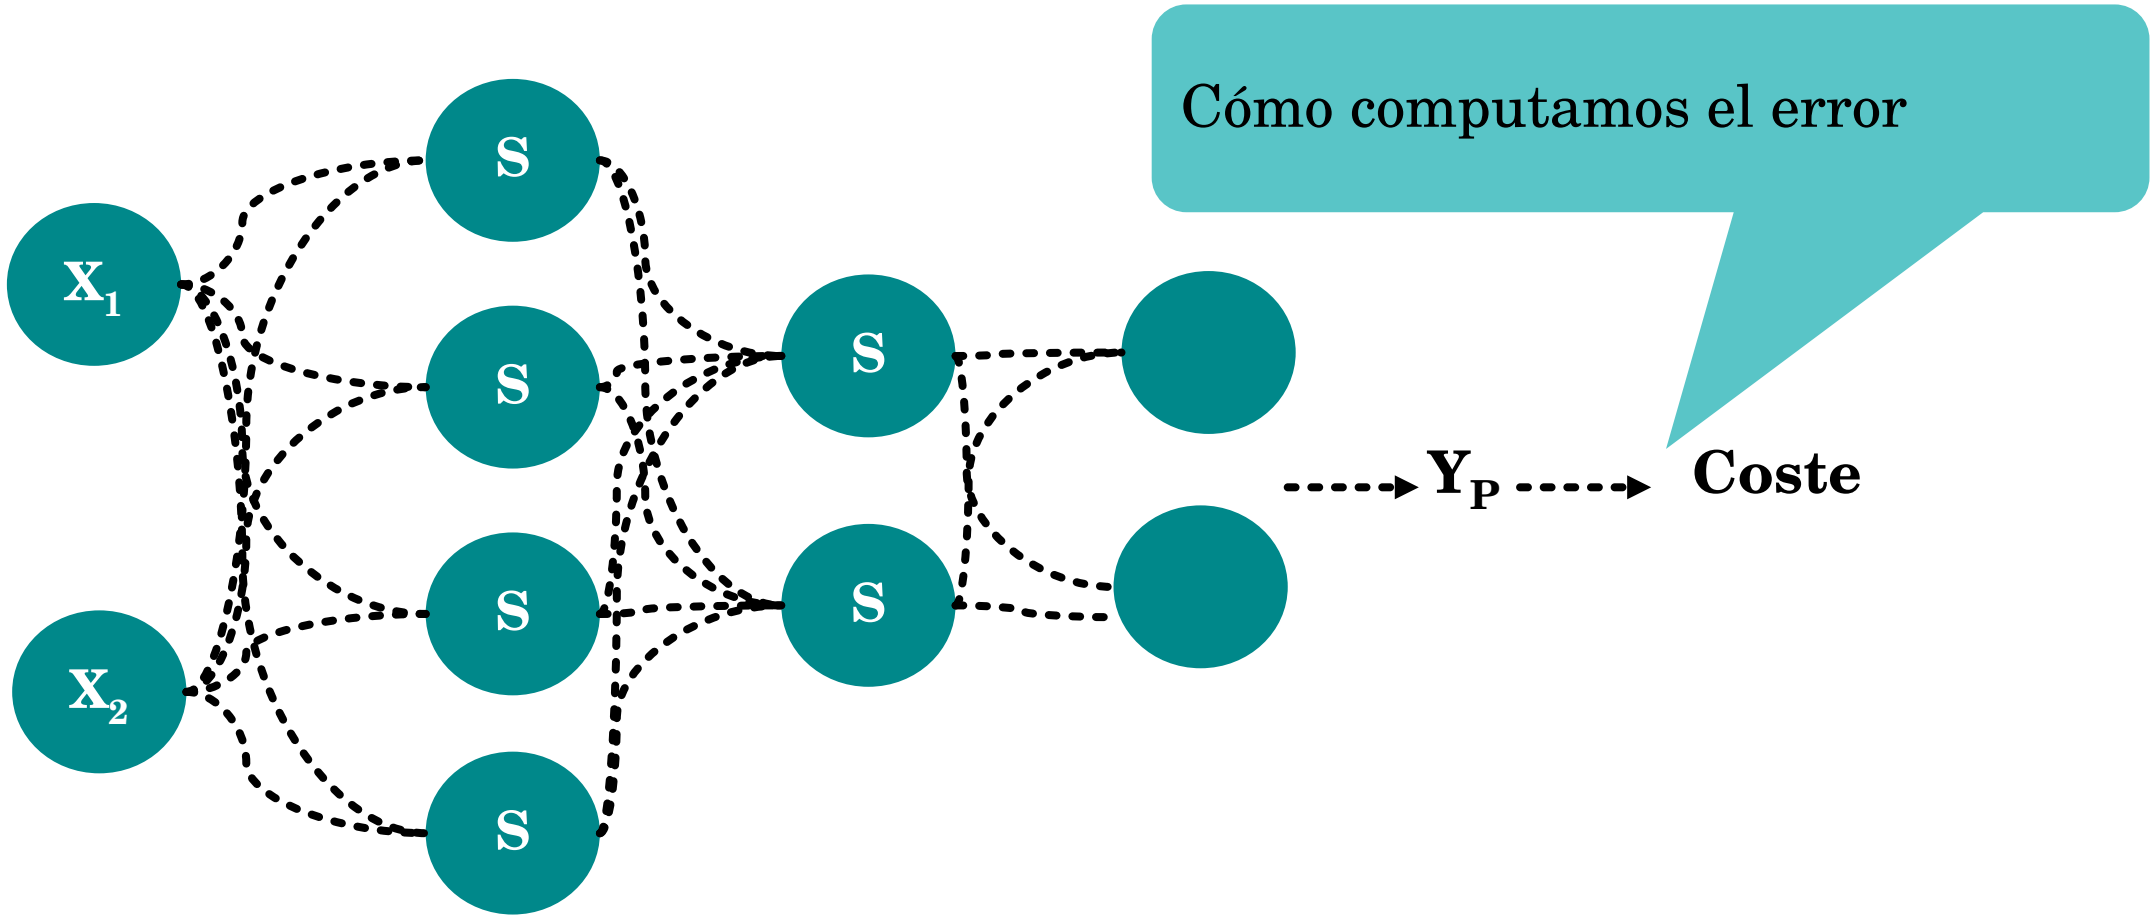

2. Conexiones e iteraciones

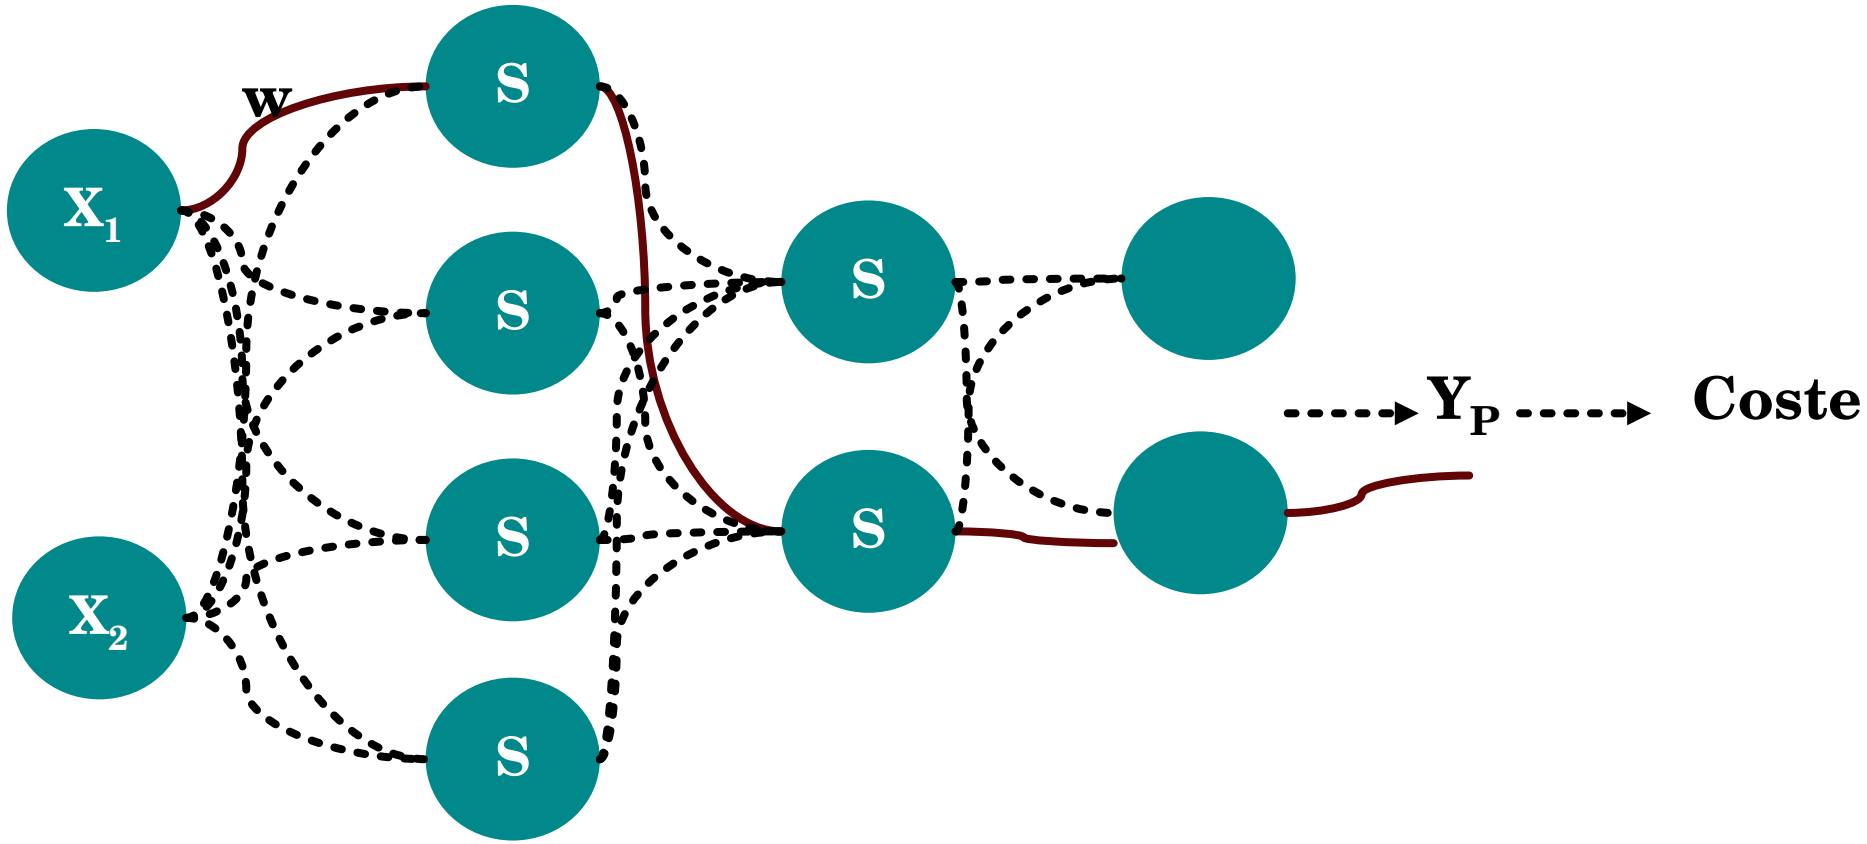

2. Conexiones e iteraciones

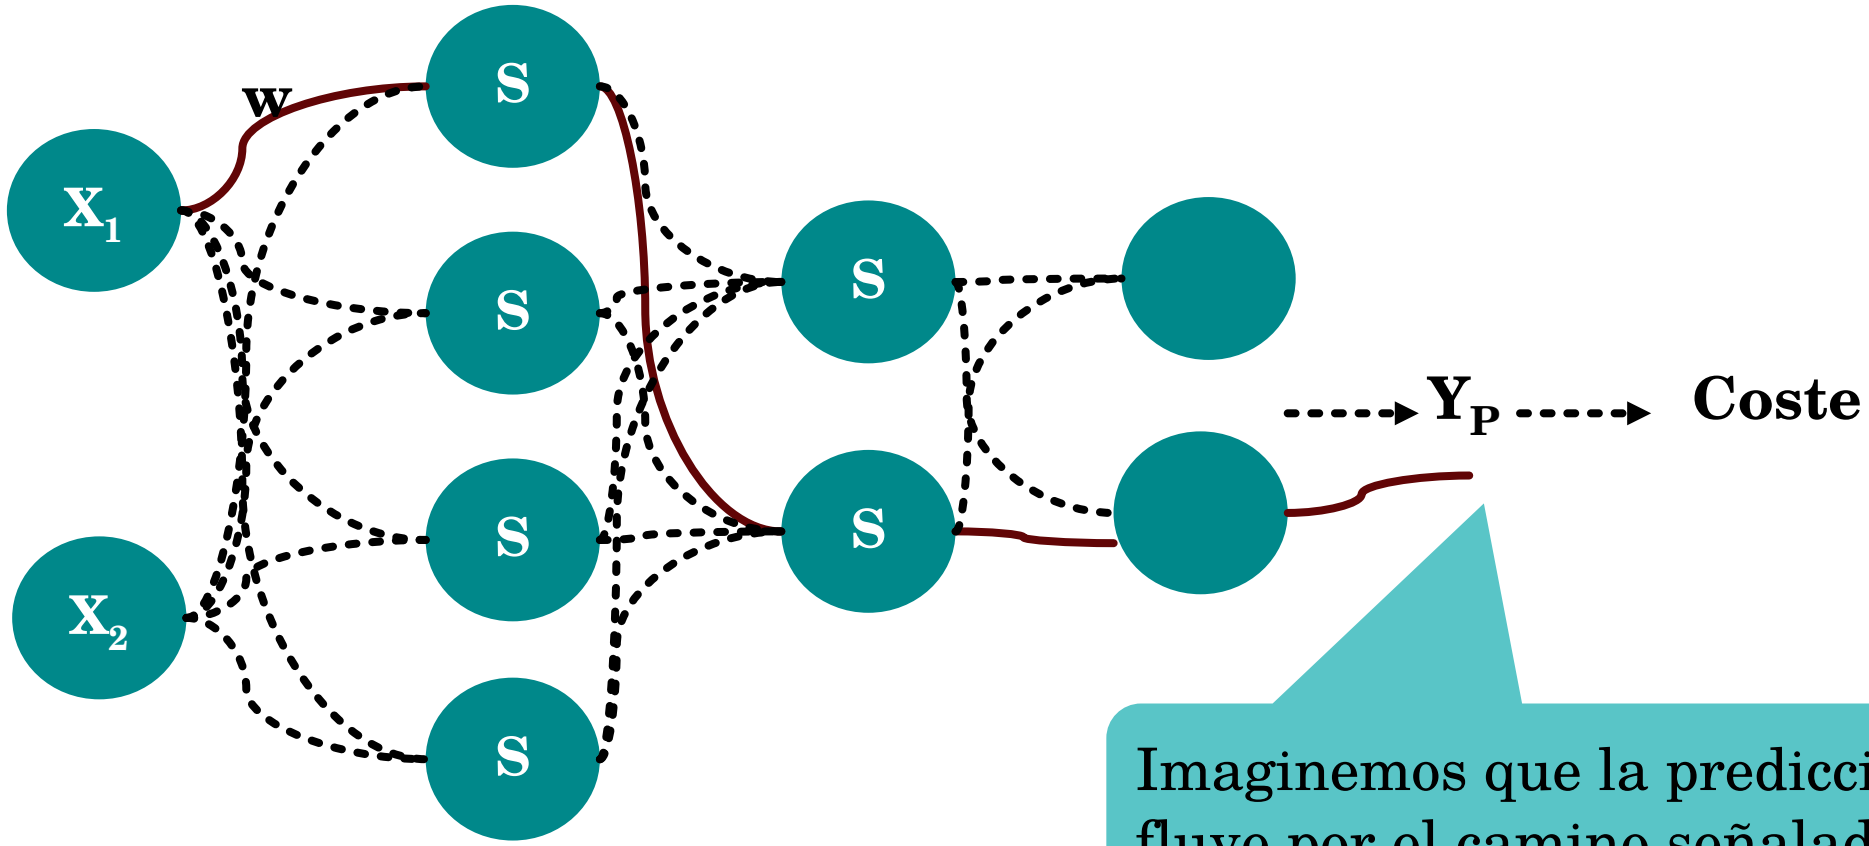

2. Conexiones e iteraciones

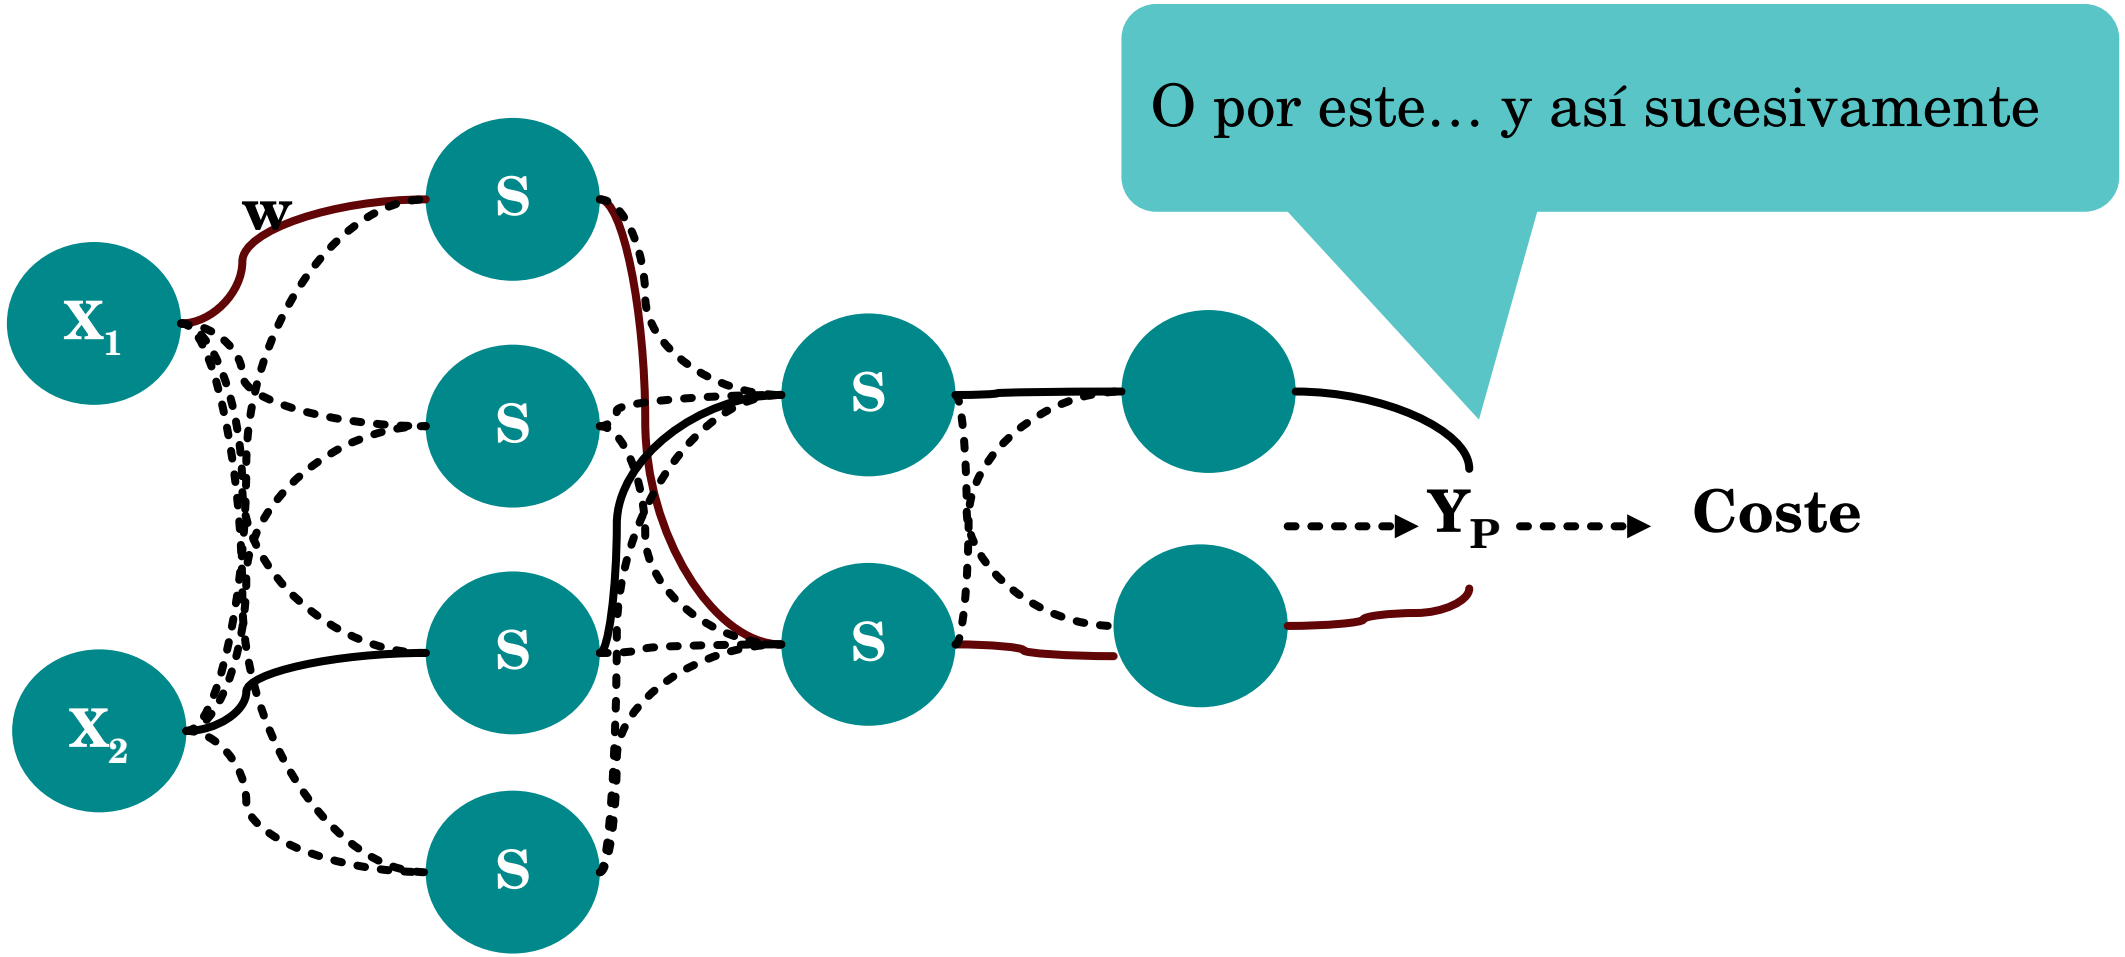

2. Conexiones e iteraciones

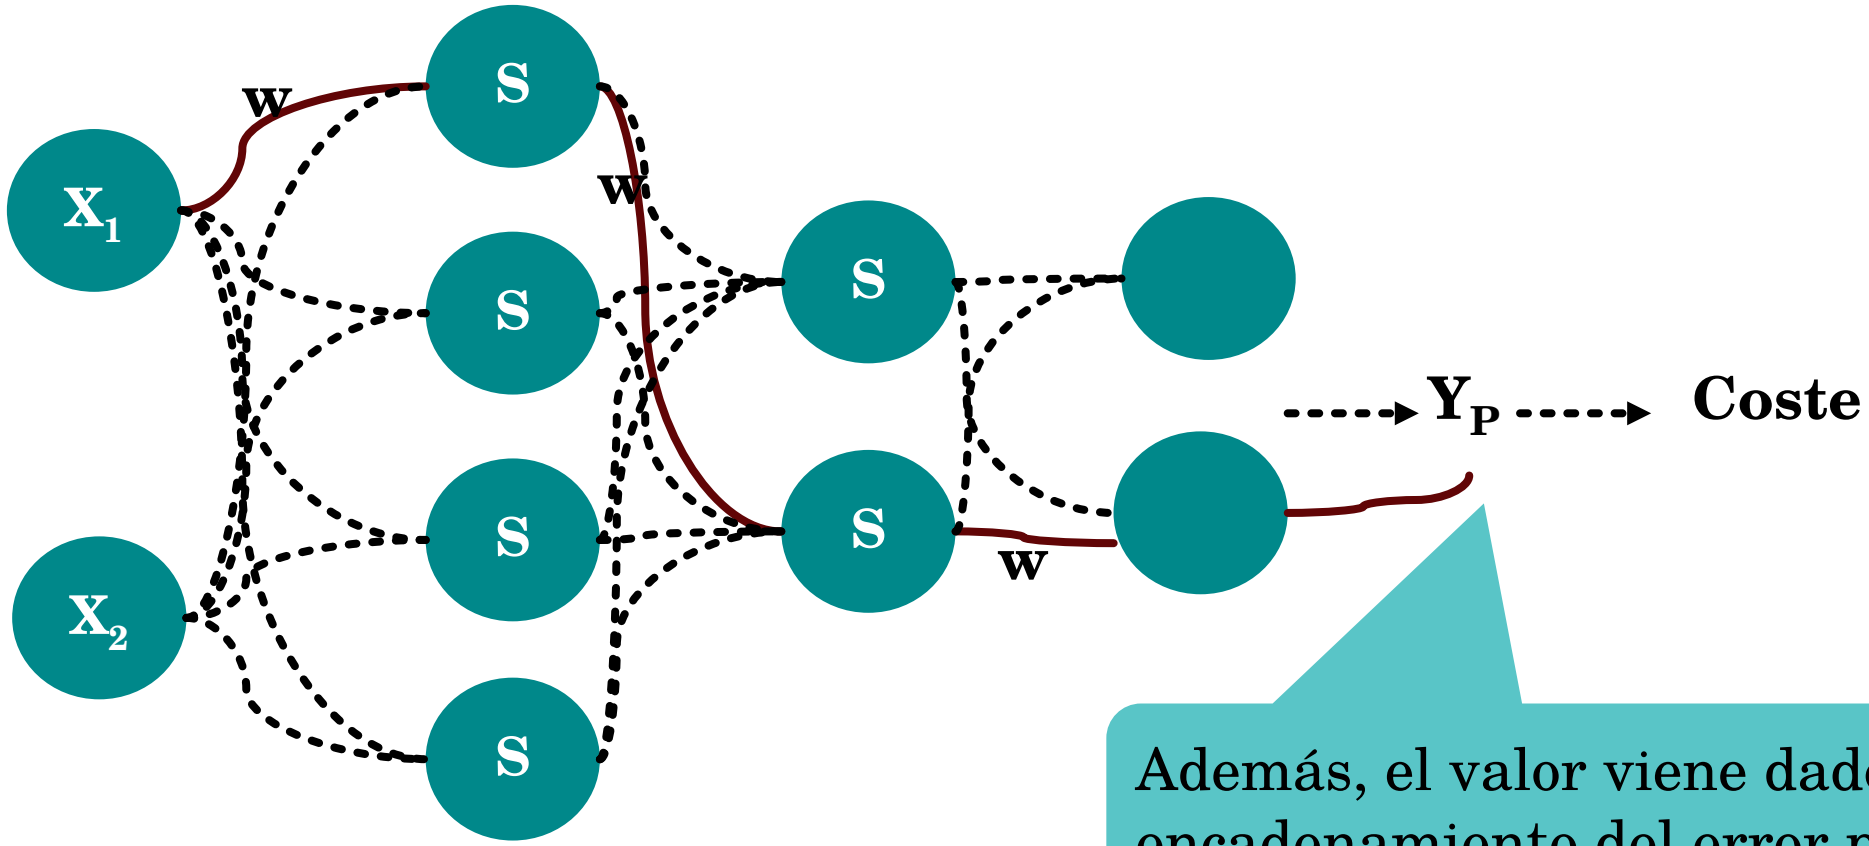

Además, el valor viene dado por encadenamiento del error previo

2. Conexiones e iteraciones

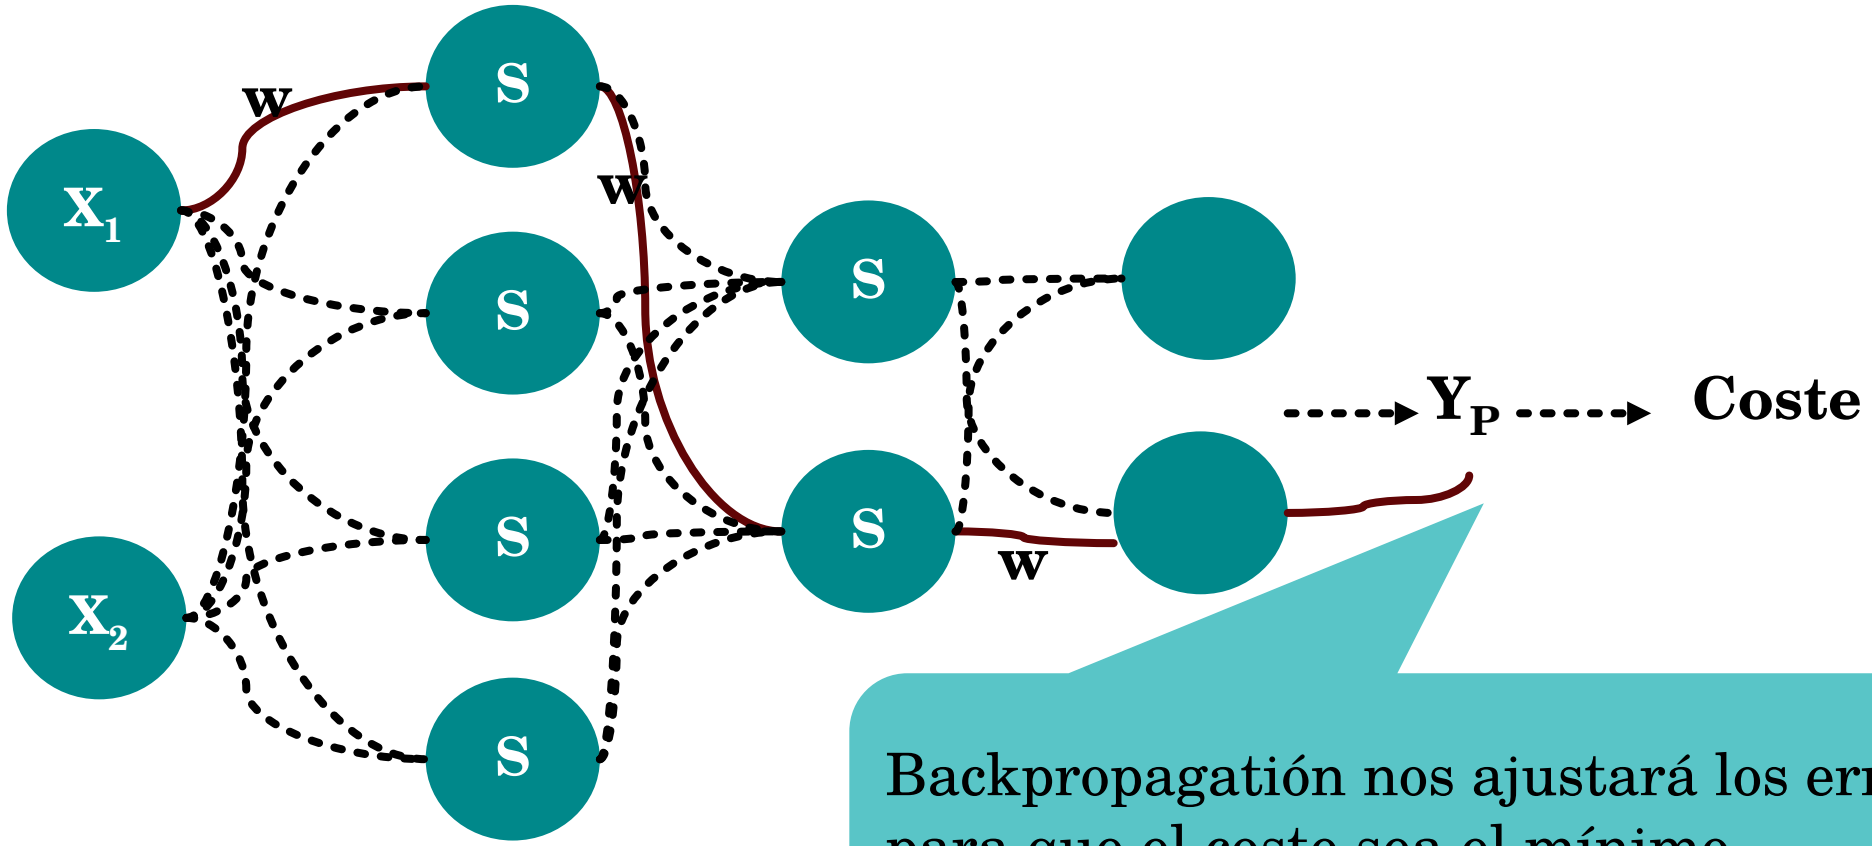

Backpropagatión nos ajustará los errores para que el coste sea el mínimo.
Para ello, utilizará el Gradiente Descendiente

3. Pensemos en el día a día

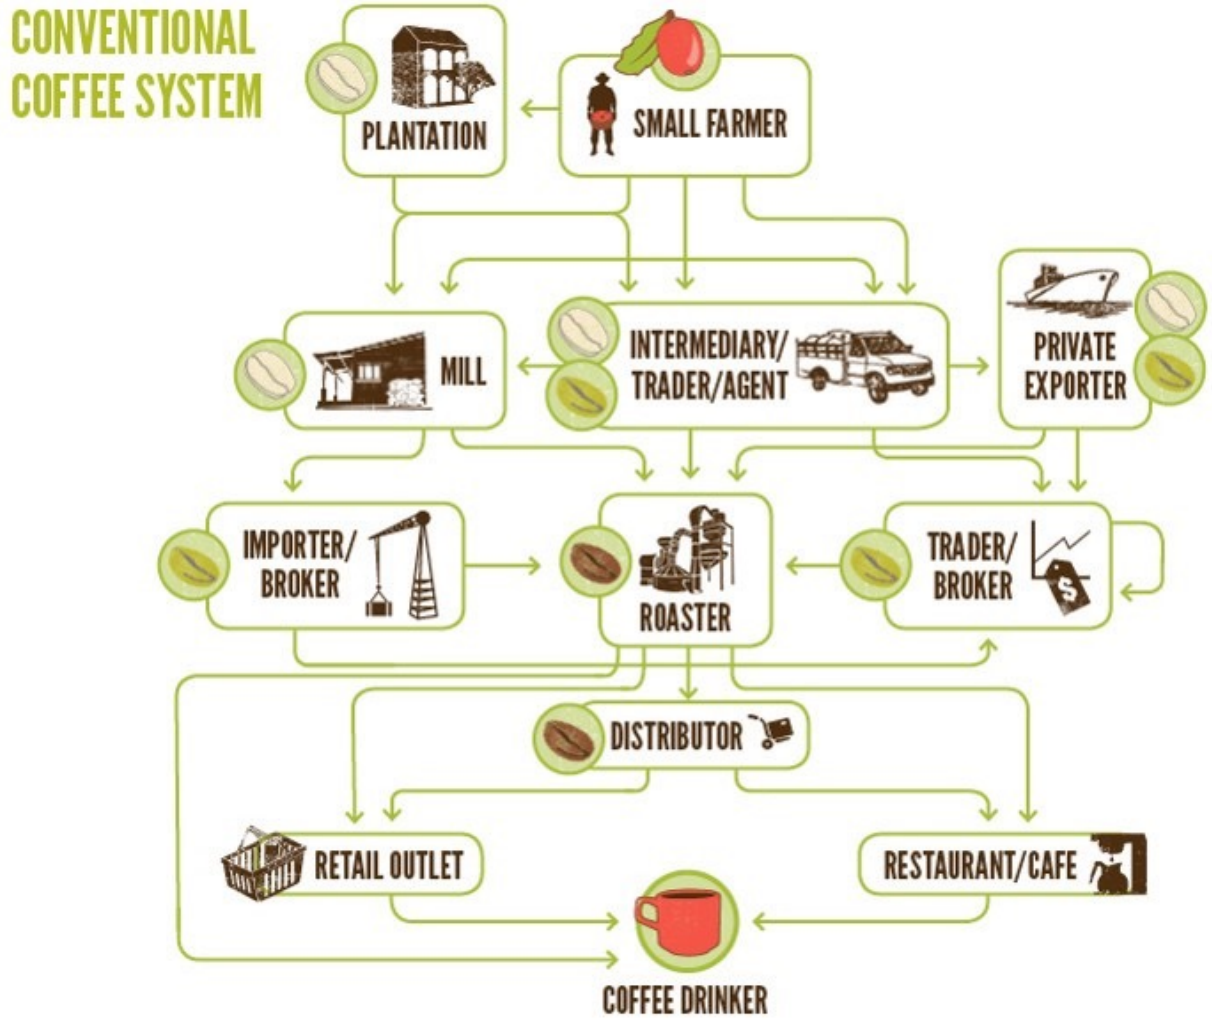

3. Pensemos en el día a día

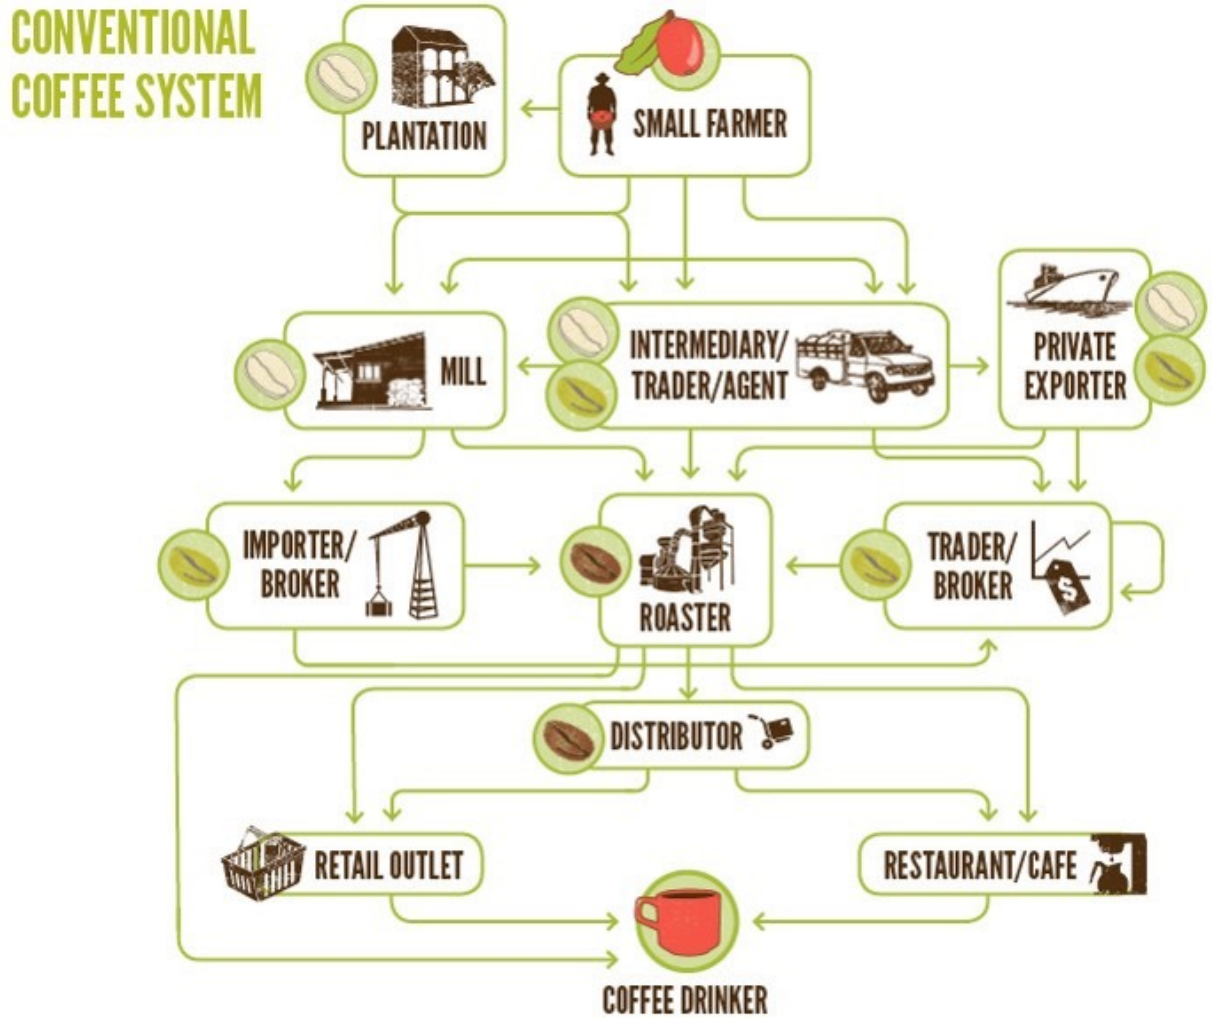

3. Pensemos en el día a día

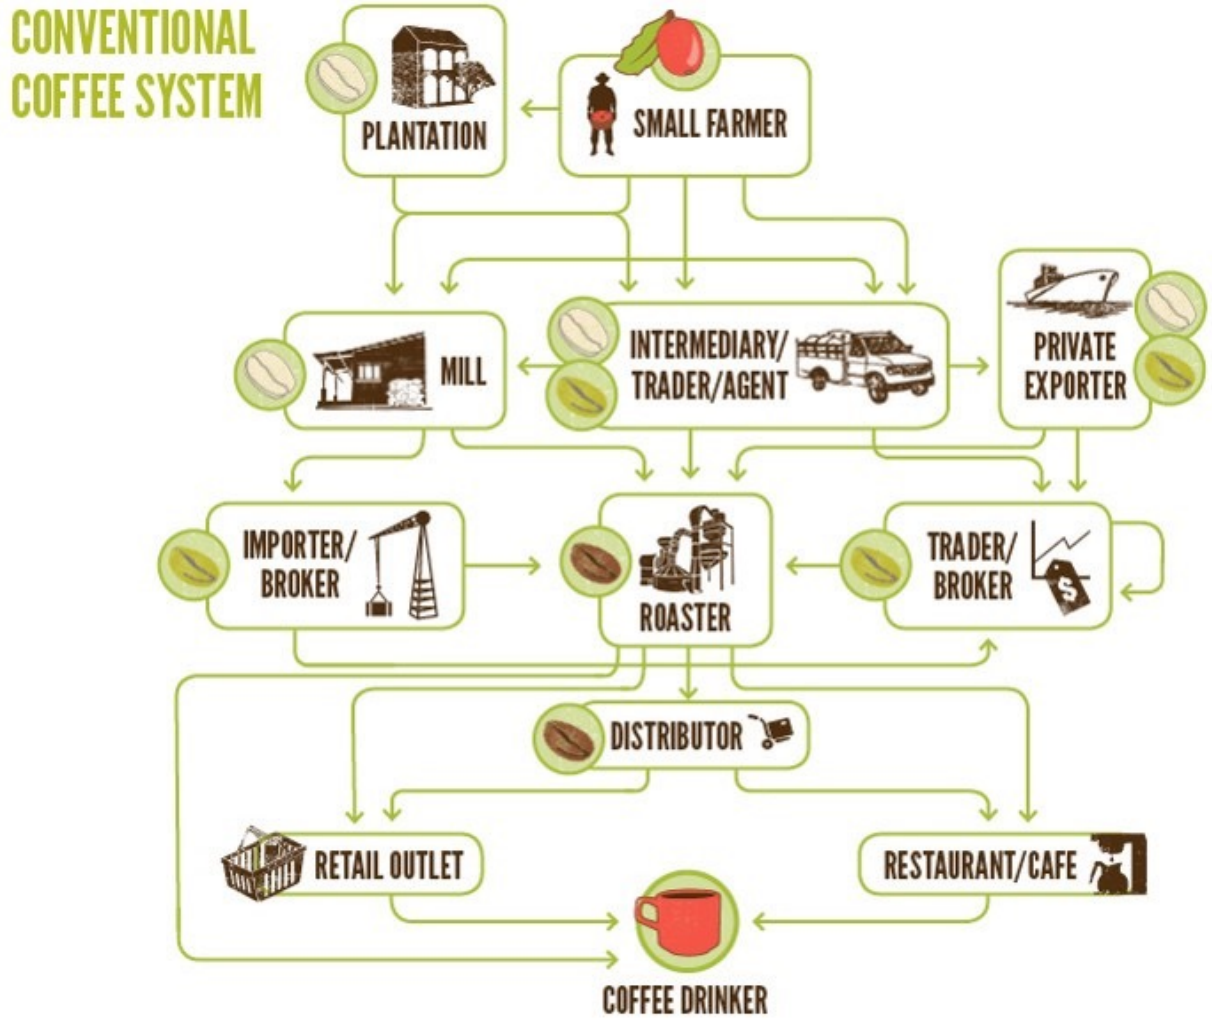

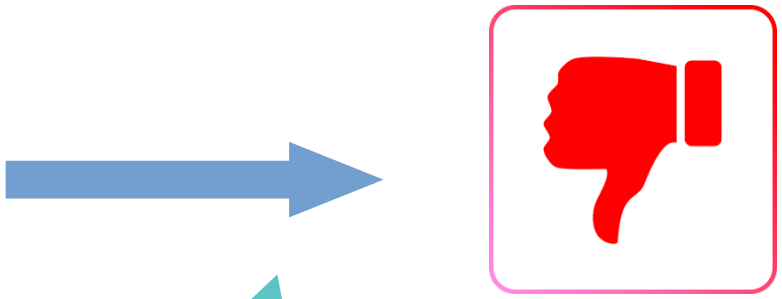

¿De quién es la culpa?

3. Pensemos en el día a día

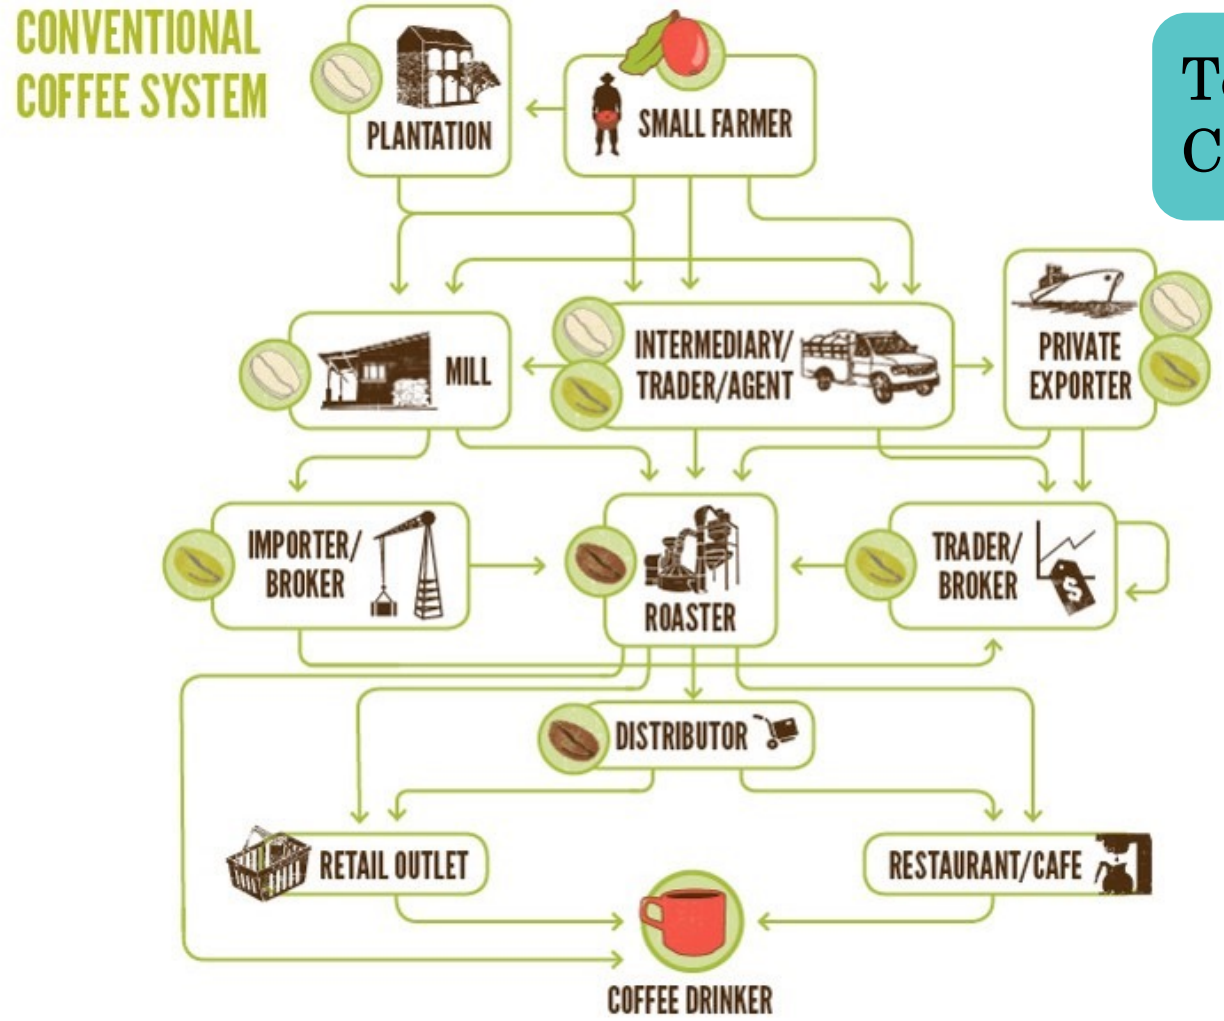

Tenemos que analizar toda la Cadena para ver quién es el culpable

3. Pensemos en el día a día

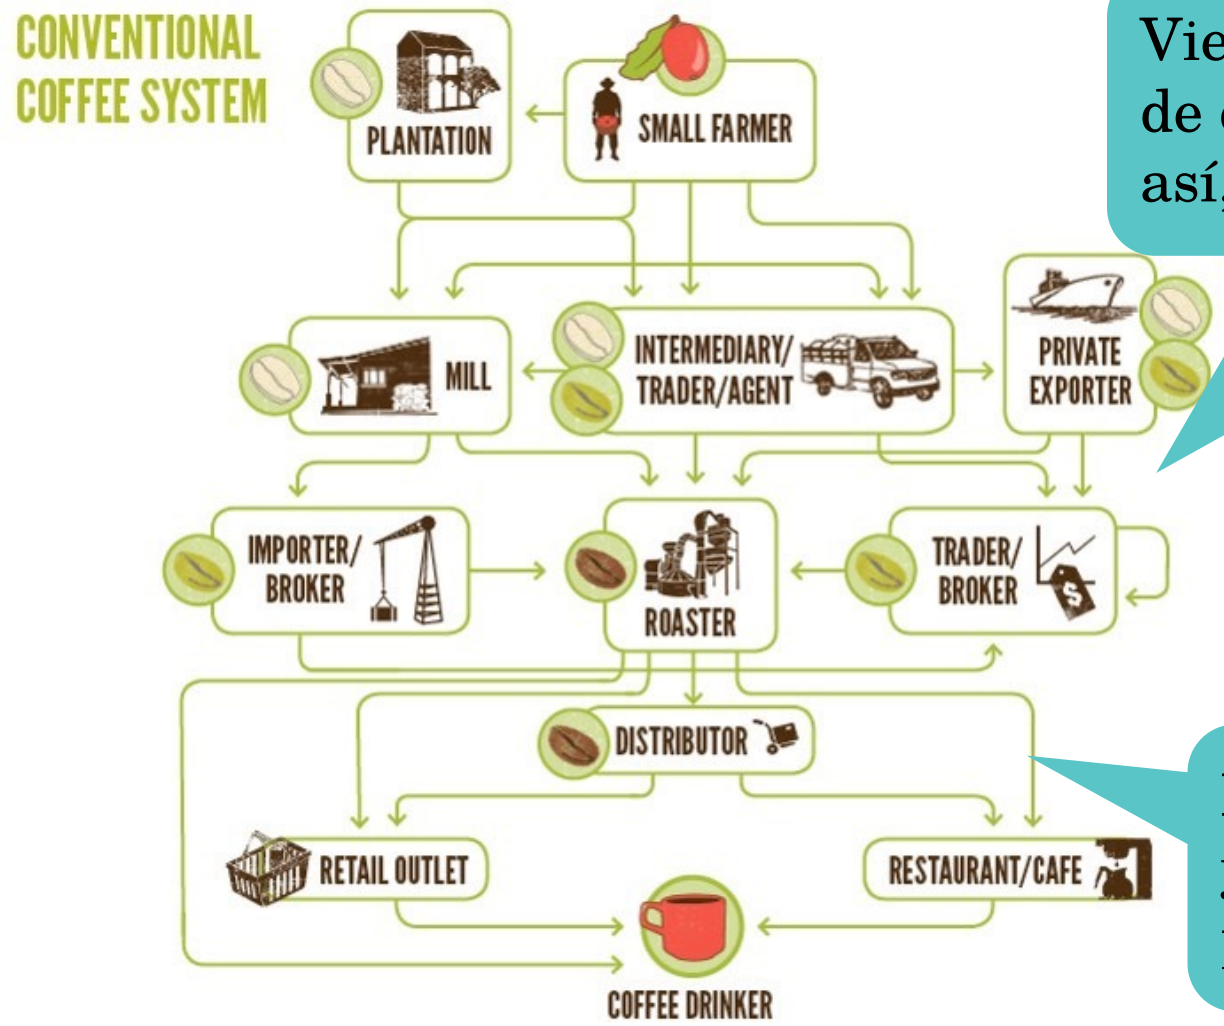

Viendo el porcentaje de implicación de cada neurona en la predicción y, así, corregirlo

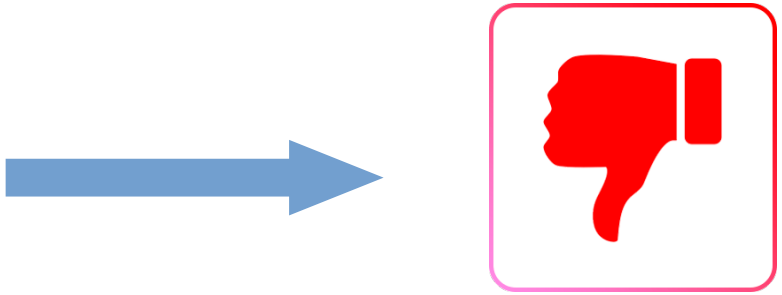

Para ello, analizamos el error y vamos analizando hacia atrás para corregirlo

3. Pensemos en el día a día

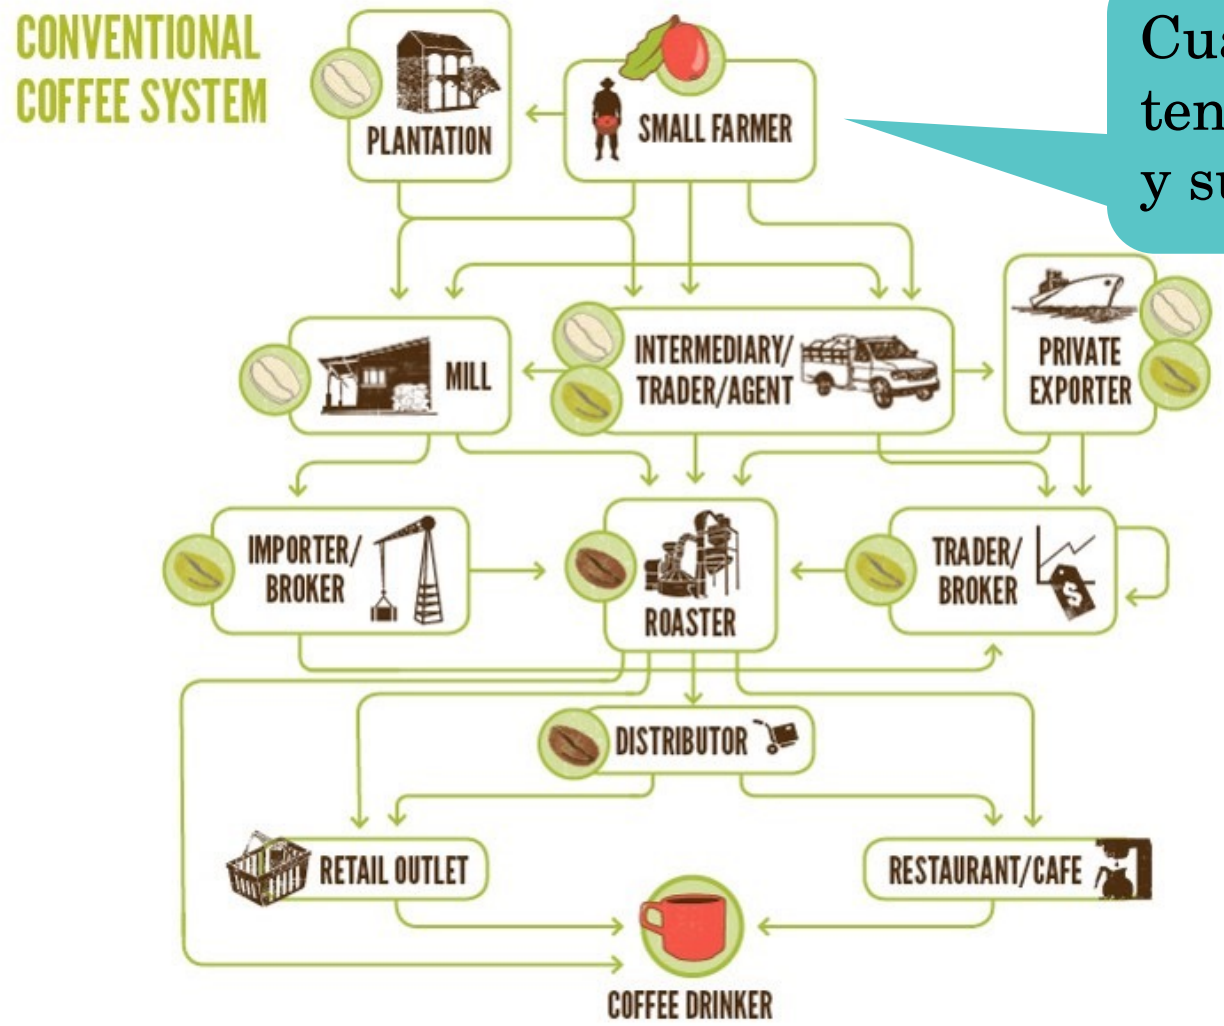

Cuando lleguemos a la primera capa tendremo el error de cada neurona y sus parámetros

¡Gracias!

Dr. Manuel Castillo-Cara
www.manuelcastillo.eu
Departamento de Inteligencia Artificial
Escuela Técnica Superior de Ingeniería Informática
Universidad Nacional de Educación a Distancia (UNED)